Прогноз безналичных расходов муниципалитетов и поиск структурных сдвигов

Конкурс СберИндекса 2026, направление «Прогнозирование». Методологический отчёт

Нарек Малоян

Октябрь 2026

0. Карта критериев

Критерий (вес)	Где в отчёте	Главное число или вывод
Простота объяснения методологии (10%)	§1, рис. 1; §2	4 шага: общий ритм страны, отклонение города, ансамбль, сторож
Сравнение моделей, лучше Prophet на 4 горизонтах (20%)	§3	MAE 306 / 435 / 446 / 658 против 563 / 574 / 652 / 1361; значимо на h = 1, 6, 12
Сравнение методов поиска сдвигов (20%)	§5	10 онлайн + 6 офлайн методов при равной частоте ложных тревог; выбор: BOCPD-подтв.
Фундаментальные модели (15%)	§4	на сырых рядах хуже наивной; на локальной компоненте в 1.5-3 раза лучше
Интеграция новостей (15%)	§6	GDELT 1,55 млн документов + реестр ЧС из официальных источников; правило «as-of»; event study паводка
Метрики: MAE и R^2 (10%)	§7	MAE, R^2 на уровнях и на изменении, WAPE, MdAPE, смещение, покрытие и WIS интервалов
Интерпретация, воспроизводимость, выводы (10%)	§8-10	проверка прогноза 2025 на факте; `make quick` со свежего клона за 2 минуты

1. Методология за одну страницу

Задача. Прогноз средних безналичных расходов на жителя для 2016 муниципальных образований (МО) по 6 категориям (12 096 рядов) на 1, 3, 6 и 12 месяцев. Поиск точек структурных сдвигов.

Главная трудность. В каждом ряду 24 точки (2023-01..2024-12). Перед прогнозом на 12 месяцев у модели меньше одного года истории. Свою годовую сезонность ряд оценить не может.



Рис. 1: Методология за минуту: четыре шага

1. **Общий ритм страны.** Сезонность и инфляция почти одинаковы для всех МО. Мы берём медиану по

2016 МО в каждом месяце. Так сезон оценивается по 2016 рядам, а не по 24 точкам одного ряда. Годовой рост на 12 месяцев вперёд берём из оборота розничной торговли Росстата.

2. **Отклонение города.** Остаток после шага 1 — медленный ряд без общего сезона. Его прогнозируют фундаментальные модели (FM), градиентный бустинг (GBM) и классические модели.
3. **Сложить и усреднить.** Прогноз = ритм страны × отклонение города. 35 моделей объединяет ансамбль. Веса для каждого горизонта выбираются **только на validation**.
4. **Сторож.** Детекторы сдвигов следят за отклонением города. Новости и реестр ЧС подсказывают, где искать сдвиг. Сигнал говорит: здесь ряд сломался, прогнозу по старой истории верить нельзя.

Результат на отложенном окне (test, 2024-07..12), MAE в рублях на жителя в месяц:

	h = 1	h = 3	h = 6	h = 12
Prophet (базовая модель организатора)	563	574	652	1361
Ансамбль (наше решение)	**306**	**435**	**446**	**658**
Снижение MAE к Prophet	−46%	−24%	−32%	−52%
ΔMAE, 95% ДИ двустороннего бутстрепа (МО × месяц)	[−511; −37]	[−302; +16]	[−353; −66]	[−1110; −430]
Значимо при 5%?	да	**нет**	да	да
R^2 на изменении (ансамбль)	0.42	0.59	0.53	−0.17
«Все категории», ансамбль / Prophet	837 / 1792	1147 / 1772	1181 / 2057	1695 / 4060

Ансамбль лучше Prophet на всех четырёх горизонтах по точечной оценке. Разница статистически значима на h = 1, 6 и 12. На h = 3 ансамбль выигрывает в 5 из 6 месяцев test, но 95% ДИ включает 0. На h = 3 ни одна из 35 моделей не лучше Prophet значимо (приложение Б). Метод ДИ — в §7.

Глоссарий.

Термин	Значение
origin o	месяц, в конце которого делается прогноз; модель видит только месяцы 0..o
горизонт h	на сколько месяцев вперёд прогноз; цель — месяц o + h
validation / test	целевые месяцы 2024-01..06 (выбор) / 2024-07..12 (итоговая оценка)
национальная компонента n	медиана log-расходов по всем МО категории в месяце: сезон и инфляция
локальная компонента d	log-расходы МО минус n: отклонение города от страны
FM, zero-shot	фундаментальная модель временных рядов; zero-shot — без дообучения на наших данных
ансамбль Caruana	жадный отбор моделей с возвращением; вес = доля шагов, на которых модель выбрана
R^2 на изменении	доля объяснённой вариации log(y_цель / y_origin), а не уровней
CPD, детектор	метод поиска точки структурного сдвига (change-point detection)
BOCPD, CUSUM	байесовский онлайн-детектор длины режима; кумулятивные суммы отклонений

2. Данные и честный протокол

Источник	Что берём	Лицензия / условия
СберИндекс, `consumption.parquet`	Средние безналичные расходы на жителя МО, руб./мес., 6 категорий, 2023-01..2024-12	CC BY-SA 4.0; только для конкурса (Положение §9.2.2)
СберИндекс, `market_access.parquet`, справочник МО	Индекс доступности рынков; регион, тип МО, координаты центра, полигоны	то же
Росстат, `Oborot_2025.xls`	Оборот розничной торговли РФ по месяцам, 2000-2025	открытые данные, со ссылкой на источник
Производственный календарь РФ	Рабочие и календарные дни месяца	пакет `holidays` (MIT) + постановления Правительства
GDELT 1.0 GKG	Темы, места и тональность новостей	свободное использование со ссылкой на GDELT
Реестр событий (наш, §6.2)	Режимы ЧС паводка 2024, ключевая ставка, тарифы: даты объявления и вступления, ссылки	официальные сайты МЧС, Правительства, регионов, Банка России

Источник	Что берём	Лицензия / условия
Портал СберИндекса, consumer-spending	Национальные расходы по месяцам 2018-2026	открытые данные; только проверка 2025 и приложение A

Панель: ряды со всеми 24 месяцами, 2016 МО × 6 категорий = **12 096 рядов**. Двенадцати регионов в данных нет (Белгородская, Курская обл., Краснодарский край и др.). «Все категории» не равны сумме пяти категорий (сумма ≈ 72%). Поэтому каждая категория — отдельный ряд. «Все категории» дают 59% суммы уровней и сильнее всего влияют на общий MAE.

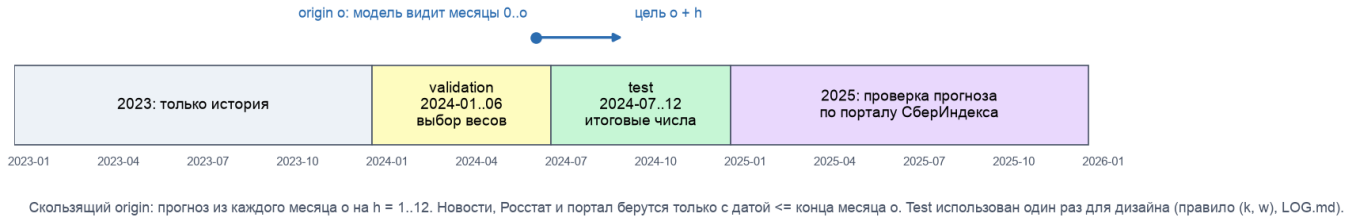


Рис. 2: Честный протокол: история, validation, test, проверка 2025

Протокол.

- **Скользящий origin.** Прогноз из месяца o на h месяцев вперёд использует только месяцы 0..o. Для каждой модели строится «куб» прогнозов: все origin 0..23 и все h = 1..12.
- **Два окна.** Validation: целевые месяцы 2024-01..06. Test: 2024-07..12. Веса ансамбля, параметры декомпозиции и выбор моделей делаются на validation.
- **Один взгляд на test в дизайне заголовка.** Правило «отдельные (k, w) для h ⩽ 3» (§3.1) мы ввели после первого просмотра test. Это одна итерация дизайна, она записана в `LOG.md`. Правило улучшило h = 1 и ухудшило h = 3; мы его не откатывали. Других выборов по test в заголовке нет. Всё, что сделано позже с просмотром test, вынесено в приложение A с пометкой «пост-hoc».
- **Внешние данные «as-of».** В origin o: Росстат с лагом 2 месяца (данные o ⩽ o − 2 уже опубликованы), новости с датой публикации ⩽ конца месяца o, реестр ЧС с датой объявления ⩽ конца месяца o. Национальная компонента месяца t использует только данные месяца t.
- **GBM** в origin o обучается только на парах (o', h') с целевым месяцем o' + h' ⩽ o.
- **Все модели на всех 12 096 рядах**, включая Prophet. Сравнение парное, на одних и тех же точках.
- **Тесты на утечку** (`make smoke`, `tests/test_leakage.py`): прогноз в origin o и тревога детектора в месяце t не меняются, если изменить данные после o (после t).

Ограничение протокола. В validation для h = 12 origin лежат в 2023-01..06 (1-6 месяцев истории). Веса для длинных горизонтов выбираются в режиме более короткой истории, чем на test.

3. Модели прогнозирования и выбор лучшей

3.1. Национальная и локальная компоненты

```
log y[i,t] = n[c,t] + d[i,t]
```

- **n[c,t]** — национальная компонента категории c: медиана log y по всем МО в месяце t.
- **d[i,t]** — локальная компонента МО. В ней нет общей сезонности. Она меняется медленно, а локальный шок (паводок, закрытие предприятия) даёт в ней ступеньку.

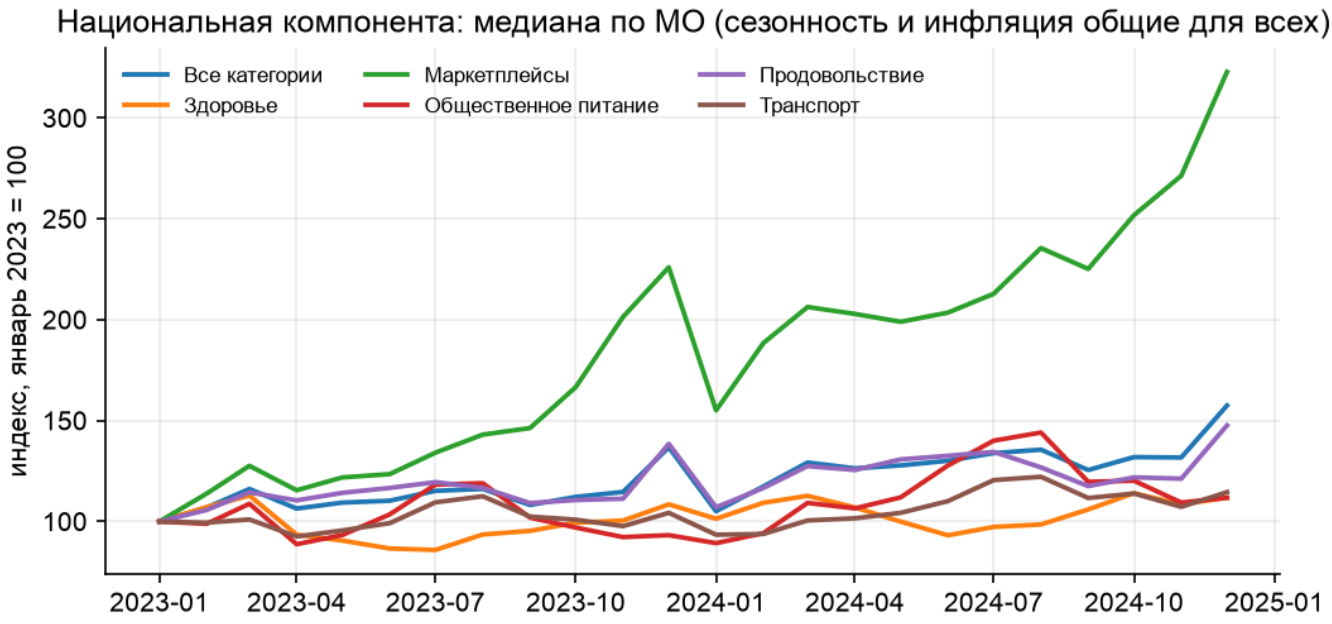


Рис. 3: Национальная компонента: сезонность общая для всех МО

Прогноз национальной компоненты (звёздочка * обозначает прогноз):

$$n*[c,T] = n[c,T-12] + G, \quad G = w \cdot YoY_own(k) + (1 - w) \cdot YoY_Росстат$$

YoY_own — средний годовой прирост n за последние k месяцев. YoY_Росстат — годовой прирост оборота розничной торговли со сдвигом 2 месяца. Пока у СберИндекса нет 12 месяцев истории (origin до 2023-12), G берётся только из Росстата. Так решается задача h = 12: годовой темп роста приходит из внешнего источника. Параметры на validation: k = 1; w = 0.75 для h = 1-2, 0.25 для h = 3, 0.5 для остальных. Сезонный профиль Росстата не подошёл (февраль −10% у Росстата, −1% у СберИндекса), поэтому из Росстата берём только темп роста. Итог: y* = exp(n* + d*).



Рис. 4: Архитектура решения

3.2. Модели

Группа	Модели	Роль
Наивные	naive, сезонная наивная × собственный YoY (k = 3), × национальный YoY, с учётом сдвигов	Опорные точки
Базовая организатора	**Prophet** (Фурье 3-го порядка, мультипликативная), отдельно на каждый ряд и origin	Цель «превзойти Prophet»
Классика	AutoETS, AutoTheta, AutoARIMA (statsforecast)	Сравнение
Первый бейзлайн	LightGBM v1 на log(y_T/y_o) без декомпозиции	Вклад архитектуры
Декомпозиция	n* + d; *d* = persistence / среднее 3 мес. / локальный сезон	Простая сильная модель

Группа	Модели	Роль
Фундаментальные	Chronos-Bolt S/B, Chronos-2, Chronos-2 мультивариантный, TimesFM 2.5, TiRex-2, Toto-2.0 22M/313M, Chronos-2 дообученный	§4
GBM	LightGBM и CatBoost на изменении d, прямой мульти-горизонтный	Признаки: лаги d, d год назад, региональный d, рост n*, календарь, FM, новости, CPD
Ансамбль	Отбор Caruana (жадный, с возвращением, 20 шагов), отдельно для каждого h, пул соседних h ± 1	Веса только по validation

3.3. Как выбрана итоговая модель

Правило выбора (зафиксировано до test): итоговый прогноз — ансамбль, потому что на validation он лучше каждой одиночной модели на всех h. Веса ансамбля подбираются на validation. Пул из 35 моделей зафиксирован в `configs/config.yaml`; `make ensemble` воспроизводит веса бит в бит.

h	Validation: лучшая одиночная	Validation: ансамбль*	Test: ансамбль	Ранг на test	Test: лучшая одиночная (после)	Test: Prophet
1	400 (TimesFM 2.5, декомп.)	301	306	10 из 36	296 (TimesFM 2.5, декомп.)	563
3	569 (Theta)	369	435	2 из 36	420 (LightGBM v1)	574
6	540 (TimesFM 2.5, декомп.)	484	446	**1** из 36	493 (TimesFM 2.5, декомп.)	652
12	993 (GBM база)	800	658	**1** из 36	691 (декомпозиция)	1361

* MAE ансамбля на validation посчитано на том же окне, где подобраны веса, и поэтому оптимистично.

Выбор на validation не гарантирует первое место на test. На h = 1 ансамбль 10-й из 36, но отставание от лучших одиночных моделей (296) не значимо: ΔMAE +9, 95% ДИ [−38; +67]. На h = 3 лучшая на test модель (LightGBM v1, 420) на validation была одной из худших (676); выбрать её заранее было нельзя. Разница с ней тоже не значима: +15 [−37; +76]. Мы не меняли выбор после test.

3.4. Сравнение на test

MAE на **test** (руб. на жителя в месяц). Жирным — лучшая модель в столбце. Полная таблица с validation, рангами, R^2 на изменении и ДИ для каждой модели — в приложении Б.

Модель	h = 1	h = 3	h = 6	h = 12
Наивная	624	864	1124	1289
Сезонная наивная × YoY	340	469	663	1289
Prophet	563	574	652	1361
AutoETS	634	807	1036	1383
AutoTheta	614	744	767	922
AutoARIMA	645	862	1094	1529
LightGBM v1 (без декомпозиции)	313	**420**	761	969
TimesFM 2.5, zero-shot на уровнях	559	797	1283	1691
Chronos-2, zero-shot на уровнях	613	877	1361	1817
Декомпозиция, d = persistence	318	566	526	691
TimesFM 2.5 на локальной компоненте	**296**	522	493	729
Chronos-2 мультивариантный на лок. комп.	302	531	532	772
Chronos-2 дообученный на лок. комп.	308	528	527	771
GBM LightGBM, все признаки	**296**	532	509	724
GBM CatBoost, все признаки	302	536	513	712
Ансамбль	306	435	**446**	**658**

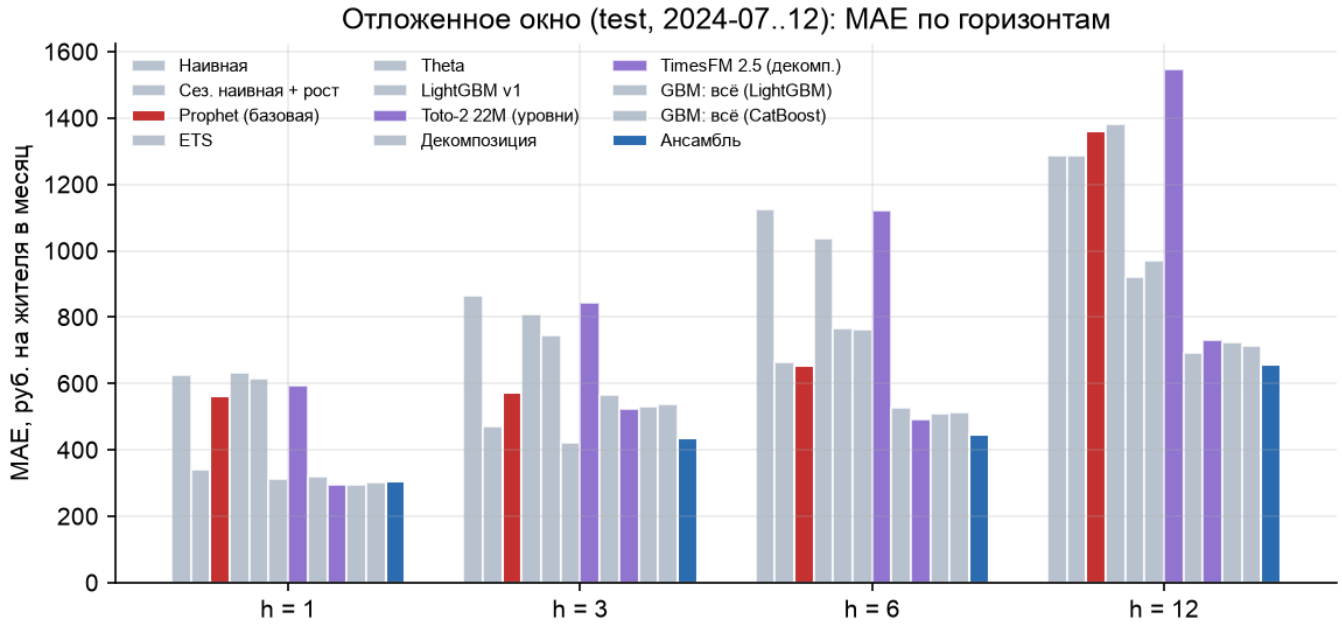


Рис. 5: MAE по горизонтам на test

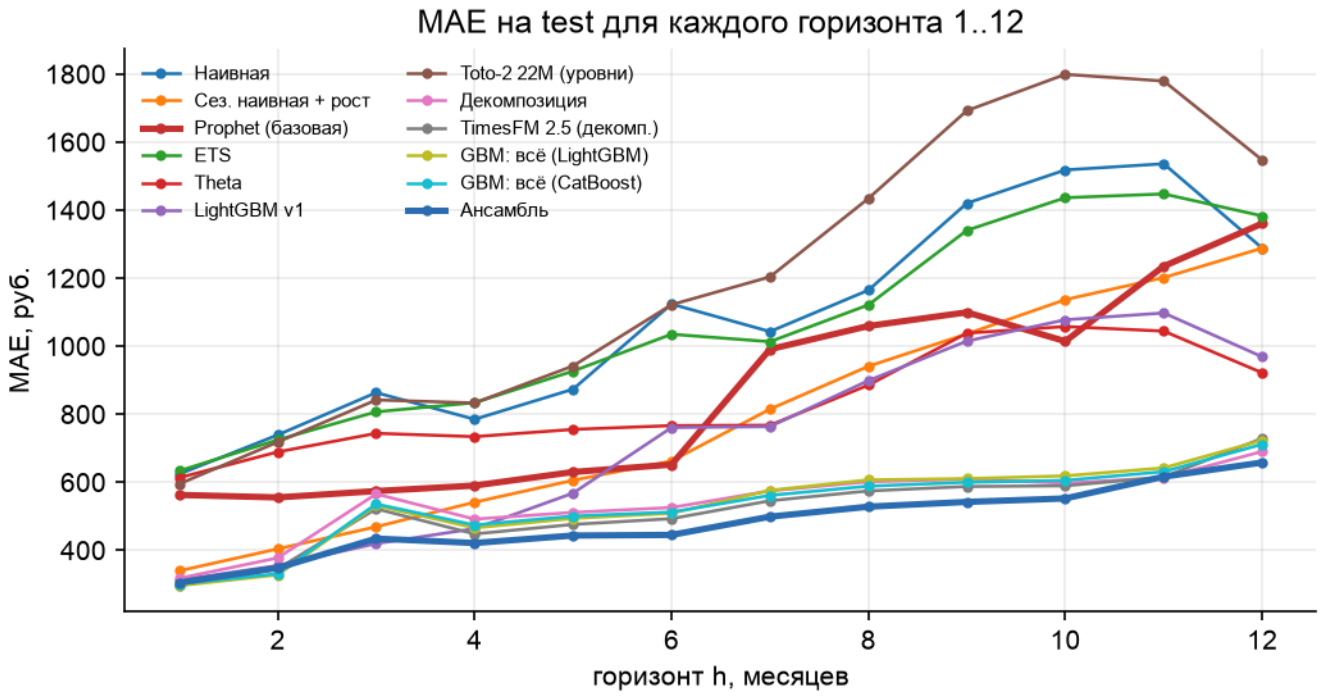


Рис. 6: MAE на test для каждого горизонта 1..12

Выводы.

- **Prophet проигрывает всем моделям на декомпозиции на всех горизонтах** по точечной оценке. На 24 точках он переоценивает тренд и плохо переносит декабрьский пик (смещение +6.8% на h = 12).
- **На h = 12 решает архитектура.** Модели без внешней информации о годовом росте (наивная, ETS, Prophet) дают 1289-1383. Национальная компонента с ростом Росстата снижает ошибку до 658-729.
- **На h = 1 сильные модели близки (296-318)**, различия между ними не значимы.

- **Состав ансамбля (веса validation):** h = 1 — сезонная наивная с учётом сдвигов 0.35, Theta 0.25, TimesFM 2.5 0.15; h = 6 — TimesFM 2.5 на локальной компоненте 0.55; h = 12 — GBM 0.45, Theta 0.25, Prophet 0.15. Prophet вошёл в ансамбль на h = 12: его ошибки слабо коррелируют с остальными.

3.5. Prophet — не соломенное чучело

Сильный результат против слабой настройки базовой модели ничего не стоит. Поэтому мы прогнали 10 конфигураций Prophet (по умолчанию; порядок Фурье 3 и 5; аддитивная и мультипликативная сезонность; обучение на log y; changepoint_prior_scale 0.01 / 0.05 / 0.5; плоский тренд; сжатая сезонность) на 400 МО (2400 рядов, по 80 МО из каждого квинтиля уровня), на тех же origin test. Лучшая конфигурация выбрана **по test** для каждого h — это заведомо в пользу Prophet.

На 400 МО, test, MAE	h = 1	h = 3	h = 6	h = 12
Prophet, наша конфигурация (Фурье 3, мульт.)	558	569	647	1316
Лучшая из 10 конфигураций (выбор по test)	452 (Фурье 5)	485 (Фурье 5)	575 (Фурье 5)	1049 (по умолчанию)
Ансамбль	305	430	432	637
Ансамбль − лучший Prophet, двусторонний 95% ДИ	**−148 [−228; −72]**	−55 [−122; +8]	**−143 [−176; −111]**	**−412 [−551; −244]**

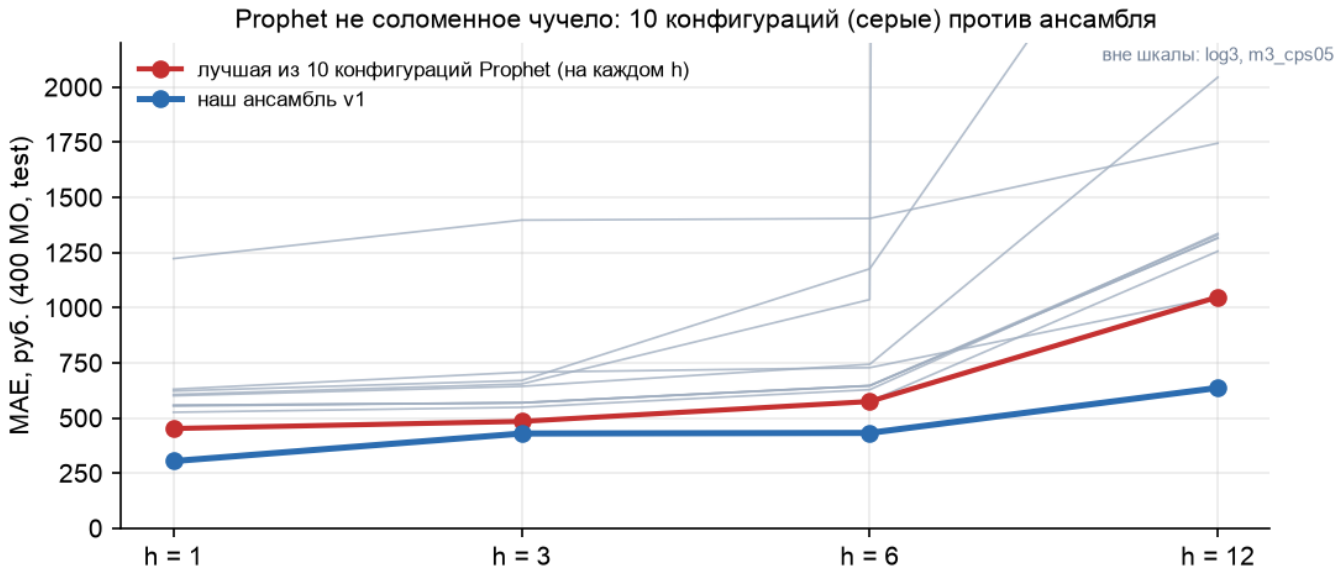


Рис. 7: 10 конфигураций Prophet против ансамбля

Наша конфигурация Prophet воспроизводит полную панель на выборке (558 против 563) и не самая сильная: порядок Фурье 5 лучше на h = 1-6 (−11..−19%), настройки по умолчанию лучше на h = 12. Ансамбль лучше даже лучшей конфигурации, выбранной задним числом: −33% / −11% / −25% / −39%; значимо на h = 1, 6, 12, на h = 3 ДИ включает 0 — та же картина, что и против основной конфигурации. Неустойчивые варианты: обучение на log y на h = 12 взрывается (экспонента тренда), плоский тренд в 2 раза хуже. Сетка: `src/models/prophet_grid.py`, `results/metrics/prophet_grid_test.csv`.

3.6. По категориям (test, MAE)

Категория	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12
Все категории	837 / 1147 / 1181 / 1695	1792 / 1772 / 2057 / 4060
Продовольствие	428 / 728 / 672 / 839	755 / 744 / 768 / 2070
Маркетплейсы	334 / 401 / 461 / **927**	526 / 547 / 593 / **825**
Транспорт	85 / 125 / 140 / 190	124 / 157 / 206 / 431
Здоровье	81 / 98 / 91 / 164	91 / 106 / 128 / 449
Общественное питание	69 / 110 / 127 / 136	90 / 120 / 161 / 332

Главная таблица (§1) — средний MAE по всем 12 096 рядам, то есть по 6 категориям вместе. Строка «Все категории» — отдельная категория с самыми крупными уровнями. Ансамбль лучше Prophet в 23 из 24 ячеек. Исключение — маркетплейсы на h = 12: рост категории ≈ +45% в год, а рост розничной торговли Росстата (≈ +15%) его занижает; трендовая экстраполяция Prophet здесь уместнее.

3.7. Абляция признаков GBM

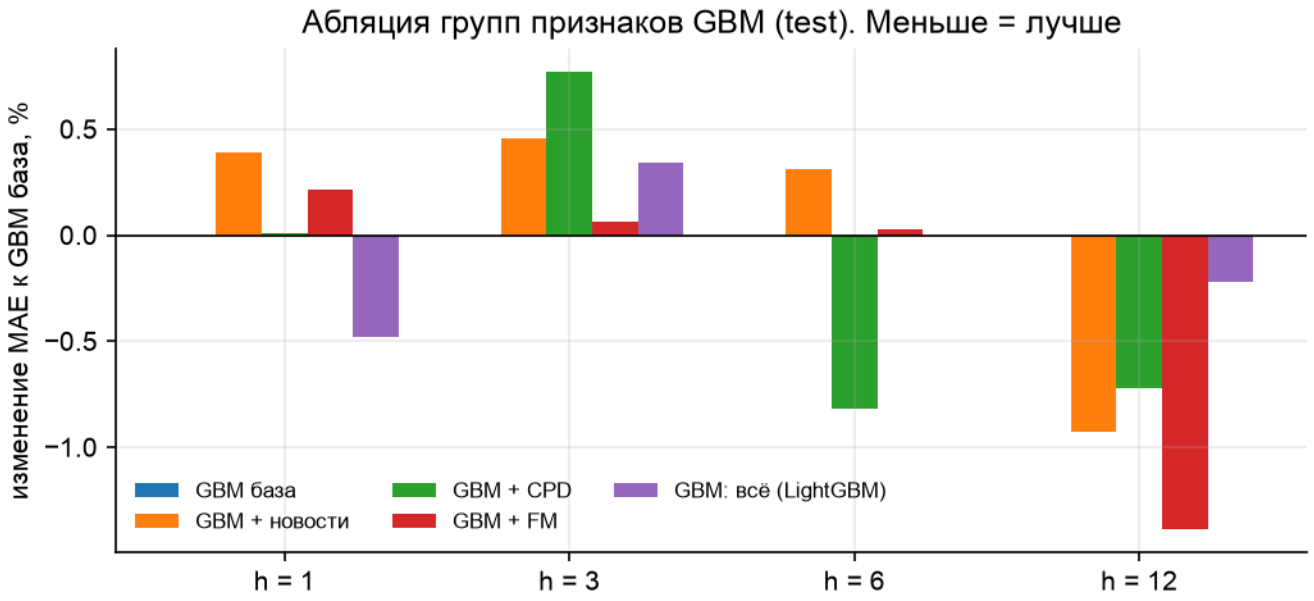


Рис. 8: Абляция групп признаков

Все варианты GBM отличаются от базового не более чем на 1.4%. Новости: +0.4% (h = 1), −0.9% (h = 12); на подвыборке MO с новостями в 3 месяцах до origin эффект тот же. Признаки сдвигов: −0.8% на h = 6. FM-признаки: −1.4% на h = 12. Главные признаки (gain): регион, d год назад относительно origin, месяц цели, категория, изменение регионального d за 3 месяца.

4. Фундаментальные модели: где помогают и где нет

Только модели с открытыми весами Apache-2.0, запуск локально (Apple M3 Pro, MPS). Moirai (CC BY-NC) и TimesFM 3.0 (некоммерческая лицензия) исключены: Положение §10.3 запрещает технологии, на которые нужны платные права. Способы применения:

1. **Zero-shot на уровнях** — «из коробки».
2. **Zero-shot на локальной компоненте** exp(d); национальная компонента добавляется обратно. Chronos-2 мультивариантный: 6 категорий одного MO как одна группа.
3. **Признаки для GBM**: медианный прогноз FM для d и ширина 80% интервала.
4. **Дообучение Chronos-2** (полное, 300 шагов, lr = 1e-5) на локальной компоненте, строго каузально: модель, дообученная на месяцах 0..c, применяется к origin c..(следующая отсечка − 1). Отсечки 2023-12, 2024-06, 2024-12.

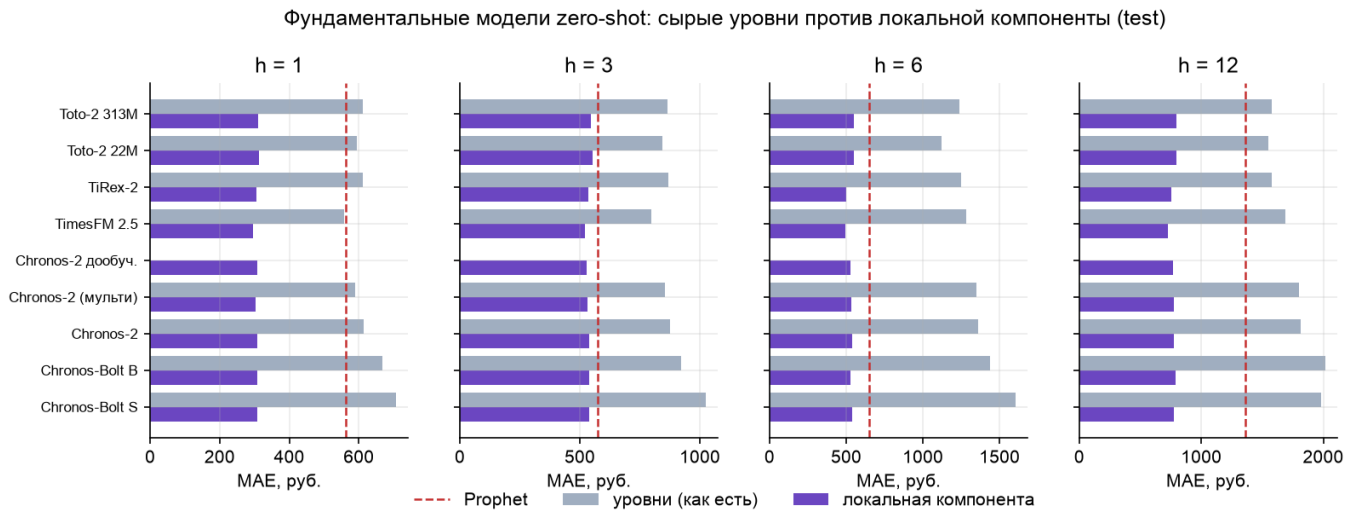


Рис. 9: FM: сырые уровни против локальной компоненты

FM (test, MAE)	уровни h = 1 / 3 / 6 / 12	лок. компонента h = 1 / 3 / 6 / 12	покрытие 80% инт., h = 1 / 12	время, с
Chronos-Bolt S	707 / 1024 / 1603 / 1986	307 / 538 / 539 / 774	0.82 / 0.88	37
Chronos-Bolt B	668 / 920 / 1439 / 2015	307 / 538 / 529 / 787	0.83 / 0.89	75
Chronos-2	613 / 877 / 1361 / 1817	307 / 539 / 540 / 776	0.83 / 0.90	102
Chronos-2 мультивар.	588 / 854 / 1351 / 1802	302 / 531 / 532 / 772	0.81 / 0.91	104
Chronos-2 дообуч.	—	308 / 528 / 527 / 771	0.88 / 0.89	982
TimesFM 2.5	559 / 797 / 1283 / 1691	**296 / 522 / 493 / 729**	0.82 / 0.73	1028
TiRex-2	612 / 870 / 1250 / 1575	305 / 535 / 502 / 757	0.80 / 0.76	3220
Toto-2.0 22M	595 / 842 / 1122 / 1548	313 / 552 / 550 / 799	0.74 / 0.88	28
Toto-2.0 313M	611 / 866 / 1240 / 1576	310 / 548 / 548 / 794	0.82 / 0.87	356

Время — полный прогон 24 origin × 12 096 рядов на Apple M3 Pro (MPS).

Где FM помогают	Где FM не помогают
На локальной компоненте: MAE в 1.5-3 раза ниже, чем на уровнях; лучше Prophet на всех h	На сырых коротких рядах: при h ⩾ 3 все 8 вариантов хуже Prophet и на уровне наивной
Средний горизонт: в ансамбле FM дают −5.9% MAE на h = 6 (446 против 473 без FM)	h = 12: FM экстраполируют локальный тренд (TimesFM 729 против persistence 691)
h = 1-3: TimesFM лучше persistence (296 против 318 на h = 1)	В ансамбле на h = 3 веса FM не перенеслись с validation (+2.4% MAE)
Chronos-2 мультивариантный: совместная динамика категорий (302 против 307)	Как признаки GBM: ±1%, GBM уже видит те же лаги
Дообучение Chronos-2: −2% на h = 3-6, покрытие на h = 1 0.88 против 0.83	Дообучение дорого (16 мин) при 24 месяцах данных; эффект скромный
Семейство Chronos: откалиброванные 80% интервалы (0.81-0.91)	TimesFM 2.5: узкие интервалы на h = 12 (покрытие 0.73)

Причина провала на уровнях: ряды из 7-23 точек с сильным декабрьским пиком. Модель не знает календарь и не может выучить сезон из одного года. Декомпозиция убирает сезон до FM, и FM получает то, что умеет прогнозировать: гладкий ряд без календарного эффекта.

5. Структурные сдвиги

5.1. Методы

Сдвиг ищем в локальной компоненте d (сезон и инфляция уже убраны). Ряд стандартизуется робастным масштабом месячных изменений в 2023 г. (MAD).

Детектор	Идея
Скачок (spike)	$\|\Delta z_t\| > k$: скачок за один месяц
CUSUM	двусторонние кумулятивные суммы отклонений от уровня 2023 г., перезапуск после тревоги
PELT, BinSeg, Window (ruptures)	переподгонка сегментации на z[0..t]; тревога, если последний разрыв свежий
BOCPD (Adams, MacKay 2007)	апостериорное распределение длины текущего режима, модель Normal-Gamma, hazard 0.05
BOCPD-подтв.	то же, но новый режим должен продержаться 2 месяца (устойчив к выбросам)
CUSUM по остаткам	CUSUM на ошибках локальной сезонной наивной модели
CUSUM / BOCPD + новости	порог CUSUM × 0.6 или hazard BOCPD × 5 в месяц новостного всплеска и следующий

Офлайн-методы (весь ряд сразу): PELT, BinSeg, BottomUp, Window, KernelCPD (rbf), MAP-сегментация BOCPD.

Честное сравнение. У каждого онлайн-детектора один порог. Его калибруем на половине рядов так, чтобы частота ложных тревог на чистых рядах была ⩽ 2% на ряд-месяц. Метрики считаем на другой половине. Без такой калибровки любой детектор можно сделать сколь угодно чувствительным.

Синтетика. В реальные ряды d («Все категории», 400 МО) вставляем в случайный месяц 2024-02..10 ступеньку 5/10/20/30%, излом тренда 2/4% в месяц или одномесячный выброс 20% (выброс — не структурный сдвиг: хороший детектор его игнорирует). Метрики: recall и precision с допуском 2 месяца, F1, средняя задержка, частота ложных тревог.

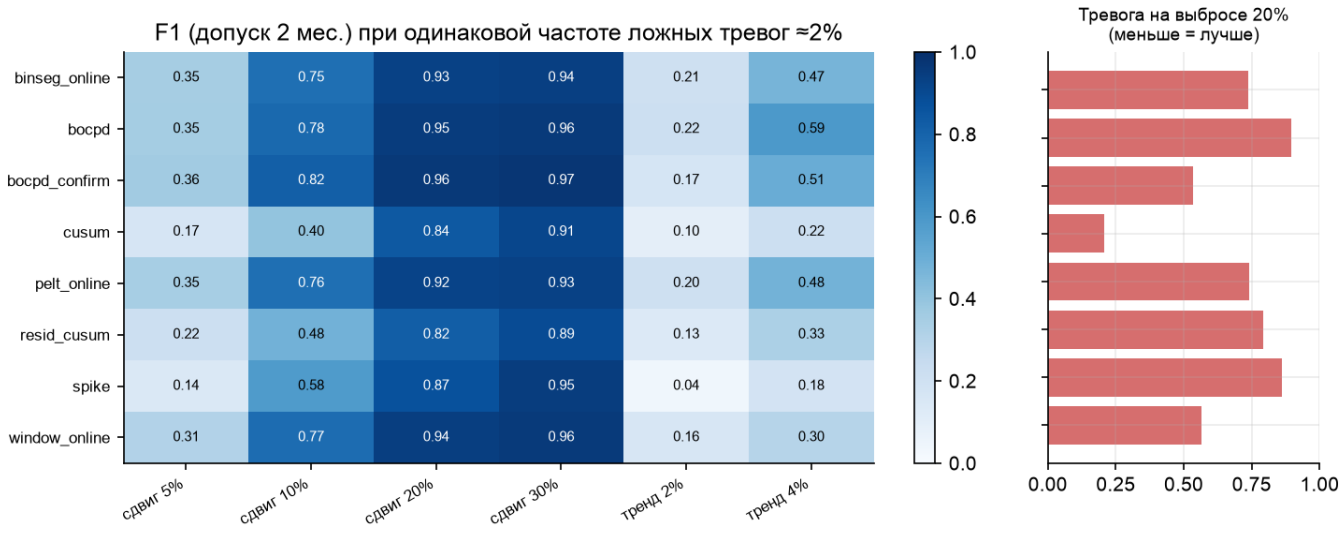


Рис. 10: F1 детекторов при равной частоте ложных тревог

5.2. Таблица решений

Все детекторы откалиброваны на одну частоту ложных тревог (≈ 1-2%), поэтому recall в таблице — это recall при фиксированной частоте ложных тревог.

Детектор	F1, сдвиг 5 / 10 / 20%	Recall при 10%	Задержка, мес.	Тревога на выбросе	Ложные тревоги	Орск: первая тревога	Lift: события GDELT	Паводки из реестра: доля МО с тревогой (lift)
BOCPD-подтв.	0.36 / 0.82 / 0.96	0.74	1.2	0.54	1.3%	нет	0.6	0% (0.0)
BOCPD	0.35 / 0.78 / 0.95	0.69	0.3	0.90	1.6%	нет	0.0	0% (0.0)
PELT	0.35 / 0.76 / 0.92	0.68	0.7	0.74	1.5%	нет	0.4	0% (0.0)
BinSeg	0.35 / 0.75 / 0.93	0.67	0.7	0.74	1.4%	нет	0.4	0% (0.0)
Window	0.31 / 0.77 / 0.94	0.70	1.6	0.56	1.2%	нет	0.9	8% (1.8)
Скачок (spike)	0.14 / 0.58 / 0.87	0.45	0.0	0.86	0.8%	нет	0.0	0% (0.0)
CUSUM по остаткам	0.22 / 0.48 / 0.82	0.36	0.3	0.79	1.3%	нет	1.2	0% (0.0)
CUSUM	0.17 / 0.40 / 0.84	0.36	1.4	0.21	1.4%	2024-06	1.5	12% (2.3)
CUSUM + новости	полусинтетика: 0.43	—	1.1	—	1.6%	2024-05	1.5	12% (2.3)
BOCPD + новости	полусинтетика: 0.73	—	0.4	—	1.6%	нет	1.2	0% (0.0)

Паводки из реестра: 26 МО с режимом ЧС в 2024 г.; доля МО с тревогой в 0..2 месяца после месяца паводка; базовая частота такого окна у CUSUM 5.1%, у BOCPD 3.1%. Приморье 2023 не входит: онлайн-детекторы запускаются с 2024-01.

Офлайн (весь ряд, допуск 1 месяц), F1 при сдвиге 10 / 20%: Window 0.71 / 0.82, PELT 0.66 / 0.76, BinSeg 0.66 / 0.77, BOCPD-MAP 0.59 / 0.69, BottomUp 0.58 / 0.68, KernelCPD 0.57 / 0.72.

Выбор для мониторинга: BOCPD с подтверждением. Правило: максимум F1 при сдвиге 10% при равной частоте ложных тревог, при условии, что детектор реагирует на одномесячный выброс реже, чем в 60% случаев. BOCPD-подтв. даёт лучший F1 (0.82 при 10%, 0.96 при 20%), лучший recall (0.74), ложные тревоги 1.3%, выбросы 54% (у BOCPD 90%). Цена — задержка ≈ 1.2 месяца. **Быстрый сигнал** без подтверждения — BOCPD (задержка 0.3 месяца). **Проверка гипотез по реестру ЧС и новостям** — CUSUM с prior: на реальных событиях он единственный стабильно выше базовой частоты. Сдвиг 5% (≈ месячный шум ряда) не обнаруживает надёжно ни один метод (F1 ⩽ 0.36): это предел данных.

Почему победитель синтетики слабее на реальных событиях. На событиях GDELT и на паводках из реестра BOCPD и BOCPD-подтв. почти не поднимают тревог (lift 0-0.6), CUSUM — 1.5 и 2.3 (на паводках 3 из 26 МО, поэтому оценка грубая). Причины: (1) большинство событий не сдвигает расходы на жителя заметно: event study (§6.5) не находит среднего эффекта; (2) реальные сдвиги около +7% (Орск) лежат у предела обнаружения, где BOCPD без накопления не срабатывает, а CUSUM накапливает отклонение; (3) синтетика содержит чистые ступеньки, а реальный шок в Орске — временный всплеск на 3 месяца. Поэтому синтетика выбирает детектор для мониторинга, а реальные события — детектор для проверки гипотез.

5.3. Реальные данные

Тревоги по месяцам 2024 г. (2016 МО, «Все категории»): BOCPD 13-53 в месяц, PELT 26-66; у CUSUM число тревог растёт к концу года (с 0 до 91): он накапливает медленный локальный дрейф. Всплеск CUSUM по остаткам в 2024-04 (100 тревог) — артефакт: его эталон «год назад» — апрель 2023, где у многих МО разрыв в исходных данных (в офлайн-PELT 341 разрыв из 986 приходится на 2023-04).

Паводок в Орске (прорыв дамбы 5 апреля 2024). Локальная компонента Орска выросла с +16% к национальному уровню (апрель) до +24% (май), затем вернулась к +16-17% к августу. В GDELT за апрель 2024 об Орске 1 367 документов, 1 336 с темой «наводнение» (обычно 0-10 в месяц). Сдвиг +7% обычные детекторы не видят; CUSUM поднимает тревогу в июне, **CUSUM с новостным prior — в мае**, на месяц раньше.



Рис. 11: Орск: данные, тревоги, новости

5.4. Как учёт сдвигов улучшает прогноз

Модели с «памятью» о прошлом годе (сезонная наивная, Prophet, признак «d год назад» в GBM) после сдвига опираются на старый уровень. Поправка: после тревоги точка сдвига уточняется (разбиение с минимальной суммой квадратов в окне [тревога − 3; тревога]), история до сдвига переносится на новый уровень, и только потом считается прогноз.

Синтетика, сдвиг 15%, MAE (руб.)	h = 1	h = 2	h = 3	h = 6
Локальная сезонная модель (YoY за 3 мес.)	947	1022	1164	1567
То же с поправкой на сдвиг	**819**	**920**	**1032**	**1397**
Изменение	−14%	−10%	−11%	−11%

На реальных данных (test) поправка затрагивает 15% рядов на h = 1 и даёт на них −0.3% MAE на h = 1 и −1.3% на h = 3. Эта модель получила наибольший вес в ансамбле на h = 1 (0.35).

6. Интеграция новостей и событий

6.1. GDELT

1. **Сбор.** Ежедневные файлы GDELT GKG 1.0 за 2022-12..2024-12 (761 день, ≈ 33 ГБ; 2023-03-23 на сервере отсутствует). Документы с городом или регионом РФ: **1,55 млн**.
2. **Привязка к МО.** GDELT геокодирует шумно (украинские топонимы попадают в российские регионы, фамилии распознаются как сёла). Точку GDELT привязываем к МО, только если (а) центр МО в 30 км и (б) транслитерация названия начинается с тех же 5 букв. Так 942 места привязаны к 811 МО; в панели новости есть у 575 МО. Остальные места — на уровне региона (ADM1, 81 регион). Таблица привязки для аудита: `data/external/news_location_match.csv`.

3. **Темы.** Группы тем GKG: бедствие, наводнение, пожар, экономика-негатив, цены, инфраструктура, безопасность. Тему MANMADE_DISASTER_IMPLIED исключаем: GDELT ставит её на большинство военных текстов.
4. **Признаки** на месяц t: log(1 + число документов), «сюрприз» (отклонение от среднего за 6 месяцев), число документов по темам, тональность; то же для региона.

6.2. Реестр событий из официальных источников

GDELT — англоязычные СМИ, малые МО почти не упоминаются. Поэтому мы вручную собрали реестр событий из русскоязычных официальных источников: режимы ЧС паводка весны 2024 (сайты МЧС, правительств регионов), решения Банка России по ключевой ставке, индексация тарифов ЖКХ, конец массовой льготной ипотеки. В каждой строке: дата объявления, дата вступления в силу, МО или регион, ожидаемый знак эффекта, ссылка на источник, признак «проверено» (страница открыта и подтверждает дату). Файл: `data/external/event_registry.csv`. Тексты страниц использовались только как данные: даты, названия МО, номера актов.

Реестр: **71 строк, все проверены** по странице источника: 48 строк о паводках (6 регионов, 42 МО панели, названных в постановлениях о ЧС), 17 решений Банка России по ключевой ставке, индексация тарифов ЖКХ с 2024-07-01, конец массовой льготной ипотеки 2024-07-01, 4 строки о лесных пожарах. Источники: publication.pravo.gov.ru (38 строк: указы и постановления губернаторов о ЧС), cbr.ru (17), mchs.gov.ru, РИА Новости и Интерфакс (даты фактических событий: прорыв дамбы, пик воды). Две даты мы перепроверили вручную повторно (прорыв дамбы в Орске 2024-04-05; уровень Тобола в Кургане 850 см 2024-04-17). Использование: (а) разметка МО для event study; (б) проверка детекторов на реальных событиях (§5.2).

6.3. Правило согласования новостей с данными

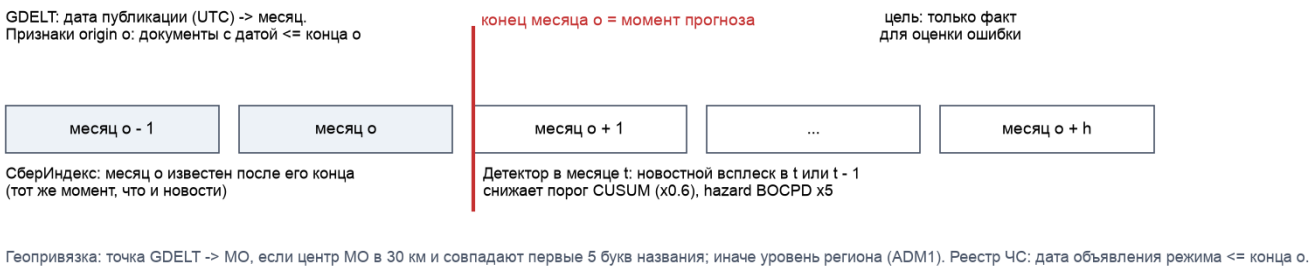


Рис. 12: Согласование по времени: что известно в момент прогноза

Что	Правило
Дата документа	GDELT `DATE` = дата публикации (UTC). Документ относится к календарному месяцу публикации
Признаки для origin o	документы с датой ⩽ конца месяца o. Месяц o СберИндекса тоже известен только после его конца, поэтому новости и расходы имеют одинаковый момент «as-of»
Prior детектора в месяце t	всплеск новостей в месяце t или $t-1$ (оба известны в конце t)
Реестр ЧС	событие используется с месяца даты **объявления**; дата вступления — для event study
Место	точка GDELT -> МО (30 км + 5 букв названия), иначе регион; реестр — МО из официального акта
Будущее	ни один признак не использует документы после конца месяца o

Событие и публикация — не одно и то же. Новость о паводке выходит в день события или позже; акт о ЧС — в день объявления режима. Для прогноза важна дата, когда информация стала доступна, поэтому в признаках используется дата публикации, а не дата события.

6.4. Что дают новости: результаты, включая нулевые

Использование	Результат
Признаки GBM	эффект на MAE ±1% (§3.7): новости редки (575 из 2016 МО) и англоязычны
Prior для CUSUM, Орск	тревога в мае 2024 вместо июня, на месяц раньше
Prior, полусинтетика (сдвиг 10%)	CUSUM + новости F1 0.43 против 0.38, задержка 1.1 против 1.5 мес.; BOCPD + новости 0.73 против 0.78 (хуже: рост hazard добавляет ложные тревоги)
Разметка событий GDELT (53 МО-месяца)	lift CUSUM 1.5, CUSUM + новости 1.5, BOCPD 0
Event study по реестру ЧС	§6.5

Вывод: новостной prior полезен медленному детектору (CUSUM) и не нужен быстрому (BOCPD). В прогнозе уровня новости почти ничего не дают; их ценность — в поиске и объяснении шоков.

6.5. Event study: паводок 2024

Вопрос: меняются ли расходы на жителя в МО, которые официальный акт о ЧС назвал зоной паводка, по сравнению с другими МО того же региона? Дизайн:

- **Опыт:** 42 МО из постановлений о ЧС: Приморье (тайфун «Ханун», 2023-08, 16 МО), Оренбургская (2024-04, 4), Курганская (2024-04, 6), Тюменская (2024-04, 13), Омская (2024-05, 3) области.
- **Контроль:** остальные 111 МО тех же регионов. Тот же национальный шок, та же региональная политика.
- **Исход:** локальная компонента d (национальная сезонность и инфляция уже убраны), 6 категорий.
- **Эффект:** разность разностей к среднему за 3 месяца до события, с отдельным месяцем события для каждого региона (stacked DiD). Основная величина — средний эффект за месяцы 0..2.
- **Вывод о значимости:** перестановочный тест (метка «опыт» случайно переставляется внутри региона, 1000 раз), поправка Холма на 6 категорий. 95% ДИ — бутстреп МО внутри регионов.
- **Плацебо по датам:** тот же дизайн с месяцем события, сдвинутым на 4 и более месяцев (23 ложные даты).

Категория	Эффект 0..2 мес.	95% ДИ	p (перестановки)	p (Холм)	Доля ложных дат с эффектом не меньше
Все категории	+0.7%	[−0.5%; +1.7%]	0.25	1.00	0.52
Продовольствие	+0.1%	[−0.9%; +1.2%]	0.78	1.00	0.87
Маркетплейсы	+0.7%	[−2.6%; +4.2%]	0.69	1.00	0.83
Транспорт	−1.9%	[−4.3%; +0.5%]	0.13	0.63	0.39
Здоровье	+0.2%	[−2.7%; +2.9%]	0.90	1.00	0.87
Общественное питание	+7.1%	[−0.8%; +15.3%]	0.09	0.55	0.17

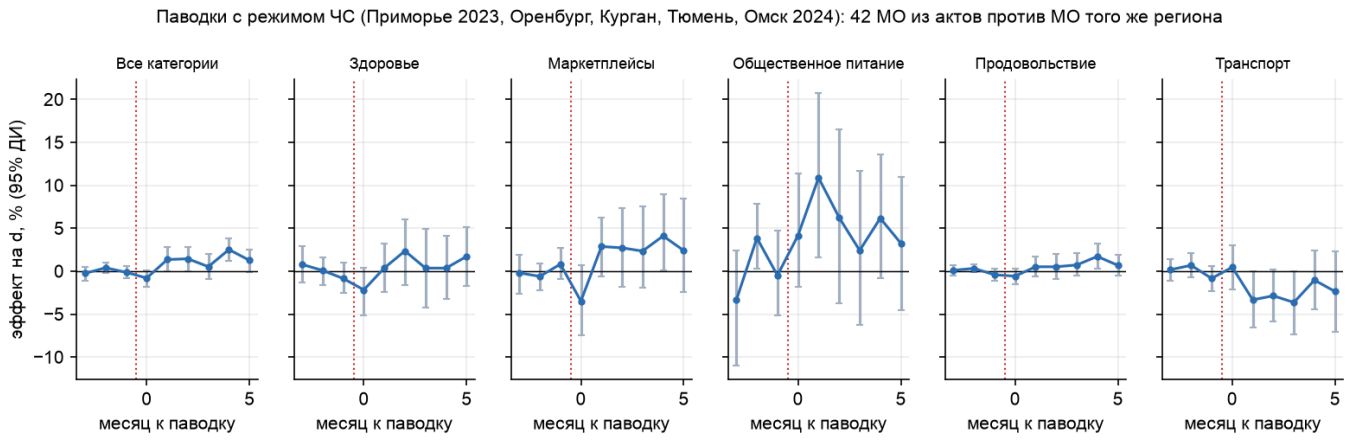


Рис. 13: Event study паводков: эффект по месяцам и категориям

Результат — нулевой, и мы его публикуем. Ни в одной категории средний эффект не значим после поправки Холма. Для «Всех категорий» эффект +0.7% [−0.5%; +1.7%], p = 0.25; ложные даты дают эффект такого же размера в половине случаев. Наибольшая точечная оценка — общепит (+7.1%, p = 0.09, после поправки 0.55). Расходы в Орске выросли на 7% (§5.3), но среднее по 42 МО из актов о ЧС эффекта не показывает: акт называет МО, где пострадала часть территории, а расходы на жителя считаются по всему МО. Практический вывод: факт режима ЧС сам по себе не предсказывает сдвиг расходов; нужен масштаб ущерба (число пострадавших домов на жителя). Это ограничение и направление развития реестра.

7. Метрики

Метрика	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12	Что показывает
MAE, руб.	306 / 435 / 446 / 658	563 / 574 / 652 / 1361	средняя ошибка в рублях (обязательная)
R^2 (уровни)	0.998 / 0.996 / 0.995 / 0.991	0.991 / 0.992 / 0.990 / 0.954	почти всегда ≈ 1: уровни МО сильно различаются
R^2 на изменении log(y_T/y_o)	0.42 / 0.59 / 0.53 / −0.17	−2.6 / −0.86 / −8.4 / −167	объясняет ли модель динамику
WAPE	3.3% / 4.7% / 4.9% / 7.2%	6.1% / 6.3% / 7.1% / 14.8%	ошибка в % от суммы факта
MdAPE	3.7% / 5.3% / 5.4% / 8.1%	5.6% / 6.3% / 7.5% / 16.7%	типичная ошибка ряда в %
Смещение	+0.7% / +1.2% / −0.4% / +0.3%	−0.6% / −0.5% / −1.6% / +6.8%	систематический сдвиг прогноза
Покрытие 80% интервала	0.81 / 0.74 / 0.67 / 0.76	0.87 / 0.90 / 0.87 / 0.93	честность интервала (цель 0.80)
WIS (80% интервал + медиана), руб.	211 / 302 / 333 / 516	485 / 448 / 503 / 1205	точность интервала и медианы вместе

Интерпретация. R^2 на уровнях не различает модели. R^2 на изменении показывает, что ансамбль объясняет 42-59% вариации изменения расходов за 1-6 месяцев. На h = 12 он отрицательный: годовой рост в основном общий для всех МО, а ошибка оценки общего роста (≈ 1 п.п.) больше, чем различия между МО. Prophet на изменении хуже константы на всех горизонтах.

Интервалы. 80% интервал строится по квантилям 10% и 90% логарифмических ошибок на **validation** (по горизонту и категории) и проверяется на test. У ансамбля покрытие ниже номинала на h = 3-12 (0.67-0.76): ошибки на test больше, чем на validation. У Prophet покрытие выше номинала, потому что его ошибки на validation велики и интервалы широкие. WIS учитывает обе стороны; у ансамбля он в 1.5-2.3 раза ниже.

Значимость. ΔMAE = MAE(модель) − MAE(Prophet) на одних и тех же рядах и месяцах. 95% ДИ — **двусторонний бутстреп**: независимо пересэмплируются МО (6 категорий МО вместе) и целевые месяцы test, 1000 повторов. Бутстреп только по МО даёт слишком узкие ДИ: ошибки всех МО в одном месяце связаны через общую национальную компоненту. Дополнительно — тест Диболда-Мариано с поправкой HLN по 6 месячным разностям (при 6 месяцах мощность низкая; для h ⩾ 6 не определён).

Ансамбль против Prophet	h = 1	h = 3	h = 6	h = 12
ΔMAE, руб.	−258	−140	−207	−702
95% ДИ, двусторонний бутстреп	[−511; −37]	[−302; +16]	[−353; −66]	[−1110; −430]
95% ДИ, только по МО (для сравнения)	[−263; −253]	[−145; −134]	[−215; −199]	[−722; −682]
DM-HLN, p	0.11	0.44	—	0.003
Месяцев test, где ансамбль лучше	5 из 6	5 из 6	5 из 6	6 из 6

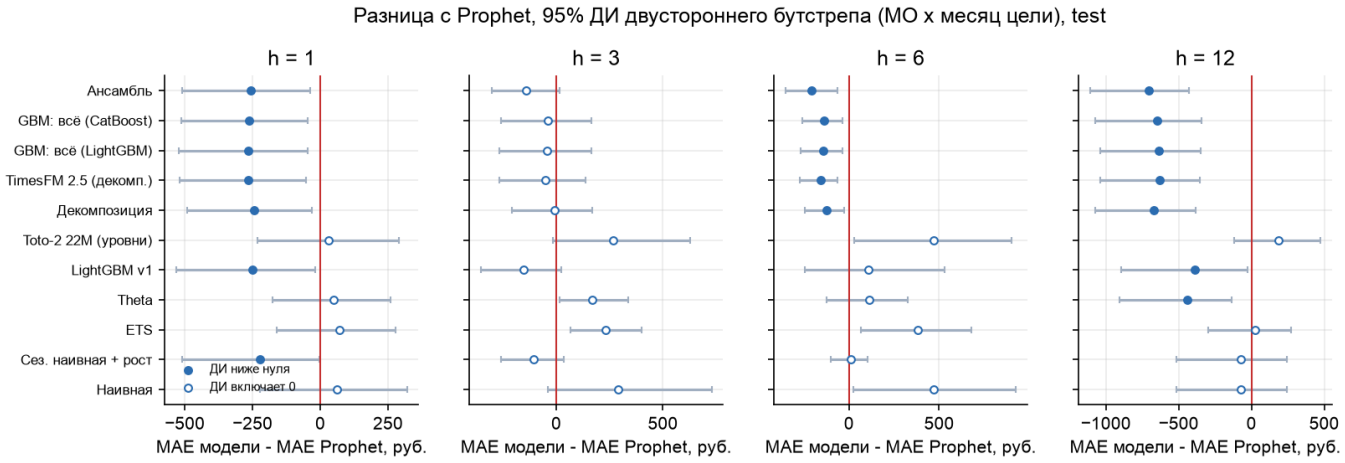


Рис. 14: Разница с Prophet, двусторонний 95% ДИ

8. Выводы, практическая ценность, проверка на 2025

8.1. Прогноз на 2025 год

Финальный прогноз (origin 2024-12, h = 1..12) делает тот же ансамбль; веса выбраны заново на validation + test. 80% интервал — квантили 10% и 90% логарифмических ошибок ансамбля на test по горизонту и категории. Файл `results/forecast_2025.csv` (145 152 строки).

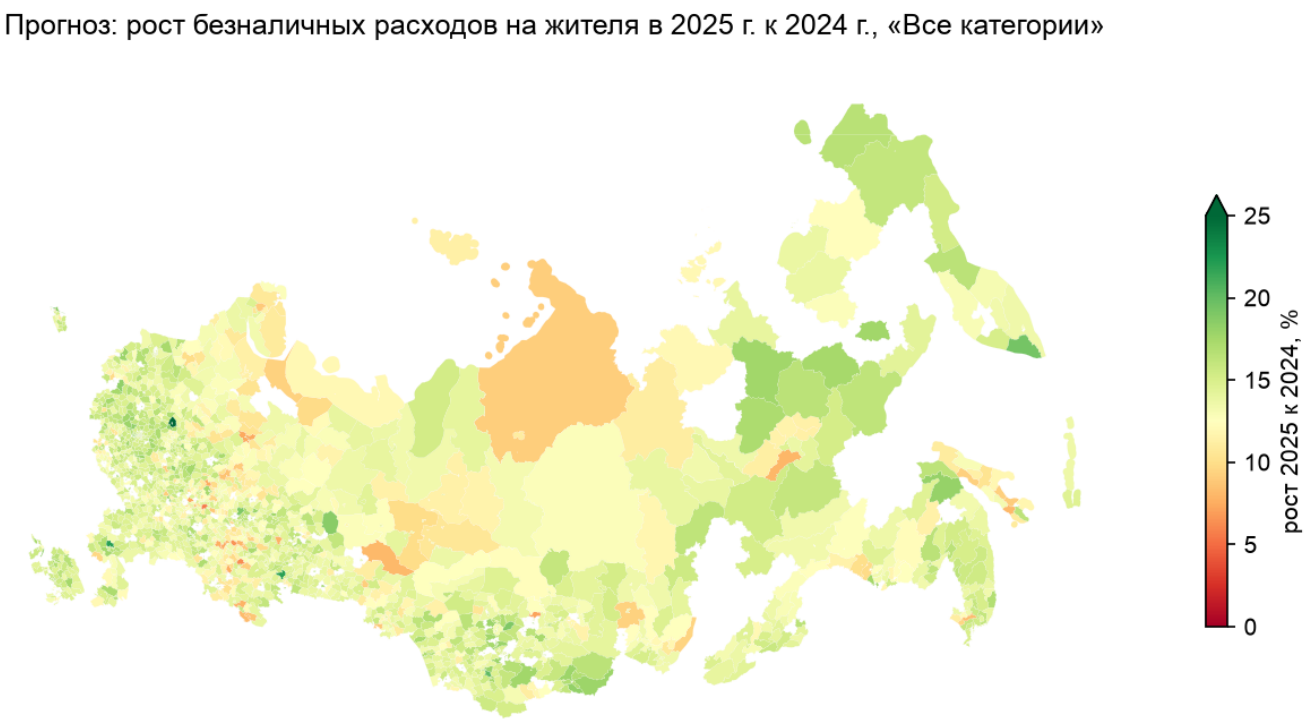


Рис. 15: Прогноз роста 2025 к 2024

Медианный прогноз декабря 2025 к декабрю 2024: все категории +10.5%, маркетплейсы +24.6%, общественное питание +13.6%, транспорт +9.9%, здоровье +7.1%, продовольствие +6.2%.

8.2. Проверка прогноза 2025 на факте

Прогноз 2025 сделан в конце 2024 г. Сейчас (октябрь 2026) на портале СберИндекса есть национальные расходы за 2025 год. Это единственная проверка на данных, которых не видел ни один этап разработки. Панель — медиана по МО на жителя, портал — сумма по РФ. Поэтому сравниваем годовой прирост log(2025-m / 2024-m), а не уровни.

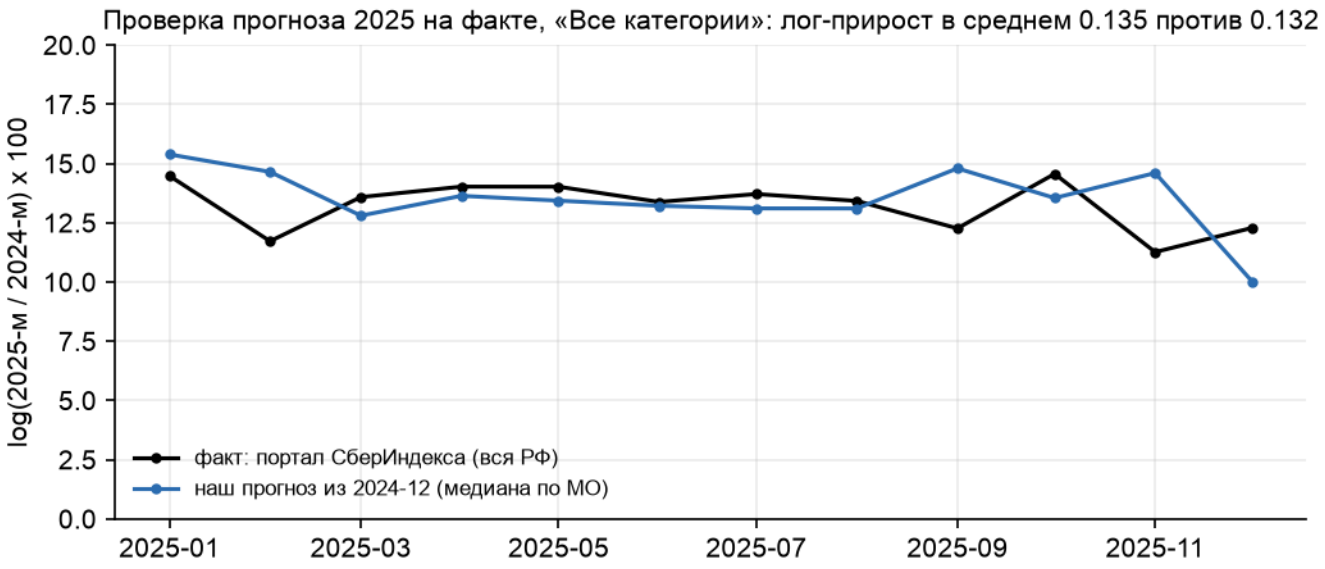


Рис. 16: Проверка прогноза 2025 на портале СберИндекса

«Все категории»	Прогноз / панель	Факт портала	Разница
Годовой log-прирост 2025, среднее за 12 месяцев	0.135 (+14.5%)	0.132 (+14.1%)	+0.3 п.п.
Тот же прирост за 2024: факт панели против портала	0.139	0.149	−1.0 п.п.

Для «Всех категорий» прогноз роста 2025 совпал с фактом с точностью 0.3 п.п.; источники в 2024 г. расходятся на 1.0 п.п., то есть сравнение корректно. По отдельным категориям сравнение грубое: типы портала не совпадают с категориями панели (у маркетплейсов разница источников за 2024 г. 28.7 п.п.; у общепита на портале в 2025 г. скачок +40%).

8.3. Практические выводы

- **Для прогноза по МО на короткой истории главное — отделить общую динамику.** Декомпозиция с persistence уже снижает MAE к Prophet на 44% / 1% / 19% / 49%.
- **Годовой горизонт требует внешнего источника роста.** Без него h = 12 не прогнозируется. Проверка 2025 показывает, что внешний рост (Росстат) переносится на следующий год.
- **Фундаментальные модели стоит применять к очищенному от сезонности сигналу**, а не к «сырым» коротким рядам; лучший выигрыш — на среднем горизонте (h = 6).
- **Мониторинг шоков.** BOCPD с подтверждением даёт устойчивые сигналы с задержкой ~1 месяц; CUSUM с prior из новостей ловит слабый сдвиг в Орске на месяц раньше.
- **Локальный шок не обязательно долгий.** В Орске всплеск расходов после паводка продлился ~3 месяца; прогноз после сдвига должен переоценивать уровень, а не продлевать скачок.

9. Ограничения

- 24 месяца: окно validation для h = 12 короче по истории, чем test (§2).
- Один взгляд на test в дизайне заголовка: правило «отдельные (k, w) для h ⩽ 3» (§2, `LOG.md`). Пост-hoc эксперименты (приложение A) смотрели на test ещё 5 раз и в заголовок не входят.
- На h = 3 выигрыш у Prophet не значим (§7). Все ДИ построены по 6 месяцам test: это мало.
- Нет настоящей разметки шоков; проверка — по реестру ЧС, новостям и примерам.
- GDELT GKG 1.0 — только англоязычные источники; реестр ЧС собран вручную и неполон.
- Фундаментальные модели обучались на открытых корпусах; мы не можем исключить, что в них есть ряды за 2024 г. (не данные СберИндекса).
- Проверка 2025 — одна национальная цифра для «Всех категорий»; факт 2025 по МО недоступен.

10. Воспроизводимость

```
make setup          # uv + Python 3.13, точные версии из requirements.lock.txt
make data           # данные СберИндекса, справочник МО, Росстат, портал (≈ 50 МБ)
make quick          # свежий клон: тесты на утечку + пересчёт всех главных чисел (≈ 2 мин)
make reproduce      # полный прогон, 4–5 ч
```

- `make quick` на свежем клоне запускает `make smoke` (тесты на утечку и проверка формы, секунды) и `make verify`: пересчёт MAE, R^2, R^2 на изменении, MAE по категориям, ДИ двустороннего бутстрепа, DM-HLN и прогноза 2025 из `results/verify/cubes.npz` (8 МБ: прогнозы 8 ключевых моделей на test) со сверкой с таблицами `results/metrics/`. Если есть полный кэш `results/cache/`, `make quick` пересобирает ансамбль, таблицы, рисунки и отчёт.
- Все параметры — в `configs/config.yaml` (окна, сетки, гиперпараметры, пул ансамбля, список FM, темы новостей). Каждый шаг — отдельный скрипт в `src/` с инструкцией в начале файла.
- Полный прогон на Apple M3 Pro: Prophet ≈ 50 мин, statsforecast ≈ 45 мин, FM ≈ 1.5 ч, GBM ≈ 1.5 ч, загрузка GDELT ≈ 1-2 ч. Журнал экспериментов со всеми итерациями — `LOG.md`.
- Данные организатора в репозиторий не входят (Положение §9.2.2).

При разработке кода использовались инструменты ИИ-ассистирования (Claude Code). Все решения, результаты и текст проверены автором; автор отвечает за проект.

Приложение А. Пост-hoc эксперименты (не используются для выбора)

Всё в этом разделе сделано **после** фиксации решения, с просмотром test (4 раза для ансамбля v2, 1 раз для варианта nat3). Числа на test здесь — не независимая оценка. Заголовок (§1) остаётся v1.

Диагностика. Если заменить прогноз национальной компоненты на факт (оракул), test MAE декомпозиции падает с 318 / 566 / 526 / 691 до 252 / 366 / 419 / 394. Главный источник ошибки — национальная компонента (6 рядов), а не локальная модель. Эта диагностика смотрела на test.

Национальная компонента v3 (выбрана на validation). Ряд портала СберИндекса (национальные расходы, в origin o только месяцы $\leqslant$ o) вместо Росстата; для o $\geqslant$ 12 — среднее с Росстатом по категориям. Validation MAE декомпозиции с persistence: 428 / 682 / 587 / 1058 -> 348 / 429 / 525 / 735. Ограничение: портал скачан в винтаже 2026-10, поздние пересмотры данных 2023-2024 могли попасть в прошлое.

Test MAE	h = 1	h = 3	h = 6	h = 12
v1, заголовок	306	435	446	658
nat3: тот же отбор Caruana, пул v1 + декомпозиция на национальной v3	291	451	487	542
nat3 − v1, двусторонний 95% ДИ	−15 [−40; +10]	+16 [−2; +32]	+41 [−10; +99]	**−117 [−176; −63]**
v2: стекинг (`src/stack.py`), выбор пула и схемы после test	268	393	568	586
v2 − v1, двусторонний 95% ДИ	−37 [−79; +1]	−42 [−80; 0]	**+122 [+25; +218]**	−72 [−189; +35]

- **nat3** (вариант предрегистрирован в `LOG.md` до просмотра test): значимо лучше v1 только на h = 12 (−18%, DM-HLN p = 0.02); на h = 1-6 разница не значима. Проверка 2025 для «Всех категорий»: 0.137 против факта 0.132 (v1: 0.135).
- **v2** не лучше v1 значимо ни на одном горизонте и значимо хуже на h = 6 (продовольствие и маркетплейсы в 2024-H2 замедлились, а ряд портала нет). Проверка 2025: 0.130 против 0.132.
- Вывод: портал как источник национального роста полезен на годовом горизонте. Это направление для следующей версии, а не замена заголовка, выбранного по честному протоколу.

Приложение Б. Все модели: validation, test, ранги, R^2, значимость

Ранг — место среди 35 кандидатов и ансамбля на test (1 = лучший). ΔMAE к Prophet — двусторонний 95% ДИ. MAE ансамбля на validation посчитано на окне подбора весов.

Модель	MAE validation h = 1 / 3 / 6 / 12	MAE test h = 1 / 3 / 6 / 12	Ранг на test	R^2 на изменении, test
Наивная	726 / 668 / 868 / 1244	624 / 864 / 1124 / 1289	32 / 31 / 29 / 22	−0.04 / −0.07 / −0.37 / −0.90
Сез. наивная + рост	438 / 827 / 1244 / 1244	340 / 469 / 663 / 1289	21 / 4 / 21 / 22	0.06 / 0.36 / −0.11 / −0.90
Сез. наивная + нац. рост	578 / 876 / 1244 / 1244	439 / 491 / 617 / 1289	23 / 5 / 19 / 22	−0.59 / 0.35 / 0.35 / −0.90
Сез. наивная + рост, учёт сдвигов	438 / 827 / 1244 / 1244	340 / 469 / 663 / 1289	20 / 3 / 22 / 22	0.06 / 0.36 / −0.11 / −0.90
Prophet (базовая)	893 / 961 / 1241 / 2219	563 / 574 / 652 / 1361	25 / 23 / 20 / 26	−2.62 / −0.86 / −8.41 / −167.21
ETS	675 / 673 / 876 / 1244	634 / 807 / 1036 / 1383	33 / 27 / 26 / 27	−0.11 / 0.01 / −1.49 / −2.19
Theta	583 / 569 / 1008 / 1125	614 / 744 / 767 / 922	31 / 25 / 25 / 20	−0.08 / −0.76 / −1.48 / −29.38
ARIMA	723 / 820 / 1088 / 1325	645 / 862 / 1094 / 1529	34 / 30 / 27 / 28	−0.11 / −0.18 / −0.55 / −10.03
LightGBM v1	705 / 676 / 855 / 1193	313 / 420 / 761 / 969	17 / 1 / 24 / 21	0.39 / 0.49 / 0.22 / −0.17
TimesFM 2.5 (уровни)	714 / 765 / 944 / 1363	559 / 797 / 1283 / 1691	24 / 26 / 32 / 32	0.08 / 0.11 / −0.52 / −2.38
Chronos-2 (уровни)	706 / 772 / 997 / 1389	613 / 877 / 1361 / 1817	30 / 34 / 34 / 34	−0.04 / −0.09 / −0.92 / −2.25
Декомпозиция	428 / 682 / 587 / 1058	318 / 566 / 526 / 691	18 / 22 / 11 / 2	0.35 / 0.36 / 0.45 / −0.12
Декомп. (ср. 3 мес.)	421 / 681 / 565 / 1084	335 / 553 / 501 / 707	19 / 21 / 3 / 4	0.29 / 0.39 / 0.49 / −0.12
Декомп. (лок. сезон)	470 / 776 / 587 / 1058	345 / 605 / 702 / 691	22 / 24 / 23 / 2	0.05 / 0.24 / 0.06 / −0.12
TimesFM 2.5 (декомп.)	400 / 638 / 540 / 1098	296 / 522 / 493 / 729	1 / 6 / 2 / 11	0.43 / 0.46 / 0.52 / −0.34
Chronos-2 (мульти) (декомп.)	409 / 658 / 559 / 1106	302 / 531 / 532 / 772	8 / 10 / 14 / 14	0.43 / 0.43 / 0.48 / −0.25
Chronos-2 дообуч. (декомп.)	409 / 659 / 557 / 1111	308 / 528 / 527 / 771	14 / 7 / 12 / 13	0.41 / 0.45 / 0.50 / −0.27
GBM база	439 / 697 / 624 / 993	298 / 530 / 509 / 725	3 / 8 / 7 / 10	0.42 / 0.45 / 0.52 / −0.12
GBM + новости	442 / 691 / 618 / 994	299 / 532 / 511 / 719	6 / 12 / 9 / 7	0.42 / 0.44 / 0.52 / −0.12
GBM: всё (LightGBM)	443 / 695 / 622 / 999	296 / 532 / 509 / 724	2 / 11 / 6 / 9	0.42 / 0.44 / 0.52 / −0.12
GBM: всё (CatBoost)	434 / 686 / 616 / 1011	302 / 536 / 513 / 712	7 / 15 / 10 / 5	0.42 / 0.46 / 0.53 / −0.09
Ансамбль	301 / 369 / 484 / 800	306 / 435 / 446 / 658	10 / 2 / 1 / 1	0.42 / 0.59 / 0.53 / −0.17

ΔMAE к Prophet, руб., и двусторонний 95% ДИ. Жирным — ДИ целиком ниже нуля (значимо лучше Prophet).

Модель	h = 1	h = 3	h = 6	h = 12
Наивная	+61 [−222; +320]	+289 [−40; +728]	+472 [+26; +927]	−72 [−517; +241]
Сез. наивная + рост	**−223 [−510; −2]**	−105 [−261; +33]	+11 [−100; +104]	−72 [−517; +241]
Сез. наивная + нац. рост	−124 [−405; +91]	−83 [−228; +50]	−35 [−162; +96]	−72 [−517; +241]
Сез. наивная + рост, учёт сдвигов	**−223 [−509; −3]**	−106 [−261; +33]	+11 [−99; +104]	−72 [−517; +241]
ETS	+71 [−161; +278]	+233 [+68; +402]	+383 [+65; +681]	+22 [−298; +271]
Theta	+51 [−176; +259]	+170 [+16; +336]	+115 [−123; +326]	**−439 [−906; −138]**
ARIMA	+81 [−167; +297]	+287 [+73; +538]	+442 [+67; +817]	+168 [−112; +459]
LightGBM v1	**−251 [−532; −18]**	−154 [−354; +22]	+109 [−247; +528]	**−392 [−897; −26]**
TimesFM 2.5 (уровни)	−5 [−252; +184]	+223 [−116; +567]	+630 [+231; +999]	+330 [+165; +498]
Chronos-2 (уровни)	+50 [−235; +307]	+303 [−65; +711]	+708 [+286; +1140]	+456 [+294; +636]

Модель	h = 1	h = 3	h = 6	h = 12
Декомпозиция	**−245 [−491; −32]**	−9 [−207; +168]	**−126 [−246; −25]**	**−670 [−1074; −385]**
Декомп. (ср. 3 мес.)	**−229 [−486; −11]**	−21 [−224; +160]	**−151 [−270; −54]**	**−654 [−1046; −381]**
Декомп. (лок. сезон)	**−218 [−476; −3]**	+30 [−197; +244]	+49 [−81; +171]	**−670 [−1074; −385]**
TimesFM 2.5 (декомп.)	**−267 [−521; −52]**	−52 [−266; +139]	**−159 [−271; −66]**	**−632 [−1040; −354]**
Chronos-2 (мульти) (декомп.)	**−261 [−510; −44]**	−44 [−251; +142]	**−121 [−245; −9]**	**−589 [−1013; −316]**
Chronos-2 дообуч. (декомп.)	**−255 [−519; −35]**	−46 [−259; +144]	**−126 [−255; −8]**	**−590 [−1025; −309]**
GBM база	**−265 [−520; −46]**	−44 [−264; +157]	**−143 [−266; −35]**	**−636 [−1050; −341]**
GBM + новости	**−264 [−519; −44]**	−42 [−266; +165]	**−141 [−262; −36]**	**−642 [−1054; −345]**
GBM: всё (LightGBM)	**−267 [−523; −48]**	−43 [−266; +165]	**−143 [−266; −37]**	**−637 [−1038; −347]**
GBM: всё (CatBoost)	**−262 [−514; −46]**	−38 [−257; +163]	**−140 [−259; −36]**	**−649 [−1076; −342]**
Ансамбль	**−258 [−511; −37]**	−140 [−302; +16]	**−207 [−353; −66]**	**−702 [−1110; −430]**

Все 35 кандидатов и все метрики: `results/metrics/model_table_test.csv`, `metrics_test.csv`, `bootstrap_test_vs_prophet.csv`.

Источники

- СберИндекс, данные конкурса: https://sber.ru/sberindex/konkurs_sberindex (CC BY-SA 4.0).
- Портал СберИндекса, consumer-spending: https://sberindex.ru.
- Росстат, оборот розничной торговли: https://rosstat.gov.ru/statistics/roznichnayatorgovlya.
- The GDELT Project, GKG 1.0: https://www.gdeltproject.org.
- МЧС России, правительства регионов, Банк России: ссылка на каждый акт — в `data/external/event_registry.csv`
- Ansari et al. Chronos (2024); Chronos-2 (2025), amazon/chronos-2, Apache-2.0.
- Das et al. TimesFM (2024); google/timesfm-2.5-200m-pytorch, Apache-2.0.
- NX-AI TiRex-2 (2026), Apache-2.0. Datadog Toto 2.0 (2026), Apache-2.0.
- Adams R., MacKay D. Bayesian Online Changepoint Detection (2007).
- Truong C., Oudre L., Vayatis N. Selective review of offline change point detection methods (ruptures), 2020.
- Caruana R. et al. Ensemble Selection from Libraries of Models, ICML 2004.
- Diebold F., Mariano R. (1995); Harvey D., Leybourne S., Newbold P. (1997): тесты точности прогнозов.
- Gneiting T., Raftery A. Strictly proper scoring rules (2007); Bracher J. et al. WIS (2021).
- Taylor S., Letham B. Forecasting at Scale (Prophet), 2018.