Прогноз безналичных расходов муниципалитетов и поиск структурных сдвигов

Конкурс СберИндекса 2026, направление «Прогнозирование». Методологический отчёт

Нарек Малоян

Октябрь 2026

1. Кратко

Задача. Прогноз средних безналичных расходов на жителя для 2016 муниципальных образований (МО) по 6 категориям (12 096 рядов) на 1, 3, 6 и 12 месяцев; поиск точек структурных сдвигов.

Главная трудность. В каждом ряду 24 точки (2023-01..2024-12). Перед прогнозом на 12 месяцев у модели меньше одного года истории: собственную годовую сезонность ряда оценить нельзя.

Решение. Мы раскладываем ряд на национальную компоненту (сезонность и инфляция, общие для всех МО; оцениваются по поперечному срезу из 2016 МО, рост на год вперёд берётся из данных Росстата) и локальную компоненту МО. Локальную компоненту прогнозируют 8 вариантов открытых фундаментальных моделей пяти семейств, GBM и классические модели. Ансамбль Caruana выбирает веса по горизонтам **только на validation**. Структурные сдвиги ищут 10 онлайн-детекторов (2 из них с новостями) и 6 офлайн-методов, откалиброванных на одинаковую частоту ложных тревог. Новости GDELT (1,55 млн документов) дают признаки и априорную информацию для детекторов.

Результат на отложенном окне (test, 2024-07..12), MAE, руб. на жителя в месяц:

Модель	h = 1	h = 3	h = 6	h = 12
Prophet (базовая модель организатора)	563	574	652	1361
Ансамбль (наше решение)	**306**	**435**	**446**	**658**
Снижение MAE к Prophet	−46%	−24%	−32%	−52%

Разница с Prophet значима на всех горизонтах: 95% доверительный интервал кластерного бутстрепа по МО целиком ниже нуля (раздел 6.2). R^2 на уровнях 0.998 / 0.996 / 0.995 / 0.991.

2. Данные

Источник	Что берём	Лицензия / условия
СберИндекс, `consumption.parquet`	Средние безналичные расходы на жителя МО, руб./мес., 6 категорий, 2023-01..2024-12	CC BY-SA 4.0; только для конкурса (Положение §9.2.2)
СберИндекс, `market_access.parquet`, справочник МО	Индекс доступности рынков; регион, тип МО, координаты центра, полигоны	то же
Росстат, `Oborot_2025.xls`	Оборот розничной торговли РФ по месяцам, 2000-2025	открытые данные Росстата, со ссылкой на источник
Производственный календарь РФ	Рабочие и календарные дни месяца	пакет `holidays` (MIT) + постановления Правительства о переносе дней
GDELT 1.0 GKG	Темы, места и тональность новостей	свободное использование со ссылкой на GDELT Project

Панель. Берём ряды, у которых есть все 24 месяца: 2016 МО × 6 категорий = **12 096 рядов**. Двенадцать регионов в данных отсутствуют (Белгородская, Курская, Краснодарский край и др.). «Все категории» не равны сумме пяти категорий (сумма ≈ 72% от «Всех категорий»), поэтому категории прогнозируются как отдельные ряды. Категория «Все категории» даёт 59% суммы уровней, поэтому она сильнее всего влияет на общий MAE; таблица по категориям — в разделе 6.4.

3. Протокол оценки (без утечки)

- **Скользящий origin.** Прогноз из месяца o на h месяцев вперёд использует только месяцы 0..o. Для каждой модели строится «куб» прогнозов: все origin 0..23 и все h = 1..12.
- **Два окна.** Validation: целевые месяцы 2024-01..2024-06. Test: 2024-07..2024-12. Веса ансамбля, параметры декомпозиции и выбор моделей делаются **только на validation**. Все итоговые числа — на test, на котором ничего не настраивалось.
- **Обучение GBM** в origin o: только пары (o', h') с целевым месяцем o' + h' ⩽ o.
- **Горизонты** 1, 3, 6, 12 (по условию) и кривая для всех h = 1..12.
- **Все модели на всех 12 096 рядах**, включая Prophet. Сравнение парное, на одних и тех же точках.
- **Метрики.** MAE в рублях (обязательная). R^2 на уровнях. **R^2 на изменении** log(y_T / y_o): R^2 на уровнях почти всегда ≈ 0.99, потому что уровни МО сильно различаются; R^2 на изменении показывает, объясняет ли модель динамику. WAPE, медиана абсолютной процентной ошибки (MdAPE), смещение (Bias, % суммы факта).
- **Значимость.** Разница MAE с Prophet и 95% доверительный интервал: кластерный бутстреп по МО (1000 повторов). Шесть категорий одного МО остаются вместе.

Ограничение протокола. В validation для h = 12 origin лежат в 2023-01..2023-06 (1-6 месяцев истории). Поэтому веса для длинных горизонтов выбираются в режиме более короткой истории, чем на test. Мы не меняем окна под test и показываем это как ограничение.

4. Архитектура: национальная и локальная компоненты

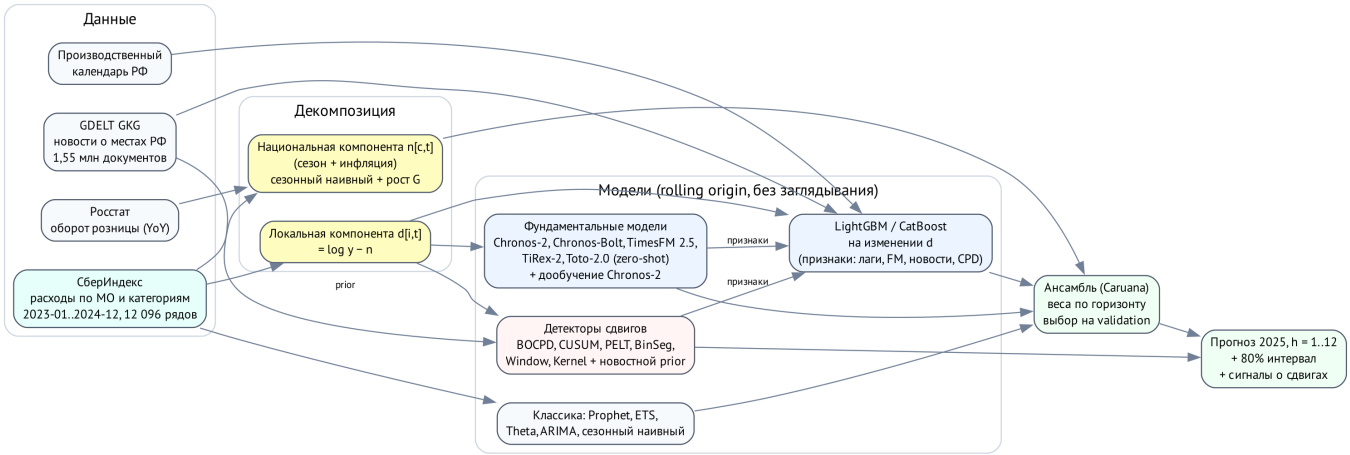


Рис. 1: Архитектура решения

Сезонность и инфляция почти одинаковы для всех МО. Их можно оценить по поперечному срезу из 2016 МО, а не по 24 точкам одного ряда:

```
log y[i,t] = n[c,t] + d[i,t]
```

- **n[c,t]** — национальная компонента категории c: медиана log y по всем МО в месяце t. Она известна в месяце t (использует только данные месяца t).
- **d[i,t]** — локальная компонента МО: отклонение от национального уровня. В ней нет общей сезонности. Она меняется медленно, а локальный шок (паводок, закрытие предприятия) даёт в ней ступеньку.

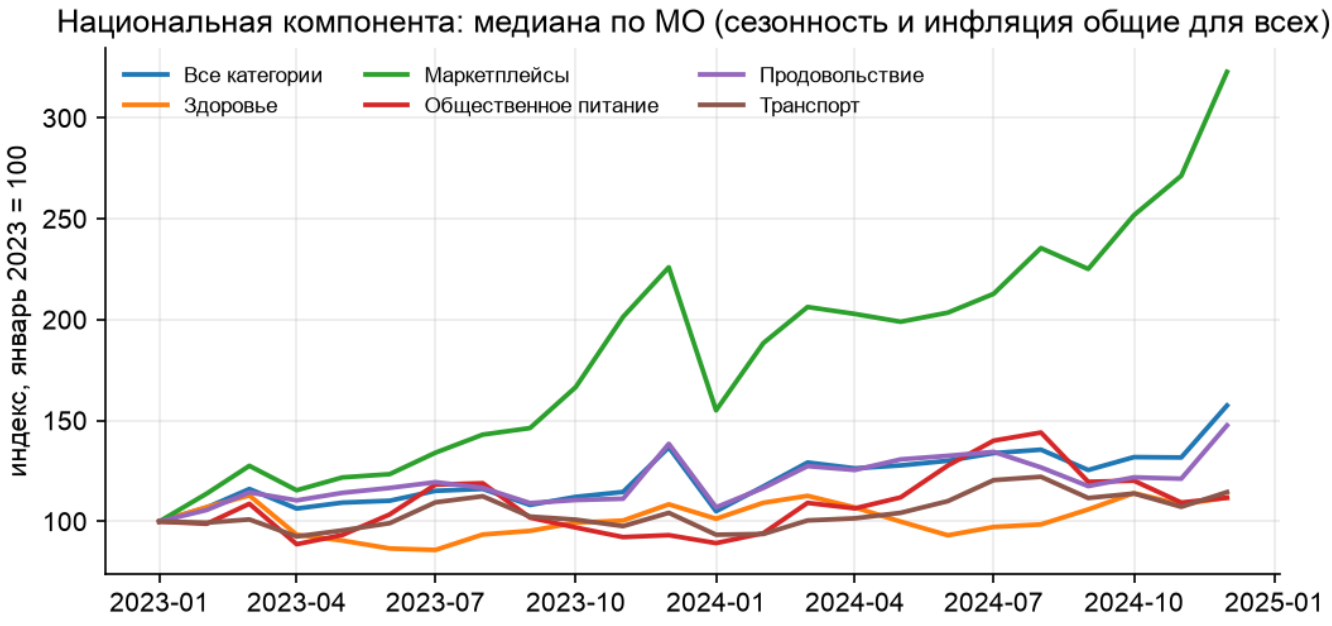


Рис. 2: Национальная компонента: сезонность общая для всех МО

Прогноз национальной компоненты (звёздочка * обозначает прогноз):

$$n*[c,T] = n[c,T-12] + G, \quad G = w \cdot YoY_own(k) + (1 - w) \cdot YoY_Росстат$$

YoY_own — средний годовой прирост n за последние k месяцев. YoY_Росстат — годовой прирост оборота розничной торговли со сдвигом 2 месяца (к моменту прогноза данные уже опубликованы). Пока у СберИндекса нет 12 месяцев истории (origin до 2023-12), G берётся только из Росстата. Это решает задачу h = 12: годовой темп роста приходит из внешнего источника, а не из 7-11 точек. Параметры (k, w) выбираются на validation по сетке: k = 1; w = 0.75 для h = 1-2, 0.25 для h = 3, 0.5 для остальных горизонтов (для h ⩾ 4 одна общая пара, потому что в validation у этих горизонтов почти нет origin с годом истории). Сезонный профиль Росстата как априорная сезонность не подошёл: он плохо совпадает с профилем СберИндекса (февраль −10% у Росстата, −1% у СберИндекса), поэтому из Росстата берём только темп роста.

Прогноз локальной компоненты d*[i,T] даёт одна из моделей раздела 5. Итог:* $y = \exp(n^* + d^*)$.

5. Модели прогнозирования

Группа	Модели	Роль
Наивные	naive, сезонная наивная, сезонная наивная × собственный YoY (k=3), × национальный YoY, дрейф	Опорные точки
Базовая организатора	**Prophet** (годовая сезонность Фурье 3-го порядка, мультипликативная), отдельная модель на каждый ряд и origin	Цель «превзойти Prophet»
Классика	AutoETS, AutoTheta, AutoARIMA (statsforecast)	Сравнение
Первый бейзлайн	LightGBM v1 на log(y_T/y_o) без декомпозиции	Вклад архитектуры
Декомпозиция	$n^* + d$; *d* = persistence / среднее 3 мес. / локальный сезон	Простая сильная модель
Фундаментальные	Chronos-Bolt S/B, Chronos-2, Chronos-2 мультивариантный, TimesFM 2.5, TiRex-2, Toto-2.0 22M/313M, Chronos-2 дообученный	Раздел 6.3

Группа	Модели	Роль
GBM	LightGBM и CatBoost на изменении d, прямой мульти-горизонтный	Признаки: лаги d, d год назад, региональный d, рост n*, календарь, FM, новости, CPD
С учётом сдвигов	сезонная наивная с поправкой истории после тревоги CUSUM	Раздел 7.4
Ансамбль	Отбор Caruana (жадный, с возвращением, 20 шагов), отдельно для каждого h, пул соседних h ± 1	Веса только по validation

Фундаментальные модели — только с открытыми весами Apache-2.0, запуск локально (Apple M3 Pro, MPS). Moirai (CC BY-NC) и TimesFM 3.0 (некоммерческая лицензия) исключены: Положение §10.3 запрещает технологии, на которые нужны платные права, а победитель передаёт Сберу лицензию на решение.

Способы применения FM:

1. **Zero-shot на уровнях** — как «из коробки».
2. **Zero-shot на локальной компоненте** exp(d). FM прогнозирует d, национальная компонента добавляется обратно. Для Chronos-2 есть мультивариантный режим: 6 категорий одного МО подаются как одна группа, модель учитывает их совместную динамику.
3. **Признаки для GBM**: медианный прогноз FM для d и ширина 80% интервала.
4. **Дообучение Chronos-2** (полное, 300 шагов, lr = 1e-5) на локальной компоненте, строго каузально: модель, дообученная на месяцах 0..c, применяется к origin c..(следующая отсечка − 1). Отсечки 2023-12, 2024-06, 2024-12. Время: 5-6 минут на отсечку на ноутбуке.

6. Результаты прогнозирования

6.1. Сравнение моделей

MAE на **test** (руб. на жителя в месяц). Жирным — лучшая модель в столбце.

Модель	h = 1	h = 3	h = 6	h = 12
Наивная	624	864	1124	1289
Сезонная наивная × YoY	340	469	663	1289
Prophet	563	574	652	1361
AutoETS	634	807	1036	1383
AutoTheta	614	744	767	922
AutoARIMA	645	862	1094	1529
LightGBM v1 (без декомпозиции)	313	**420**	761	969
TimesFM 2.5, zero-shot на уровнях	559	797	1283	1691
Chronos-2, zero-shot на уровнях	613	877	1361	1817
Декомпозиция, d = persistence	318	566	526	691
TimesFM 2.5 на локальной компоненте	296	522	493	729
Chronos-2 мультивариантный на лок. комп.	302	531	532	772
Chronos-2 дообученный на лок. комп.	308	528	527	771
GBM LightGBM, все признаки	**296**	532	509	724
GBM CatBoost, все признаки	302	536	513	712
Ансамбль	306	435	**446**	**658**

То же на **validation** (окно выбора; для ансамбля это значение на обучающем окне весов, оно оптимистично и приведено только для полноты): Prophet 893 / 961 / 1241 / 2219; декомпозиция 428 / 682 / 587 / 1058; TimesFM 2.5 на лок. комп. 400 / 638 / 540 / 1098; GBM 443 / 695 / 622 / 999.

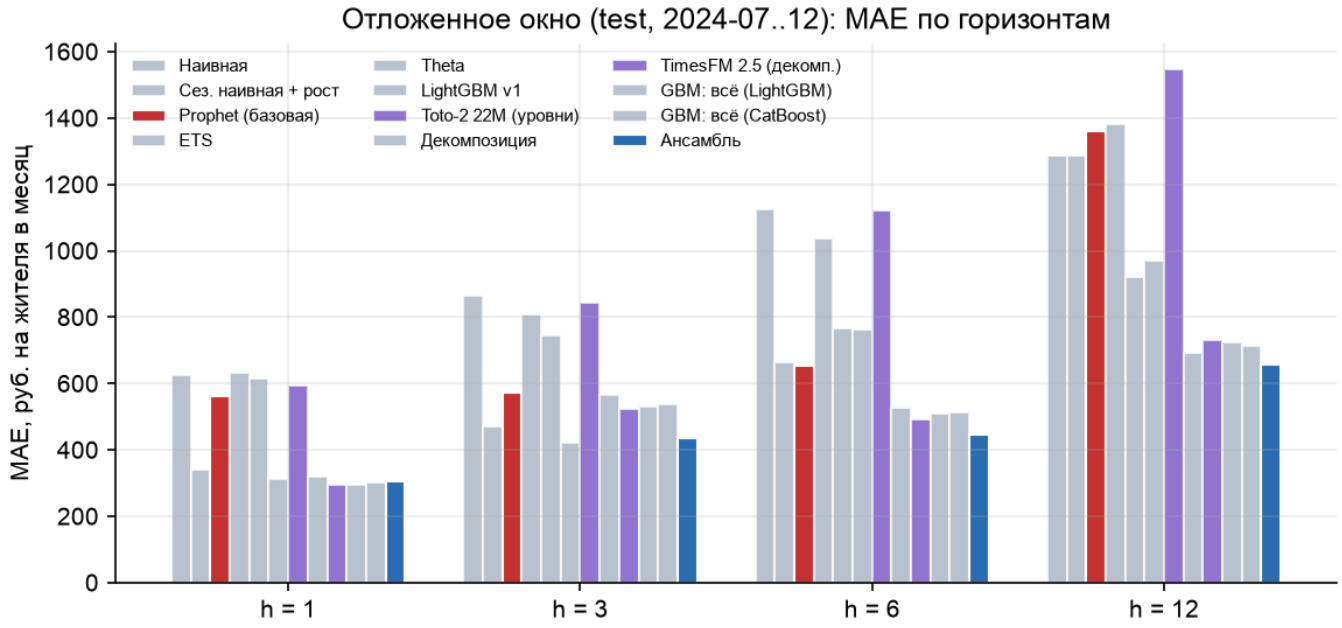


Рис. 3: MAE по горизонтам на test

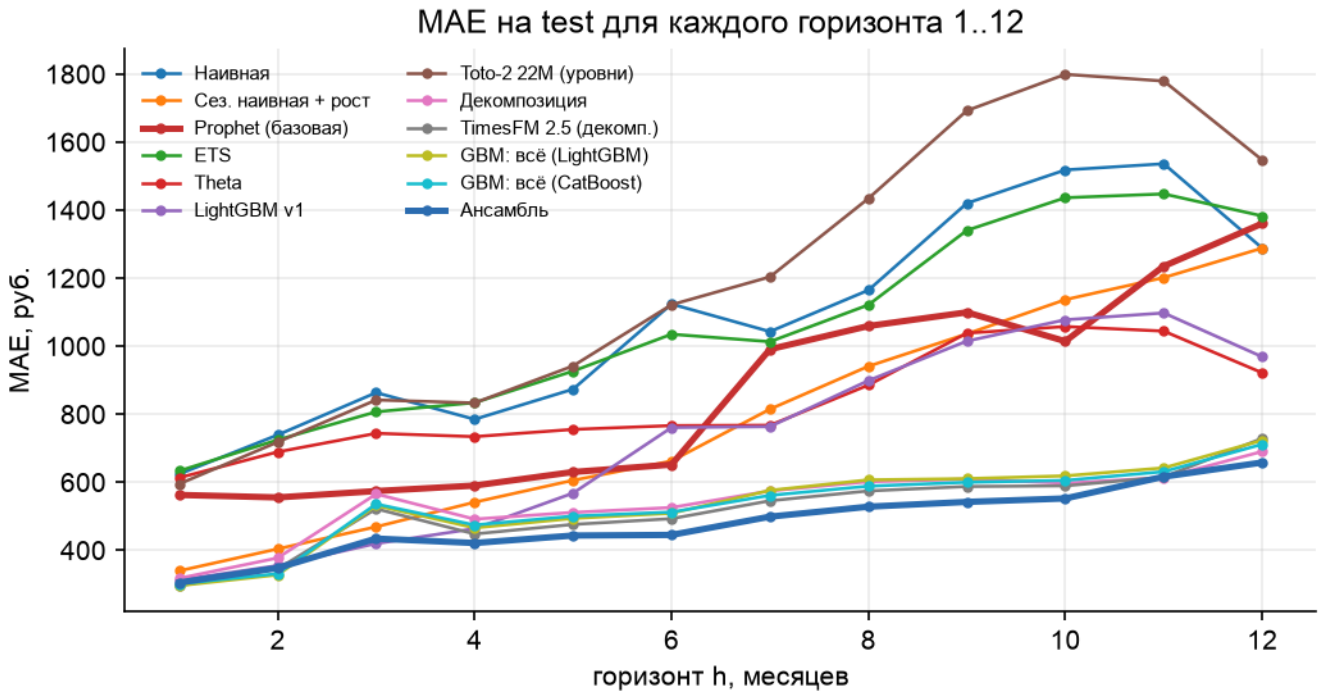


Рис. 4: MAE на test для каждого горизонта

Выводы.

- **Prophet проигрывает всем моделям на декомпозиции на всех горизонтах.** На 24 точках он переоценивает тренд и плохо переносит декабрьский пик (смещение +6.8% на h = 12).
- **На h = 12 решает архитектура.** Модели без внешней информации о годовом росте (наивная, сезонная наивная, ETS, Prophet) дают 1289-1383. Национальная компонента с ростом из Росстата снижает ошибку до 658-729.

- **На h = 1 почти все сильные модели близки (296-318).** Ансамбль (306) немного хуже лучшей одиночной модели: веса выбраны на validation, а не на test.
- **На h = 3 лучший одиночный результат у LightGBM v1 (420).** На validation он был хуже (676), поэтому ансамбль его не выбрал. Это честная цена выбора без подглядывания в test.
- **Ансамбль лучший на h = 6 и h = 12** и второй на h = 3. Состав весов (validation): h = 1 — сезонная наивная с учётом сдвигов 0.35, Theta 0.25, TimesFM 2.5 0.15, остальное 0.25; h = 6 — TimesFM 2.5 на локальной компоненте 0.55; h = 12 — GBM 0.45, Theta 0.25, Prophet 0.15. Prophet вошёл в ансамбль на h = 12: его ошибки слабо коррелируют с остальными.

6.2. Значимость и дополнительные метрики



Рис. 5: Разница MAE с Prophet, 95% ДИ

Метрика (test)	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12
MAE, руб.	306 / 435 / 446 / 658	563 / 574 / 652 / 1361
R^2 (уровни)	0.998 / 0.996 / 0.995 / 0.991	0.991 / 0.992 / 0.990 / 0.954
R^2 (изменение к origin)	0.42 / 0.59 / 0.53 / −0.17	−2.6 / −0.86 / −8.4 / −167
WAPE	3.3% / 4.7% / 4.9% / 7.2%	6.1% / 6.3% / 7.1% / 14.8%
MdAPE	3.7% / 5.3% / 5.4% / 8.1%	5.6% / 6.3% / 7.5% / 16.7%
Смещение	+0.7% / +1.2% / −0.4% / +0.3%	−0.6% / −0.5% / −1.6% / +6.8%

ΔMAE ансамбля к Prophet и 95% ДИ: h = 1: −258 [−263; −253]; h = 3: −140 [−145; −134]; h = 6: −207 [−215; −199]; h = 12: −702 [−722; −682] руб.

Интерпретация метрик. R^2 на уровнях высокий у всех моделей и плохо их различает. R^2 на изменении показывает, что ансамбль объясняет 42-59% вариации изменения расходов за 1-6 месяцев. На h = 12 R^2 на изменении отрицательный: годовой рост в основном общий для всех МО, а ошибка оценки общего роста (≈ 1 п.п.) больше, чем различия между МО. Prophet на изменении хуже константы на всех горизонтах. Смещение ансамбля мало (|Bias| ⩽ 1.2%), у Prophet на h = 12 +6.8%: он экстраполирует тренд первого года.

6.3. Фундаментальные модели: преимущества и ограничения

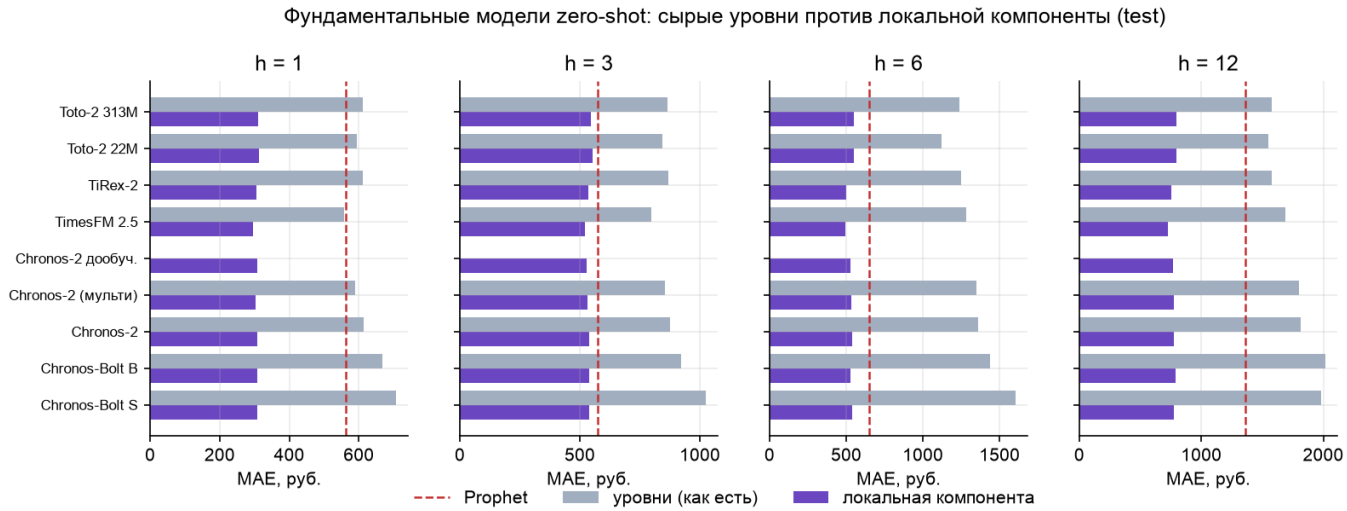


Рис. 6: FM: сырые уровни против локальной компоненты

FM (test, MAE)	уровни h = 1 / 3 / 6 / 12	лок. компонента h = 1 / 3 / 6 / 12	покрытие 80% инт., h = 1 / 12	время, с
Chronos-Bolt S	707 / 1024 / 1603 / 1986	307 / 538 / 539 / 774	0.82 / 0.88	37
Chronos-Bolt B	668 / 920 / 1439 / 2015	307 / 538 / 529 / 787	0.83 / 0.89	75
Chronos-2	613 / 877 / 1361 / 1817	307 / 539 / 540 / 776	0.83 / 0.90	102
Chronos-2 мультивар.	588 / 854 / 1351 / 1802	302 / 531 / 532 / 772	0.81 / 0.91	104
Chronos-2 дообуч.	—	308 / 528 / 527 / 771	0.88 / 0.89	982
TimesFM 2.5	559 / 797 / 1283 / 1691	**296 / 522 / 493 / 729**	0.82 / 0.73	1028
TiRex-2	612 / 870 / 1250 / 1575	305 / 535 / 502 / 757	0.80 / 0.76	3220
Toto-2.0 22M	595 / 842 / 1122 / 1548	313 / 552 / 550 / 799	0.74 / 0.88	28
Toto-2.0 313M	611 / 866 / 1240 / 1576	310 / 548 / 548 / 794	0.82 / 0.87	356

Время — полный прогон 24 origin × 12 096 рядов на Apple M3 Pro (MPS), при параллельной загрузке машины другими расчётами.

Выводы по FM.

- **Zero-shot на сырых уровнях не работает:** при h ⩾ 3 все 8 вариантов хуже Prophet и примерно на уровне наивной модели (797-1024 против 864 на h = 3; 1122-1603 против 1124 на h = 6). Причина — ряды из 7-23 точек с сильным декабрьским пиком. Модель не знает календарь и не может выучить сезон из одного года. Это ограничение FM на очень коротких рядах.
- **Корректное применение — на локальной компоненте.** Та же модель без дообучения снижает MAE в 1.5-3 раза и обгоняет Prophet на всех горизонтах. На h = 1-3 FM лучше persistence (296 против 318 на h = 1), на h = 12 хуже (729 против 691): FM экстраполируют локальный тренд.
- **Лучшая FM — TimesFM 2.5**, но её 80% интервалы на длинных горизонтах узкие (покрытие 0.73 на h = 12). Семейство Chronos даёт откалиброванные интервалы (0.81-0.91).
- **Мультивариантный Chronos-2** (6 категорий МО как одна группа) немного лучше одномерного (302 против 307 на h = 1): совместная динамика категорий несёт информацию.
- **Дообучение Chronos-2** (каузальное, 3 отсечки, 16 минут) даёт −2% на h = 3-6 и улучшает покрытие интервалов на h = 1 (0.88 против 0.83). Эффект скромный: в панели всего 24 месяца.
- **Вклад в ансамбль.** Тот же отбор Caruana без всех FM-моделей: 307 / 425 / 473 / 658. С FM: 306 / 435 / 446 / 658. FM снижают MAE ансамбля на h = 6 на 5.9%, на h = 1 на 0.5%, на h = 12 не входят в ансамбль, на h =

3 ухудшают на 2.4% (веса validation не перенеслись).

- **FM как признаки GBM** почти не помогают (±1%, раздел 6.5): GBM уже видит те же лаги.

6.4. По категориям (test, MAE)

Категория	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12
Все категории	837 / 1147 / 1181 / 1695	1792 / 1772 / 2057 / 4060
Продовольствие	428 / 728 / 672 / 839	755 / 744 / 768 / 2070
Маркетплейсы	334 / 401 / 461 / **927**	526 / 547 / 593 / **825**
Транспорт	85 / 125 / 140 / 190	124 / 157 / 206 / 431
Здоровье	81 / 98 / 91 / 164	91 / 106 / 128 / 449
Общественное питание	69 / 110 / 127 / 136	90 / 120 / 161 / 332

Ансамбль лучше Prophet в 23 из 24 ячеек. Исключение — маркетплейсы на h = 12: рост категории ≈ +45% в год, а годовой рост розничной торговли Росстата (≈ +15%) его занижает; трендовая экстраполяция Prophet здесь уместнее. Улучшение на будущее: категорийный внешний источник роста (например, доля интернет-торговли Росстата).

6.5. Абляция признаков GBM

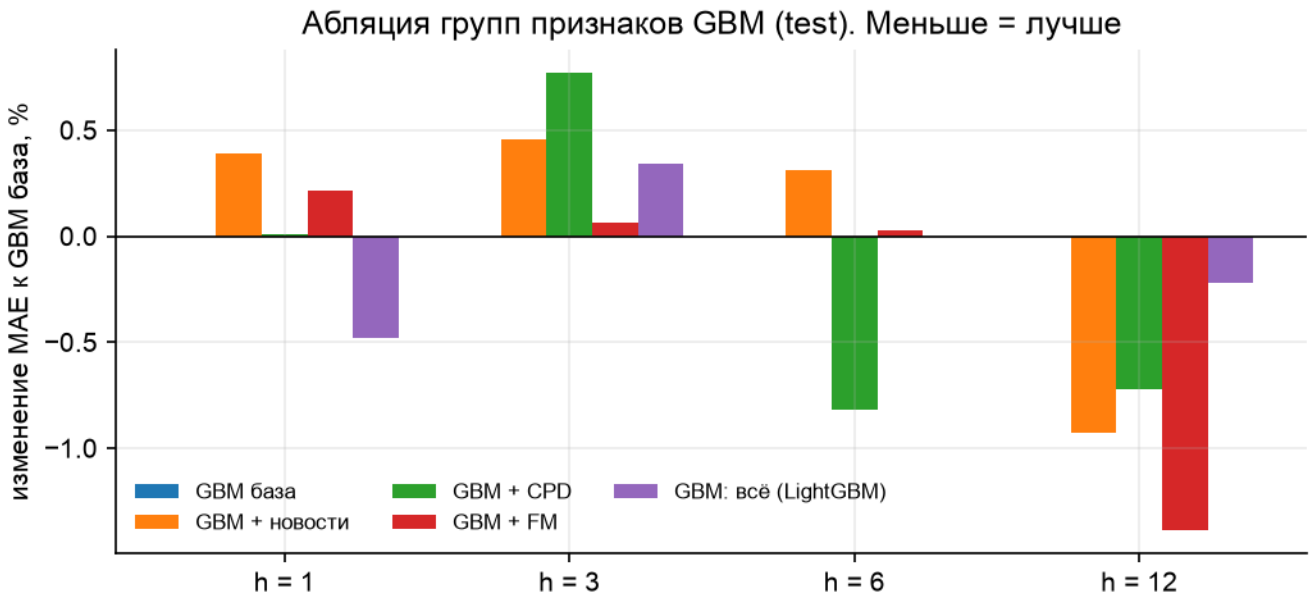


Рис. 7: Абляция групп признаков

Все варианты GBM отличаются от базового не более чем на 1.4%. Новости: +0.4% (h = 1), −0.9% (h = 12); на подвыборке MO с новостями в 3 месяцах до origin эффект тот же. Признаки сдвигов: −0.8% на h = 6. FM-признаки: −1.4% на h = 12. Главные признаки (gain): регион, d год назад относительно origin, месяц цели, категория, изменение регионального d за 3 месяца. Вывод: в прогнозе уровня новости дают мало — они редки (новости есть у 575 из 2016 MO) и англоязычны. Их ценность — в поиске сдвигов (раздел 7) и в объяснении шоков.

7. Структурные сдвиги

7.1. Методы

Сдвиг ищем в локальной компоненте d (сезонность и инфляция уже убраны). Ряд стандартизуется робастным масштабом месячных изменений в 2023 г. (MAD).

Онлайн-детекторы (решение в месяце t только по данным до t, запуск с 2024-01):

Детектор	Идея
spike	$\|\Delta z_t\| > k$: скачок за один месяц
CUSUM	двусторонние кумулятивные суммы отклонений от уровня 2023 г., перезапуск после тревоги
PELT, BinSeg, Window (ruptures)	переподгонка сегментации на z[0..t]; тревога, если последний разрыв свежий
BOCPD (Adams, MacKay 2007)	апостериорное распределение длины текущего режима, модель Normal-Gamma, hazard 0.05
BOCPD-подтв.	то же, но новый режим должен продержаться 2 месяца (устойчив к выбросам)
resid-CUSUM	CUSUM на ошибках локальной сезонной наивной модели
CUSUM / BOCPD + новости	порог CUSUM × 0.6 или hazard BOCPD × 5 в месяц новостного всплеска и следующий

Офлайн-методы (весь ряд сразу): PELT, BinSeg, BottomUp, Window, KernelCPD (rbf), MAP-сегментация BOCPD.

Честное сравнение. У каждого онлайн-детектора один порог. Его калибруем на половине рядов так, чтобы частота ложных тревог на чистых рядах была ⩽ 2% на ряд-месяц (подобранные пороги: spike k = 4, CUSUM h = 8, PELT/BinSeg/Window штраф 12, BOCPD порог 0.7, BOCPD-подтв. 0.8). Метрики считаем на другой половине. Без такой калибровки сравнение «чувствительность против задержки» не имеет смысла: любой детектор можно сделать сколь угодно чувствительным.

Синтетика. В реальные ряды d («Все категории», 400 МО) вставляем в случайный месяц 2024-02..2024-10 ступеньку 5/10/20/30%, излом тренда 2/4% в месяц или одномесячный выброс 20% (выброс — не структурный сдвиг: хороший детектор его игнорирует). Метрики: recall и precision с допуском 2 месяца, F1, средняя задержка, частота ложных тревог.

7.2. Результаты на синтетике

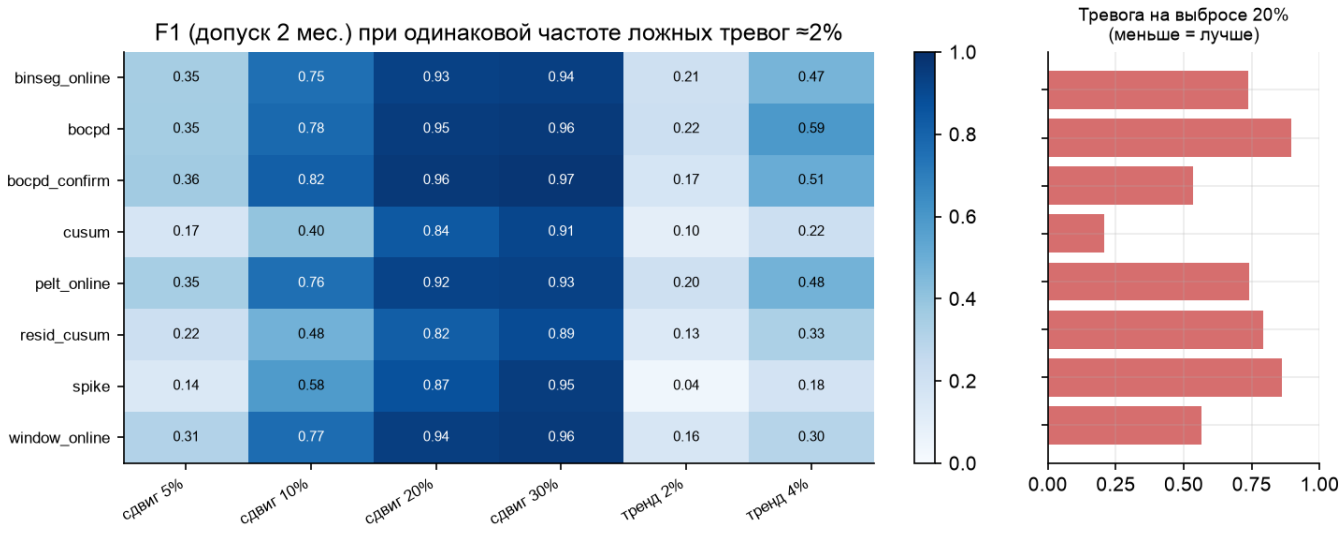


Рис. 8: F1 детекторов при равной частоте ложных тревог

Детектор	F1, сдвиг 5 / 10 / 20%	Задержка, мес. (сдвиг 10%)	F1, тренд 4%/мес	Тревога на выбросе	Ложные тревоги
BOCPD-подтв.	0.36 / **0.82** / **0.96**	1.19	0.51	0.54	1.3%
BOCPD	0.35 / 0.78 / 0.95	0.34	**0.59**	0.90	1.6%
Window	0.31 / 0.77 / 0.94	1.62	0.30	0.56	1.2%
PELT	0.35 / 0.76 / 0.92	0.70	0.48	0.74	1.5%
BinSeg	0.35 / 0.75 / 0.93	0.69	0.47	0.74	1.4%
spike	0.14 / 0.58 / 0.87	**0.00**	0.18	0.86	0.8%
resid-CUSUM	0.22 / 0.48 / 0.82	0.27	0.33	0.79	1.3%
CUSUM	0.17 / 0.40 / 0.84	1.36	0.22	**0.21**	1.4%

Офлайн (весь ряд, допуск 1 месяц), F1 при сдвиге 10 / 20%: Window 0.71 / 0.82, PELT 0.66 / 0.76, BinSeg 0.66 / 0.77, BOCPD-MAP 0.59 / 0.69, BottomUp 0.58 / 0.68, KernelCPD 0.57 / 0.72. Ошибка положения у PELT и BinSeg при сдвиге $\geqslant 10\%$ меньше 0.1 месяца.

Выбор. Для раннего обнаружения — **BOCPD**: при той же частоте ложных тревог он ловит сдвиг 10% с задержкой 0.3 месяца и лучше всех находит изломы тренда. Его слабость — реакция на одномесячные выбросы (90%). Для устойчивых сигналов — **BOCPD с подтверждением**: лучший F1 (0.82 при сдвиге 10%), выбросы почти вдвое реже, цена — 1 месяц задержки. CUSUM почти не реагирует на выбросы (21%), но медленный (1.4 месяца) и пропускает малые сдвиги. Сдвиг 5% ($\approx$ месячный шум ряда) не обнаруживает надёжно ни один метод (F1 $\leqslant 0.36$): это предел данных.

7.3. Реальные данные и новости

Тревоги по месяцам 2024 г. (2016 МО, «Все категории»): BOCPD 13-53 в месяц, PELT 26-66; у CUSUM число тревог растёт к концу года (с 0 до 91): он накапливает медленный локальный дрейф, поэтому для реальных рядов CUSUM нужен с осторожностью. Всплеск resid-CUSUM в 2024-04 (100 тревог) — артефакт: его эталон «год назад» — апрель 2023, где у многих МО есть разрыв в исходных данных (в офлайн-PELT 341 разрыв из 986 приходится на 2023-04; это край ряда с min_size = 3 или смена методики в источнике).

Паводок в Орске (прорыв дамбы 5 апреля 2024). Локальная компонента Орска выросла с +16% к национальному уровню (апрель) до +24% (май), затем вернулась к +16-17% к августу. Вероятные причины всплеска (гипотеза, не проверена): выплаты пострадавшим и покупки взамен утраченного имущества. В GDELT за апрель 2024 об Орске 1 367 документов, 1 336 с темой «наводнение» (обычно 0-10 в месяц). Сдвиг +7% близок к пределу обнаружения: обычные детекторы его не видят; CUSUM поднимает тревогу в июне, **CUSUM с новостным prior — в мае**, на месяц раньше.



Рис. 9: Орск: данные, тревоги, новости

Новостные события как разметка. 53 МО-месяца 2024 г. со всплеском документов о бедствиях ($\geqslant 10$ документов и в 3 раза выше среднего за 6 месяцев). Доля событий, после которых детектор поднял тревогу в 0..2 месяца, против базовой частоты тревог: CUSUM 7.5% против 5.1% (lift 1.5), CUSUM + новости 7.5% (1.5), BOCPD + новости 3.8% против 3.1% (1.2), BOCPD 0% (lift 0). Большая часть новостных событий не сдвигает расходы на жителя (пожары, ДТП, новости о крупных городах), поэтому lift невысокий у всех методов.

Полусинтетика с новостями (сдвиг 10%; новость есть у половины сдвигов и в 3% прочих месяцев, как в реальных данных): CUSUM + новости F1 0.43 против 0.38, задержка 1.1 против 1.5 месяца; BOCPD + новости 0.73 против 0.78 (рост hazard добавляет ложные тревоги). Вывод: новостной prior полезен для медленного детектора (CUSUM) и не нужен быстрому (BOCPD).

7.4. Как учёт сдвигов улучшает прогноз

Модели с «памятью» о прошлом годе (сезонная наивная, Prophet, признак «d год назад» в GBM) после сдвига опираются на старый уровень. Поправка: после тревоги точка сдвига уточняется (разбиение с минимальной суммой квадратов в окне [тревога − 3; тревога]), история до сдвига переносится на новый уровень, и только потом считается прогноз.

Синтетика, сдвиг 15%, MAE (руб.)	h = 1	h = 2	h = 3	h = 6
Локальная сезонная модель (YoY за 3 мес.)	947	1022	1164	1567
То же с поправкой на сдвиг	**819**	**920**	**1032**	**1397**
Изменение	−14%	−10%	−11%	−11%

На реальных данных (test) поправка в сезонной наивной модели затрагивает 15% рядов на h = 1 и даёт на этих рядах −0.3% MAE на h = 1 и −1.3% на h = 3; эта модель получила наибольший вес в ансамбле на h = 1 (0.35). Первая версия поправки без уточнения точки сдвига ухудшала прогноз: тревога приходит с задержкой, и

поправка попадала не на те месяцы (см. LOG.md).

8. Интеграция новостей

1. **Сбор.** Ежедневные файлы GDELT GKG 1.0 за 2022-12..2024-12 (761 день, ≈ 33 ГБ; 2023-03-23 на сервере GDELT отсутствует). Оставляем документы, где есть город или регион РФ: **1,55 млн документов**.
2. **Привязка к МО.** GDELT геокодирует шумно (украинские топонимы попадают в российские регионы, фамилии распознаются как сёла). Город GDELT привязываем к МО, только если (а) центр МО в 30 км от точки GDELT и (б) транслитерация названия центра МО или краткого имени МО начинается с тех же 5 букв. Так 942 места привязаны к 811 МО. Остальные места считаются на уровне региона (по коду ADM1, 81 регион). Таблица привязки сохраняется для аудита (`data/external/news_location_match.csv`).
3. **Темы.** Темы GKG извлечены GDELT из текста статьи. Группы: бедствие, наводнение, пожар, экономика-негатив (безработица, банкротство, забастовка), цены, инфраструктура, безопасность. Тему MANMADE_DISASTER_IMPLIED исключаем: GDELT ставит её на большинство военных текстов.
4. **Признаки** на месяц t (только документы до конца месяца t): log(1 + число документов), «сюрприз» (отклонение от среднего за 6 месяцев), число документов по темам, средняя тональность; то же для региона.
5. **Использование.** (а) признаки GBM (абляция в 6.5); (б) априорная информация для детекторов сдвигов: новостной всплеск снижает порог CUSUM и повышает hazard BOCPD (7.3); (в) разметка реальных событий для проверки детекторов (7.3).

Ограничения. GKG 1.0 — англоязычные СМИ; малые МО почти не упоминаются (новости есть у 575 из 2016 МО панели). Русскоязычный поток GDELT 2.0 (Translingual) полнее, но это ≈ 70 тыс. 15-минутных файлов; в рамках конкурса его не загружали.

9. Прогноз на 2025 год и практические выводы

Финальный прогноз (origin 2024-12, h = 1..12) делает тот же ансамбль; веса выбраны заново на validation + test. 80% интервал — эмпирические квантили 10% и 90% логарифмических ошибок честного ансамбля на test по горизонту и категории. Файл `results/forecast_2025.csv` (145 152 строки: МО, категория, месяц, прогноз, нижняя и верхняя граница).

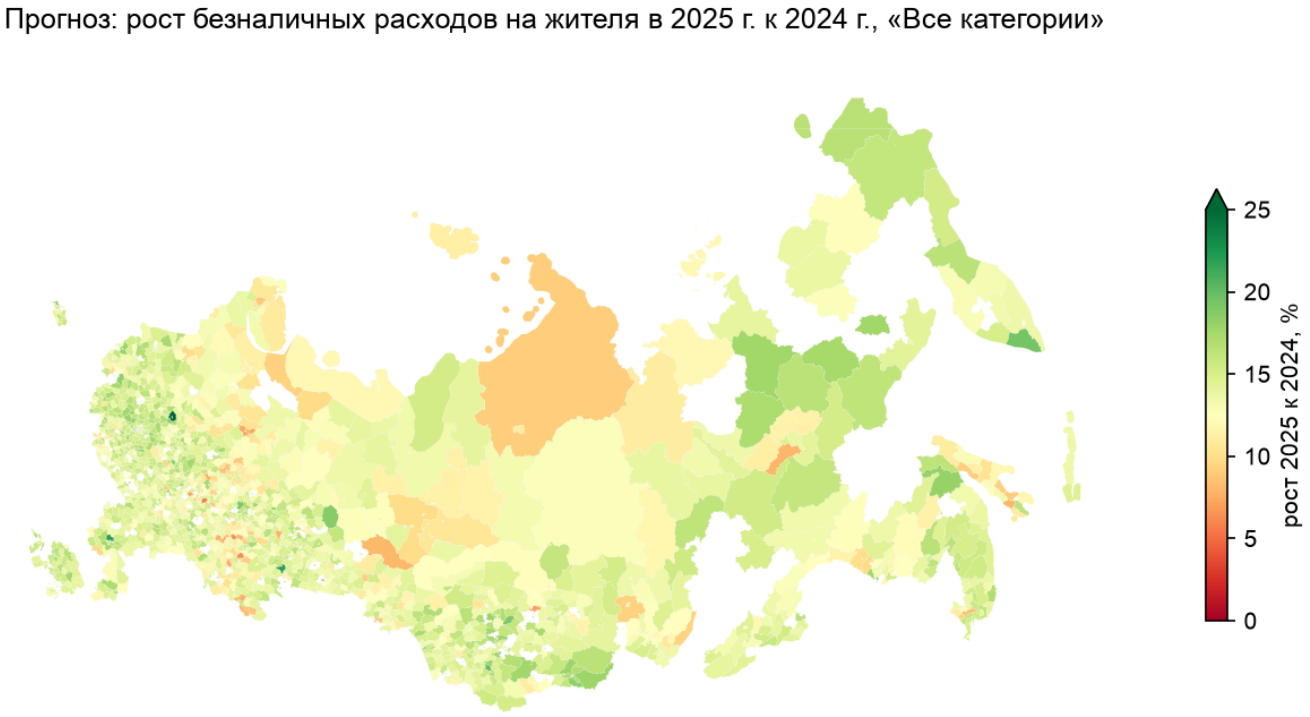


Рис. 10: Прогноз роста 2025 к 2024

Медианный прогноз декабря 2025 к декабрю 2024: все категории +10.5%, маркетплейсы +24.6%, общественное питание +13.6%, транспорт +9.9%, здоровье +7.1%, продовольствие +6.2%.

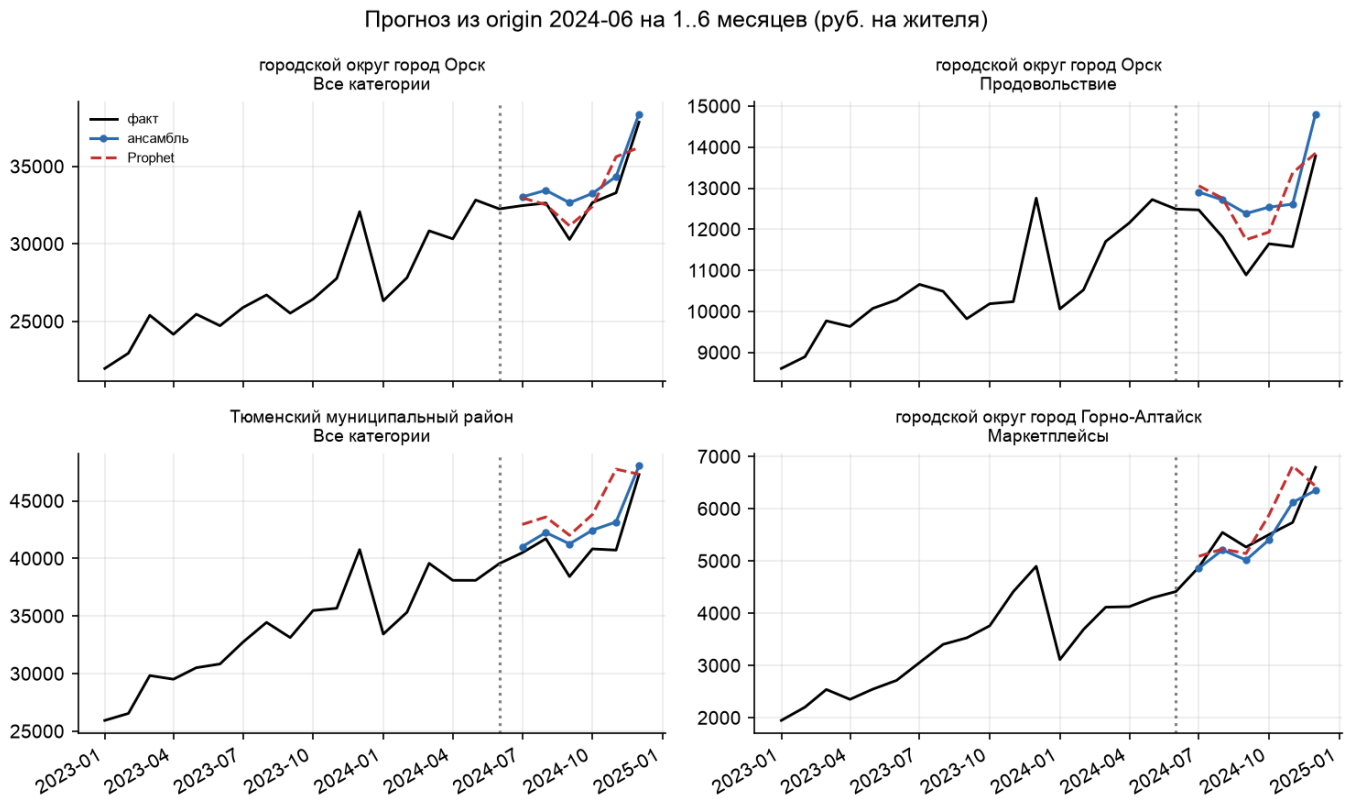


Рис. 11: Примеры прогнозов

Практические выводы.

- **Для прогноза по МО на короткой истории главное — отделить общую динамику.** Это даёт больше, чем выбор модели: декомпозиция с persistence уже снижает MAE к Prophet на 44% / 1% / 19% / 49%.
- **Годовой горизонт требует внешнего источника роста.** Без него h = 12 не прогнозируется.
- **Фундаментальные модели стоит применять к очищенному от сезонности сигналу**, а не к «сырым» коротким рядам; лучший выигрыш — на среднем горизонте (h = 6).
- **Мониторинг шоков.** BOCPD с подтверждением даёт устойчивые сигналы с задержкой ~1 месяц; для быстрых сигналов — BOCPD; новости ускоряют CUSUM на месяц (пример Орска).
- **Локальный шок не обязательно долгий.** В Орске всплеск расходов после паводка продлился ~3 месяца; прогноз после сдвига должен переоценивать уровень, а не продлевать скачок.

10. Ограничения

- 24 месяца: окно validation для h = 12 короче по истории, чем test (раздел 3).
- Правило «отдельные (k, w) для h ⩽ 3» введено после первого просмотра test (одна итерация дизайна, зафиксирована в LOG.md). Оно улучшило h = 1 и ухудшило h = 3 на test; мы его не меняли.
- Нет настоящей разметки шоков; реальная проверка — по новостной разметке и примерам.
- GDELT GKG 1.0 — только англоязычные источники.
- Фундаментальные модели обучались на открытых корпусах; мы не можем исключить, что в них есть ряды за 2024 г. (не данные СберИндекса).

11. Воспроизводимость

```
make setup          # uv + Python 3.13, точные версии из requirements.lock.txt
make data           # данные СберИндекса, справочник МО, Росстат
make reproduce      # все шаги: модели, FM, CPD, новости, ансамбль, прогноз, рисунки, отчёт
```

Все параметры — в `configs/config.yaml` (окна, сетки, гиперпараметры, список FM, темы новостей). Каждый шаг — отдельный скрипт в `src/` с инструкцией в начале файла; промежуточные прогнозы кэшируются в `results/cache/`. Полный прогон на Apple M3 Pro: ≈ 4-5 ч (Prophet ≈ 50 мин, statsforecast ≈ 45 мин, FM ≈ 1.5 ч, GBM ≈ 1.5 ч, загрузка GDELT ≈ 1-2 ч). Журнал экспериментов — `LOG.md`. Данные организатора в репозиторий не входят (Положение §9.2.2).

При разработке кода использовались инструменты ИИ-ассистирования (Claude Code). Все решения, результаты и текст проверены автором; автор отвечает за проект.

12. Источники

- СберИндекс, данные конкурса: https://sber.ru/sberindex/konkurs_sberindex (CC BY-SA 4.0).
- Росстат, оборот розничной торговли: https://rosstat.gov.ru/statistics/roznichnayatorgovlya.
- The GDELT Project, GKG 1.0: https://www.gdeltproject.org.
- Ansari et al. Chronos (2024); Chronos-2 (2025), amazon/chronos-2, Apache-2.0.
- Das et al. TimesFM (2024); google/timesfm-2.5-200m-pytorch, Apache-2.0.
- NX-AI TiRex-2 (2026), Apache-2.0. Datadog Toto 2.0 (2026), Apache-2.0.
- Adams R., MacKay D. Bayesian Online Changepoint Detection (2007).
- Truong C., Oudre L., Vayatis N. Selective review of offline change point detection methods (ruptures), 2020.
- Caruana R. et al. Ensemble Selection from Libraries of Models, ICML 2004.
- Taylor S., Letham B. Forecasting at Scale (Prophet), 2018.