Прогноз безналичных расходов муниципалитетов и поиск структурных сдвигов

Конкурс СберИндекса 2026, направление «Прогнозирование». Методологический отчёт

Нарек Малоян

Октябрь 2026

0. Карта критериев

Критерий (вес)	Где в отчёте	Главное число или вывод
Простота объяснения методологии (10%)	§1, рис. 1; §2	4 шага: общий ритм страны, отклонение города, ансамбль, сторож
Сравнение моделей, лучше Prophet на 4 горизонтах (20%)	§3	MAE 306 / 435 / 446 / 658 против 563 / 574 / 652 / 1361; значимо на h = 1, 6, 12
Сравнение методов поиска сдвигов (20%)	§5	10 онлайн + 6 офлайн методов при равной частоте ложных тревог; выбор: BOCPD-подтв.
Фундаментальные модели (15%)	§4	на сырых рядах хуже наивной; на локальной компоненте в 1.5-3 раза лучше
Интеграция новостей (15%)	§6	GDELT 1,55 млн документов + реестр ЧС из официальных источников; правило «as-of»; event study паводка
Метрики: MAE и R^2 (10%)	§7	MAE, R^2 на уровнях и на изменении, WAPE, MdAPE, смещение, покрытие и WIS интервалов
Интерпретация, воспроизводимость, выводы (10%)	§8-10	проверка прогноза 2025 на факте; `make quick` со свежего клона за 2 минуты

1. Методология за одну страницу

Задача. Прогноз средних безналичных расходов на жителя для 2016 муниципальных образований (МО) по 6 категориям (12 096 рядов) на 1, 3, 6 и 12 месяцев. Поиск точек структурных сдвигов.

Главная трудность. В каждом ряду 24 точки (2023-01..2024-12). Перед прогнозом на 12 месяцев у модели меньше одного года истории. Свою годовую сезонность ряд оценить не может.



Рис. 1: Методология за минуту: четыре шага

1. **Общий ритм страны.** Сезонность и инфляция почти одинаковы для всех МО. Мы берём медиану по

2016 МО в каждом месяце. Так сезон оценивается по 2016 рядам, а не по 24 точкам одного ряда. Годовой рост на 12 месяцев вперёд берём из оборота розничной торговли Росстата.

2. **Отклонение города.** Остаток после шага 1 — медленный ряд без общего сезона. Его прогнозируют фундаментальные модели (FM), градиентный бустинг (GBM) и классические модели.
3. **Сложить и усреднить.** Прогноз = ритм страны × отклонение города. 35 моделей объединяет ансамбль. Веса для каждого горизонта выбираются **только на validation**.
4. **Сторож.** Детекторы сдвигов следят за отклонением города. Новости и реестр ЧС подсказывают, где искать сдвиг. Сигнал говорит: здесь ряд сломался, прогнозу по старой истории верить нельзя.

Результат на отложенном окне (test, 2024-07..12), MAE в рублях на жителя в месяц:

	h = 1	h = 3	h = 6	h = 12
Prophet (базовая модель организатора)	563	574	652	1361
Ансамбль (наше решение)	**306**	**435**	**446**	**658**
Снижение MAE к Prophet	−46%	−24%	−32%	−52%
ΔMAE, 95% ДИ двустороннего бутстрепа (МО × месяц)	[−511; −37]	[−302; +16]	[−353; −66]	[−1110; −430]
Значимо при 5%?	да	**нет**	да	да
R^2 на изменении (ансамбль)	0.42	0.59	0.53	−0.17
«Все категории», ансамбль / Prophet	837 / 1792	1147 / 1772	1181 / 2057	1695 / 4060

Ансамбль лучше Prophet на всех четырёх горизонтах по точечной оценке. Разница статистически значима на h = 1, 6 и 12. На h = 3 ансамбль выигрывает в 5 из 6 месяцев test, но 95% ДИ включает 0. На h = 3 ни одна из 35 моделей не лучше Prophet значимо (приложение Б). Метод ДИ — в §7.

Глоссарий.

Термин	Значение
origin o	месяц, в конце которого делается прогноз; модель видит только месяцы 0..o
горизонт h	на сколько месяцев вперёд прогноз; цель — месяц o + h
validation / test	целевые месяцы 2024-01..06 (выбор) / 2024-07..12 (итоговая оценка)
национальная компонента n	медиана log-расходов по всем МО категории в месяце: сезон и инфляция
локальная компонента d	log-расходы МО минус n: отклонение города от страны
FM, zero-shot	фундаментальная модель временных рядов; zero-shot — без дообучения на наших данных
ансамбль Caruana	жадный отбор моделей с возвращением; вес = доля шагов, на которых модель выбрана
R^2 на изменении	доля объяснённой вариации log(y_цель / y_origin), а не уровней
CPD, детектор	метод поиска точки структурного сдвига (change-point detection)
BOCPD, CUSUM	байесовский онлайн-детектор длины режима; кумулятивные суммы отклонений

2. Данные и честный протокол

Источник	Что берём	Лицензия / условия
СберИндекс, `consumption.parquet`	Средние безналичные расходы на жителя МО, руб./мес., 6 категорий, 2023-01..2024-12	CC BY-SA 4.0; только для конкурса (Положение §9.2.2)
СберИндекс, `market_access.parquet`, справочник МО	Индекс доступности рынков; регион, тип МО, координаты центра, полигоны	то же
Росстат, `Oborot_2025.xls`	Оборот розничной торговли РФ по месяцам, 2000-2025	открытые данные, со ссылкой на источник
Производственный календарь РФ	Рабочие и календарные дни месяца	пакет `holidays` (MIT) + постановления Правительства
GDELT 1.0 GKG	Темы, места и тональность новостей	свободное использование со ссылкой на GDELT
Реестр событий (наш, §6.2)	Режимы ЧС паводка 2024, ключевая ставка, тарифы: даты объявления и вступления, ссылки	официальные сайты МЧС, Правительства, регионов, Банка России

Источник	Что берём	Лицензия / условия
Портал СберИндекса, consumer-spending	Национальные расходы по месяцам 2018-2026	открытые данные; только проверка 2025 и приложение A

Панель: ряды со всеми 24 месяцами, 2016 МО × 6 категорий = **12 096 рядов**. Двенадцати регионов в данных нет (Белгородская, Курская обл., Краснодарский край и др.). «Все категории» не равны сумме пяти категорий (сумма ≈ 72%). Поэтому каждая категория — отдельный ряд. «Все категории» дают 59% суммы уровней и сильнее всего влияют на общий MAE.

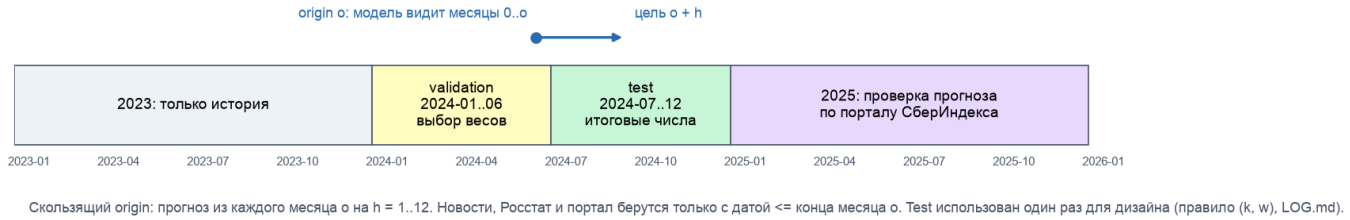


Рис. 2: Честный протокол: история, validation, test, проверка 2025

Протокол.

- **Скользящий origin.** Прогноз из месяца o на h месяцев вперёд использует только месяцы 0..o. Для каждой модели строится «куб» прогнозов: все origin 0..23 и все h = 1..12.
- **Два окна.** Validation: целевые месяцы 2024-01..06. Test: 2024-07..12. Веса ансамбля, параметры декомпозиции и выбор моделей делаются на validation.
- **Один взгляд на test в дизайне заголовка.** Правило «отдельные (k, w) для h ⩽ 3» (§3.1) мы ввели после первого просмотра test. Это одна итерация дизайна, она записана в `LOG.md`. Правило улучшило h = 1 и ухудшило h = 3; мы его не откатывали. Других выборов по test в заголовке нет. Всё, что сделано позже с просмотром test, вынесено в приложение A с пометкой «пост-hoc».
- **Внешние данные «as-of».** В origin o: Росстат с лагом 2 месяца (данные o ⩽ o − 2 уже опубликованы), новости с датой публикации ⩽ конца месяца o, реестр ЧС с датой объявления ⩽ конца месяца o. Национальная компонента месяца t использует только данные месяца t.
- **GBM** в origin o обучается только на парах (o', h') с целевым месяцем o' + h' ⩽ o.
- **Все модели на всех 12 096 рядах**, включая Prophet. Сравнение парное, на одних и тех же точках.
- **Тесты на утечку** (`make smoke`, `tests/test_leakage.py`): прогноз в origin o и тревога детектора в месяце t не меняются, если изменить данные после o (после t).

Ограничение протокола. В validation для h = 12 origin лежат в 2023-01..06 (1-6 месяцев истории). Веса для длинных горизонтов выбираются в режиме более короткой истории, чем на test.

3. Модели прогнозирования и выбор лучшей

3.1. Национальная и локальная компоненты

```
log y[i,t] = n[c,t] + d[i,t]
```

- **n[c,t]** — национальная компонента категории c: медиана log y по всем МО в месяце t.
- **d[i,t]** — локальная компонента МО. В ней нет общей сезонности. Она меняется медленно, а локальный шок (паводок, закрытие предприятия) даёт в ней ступеньку.

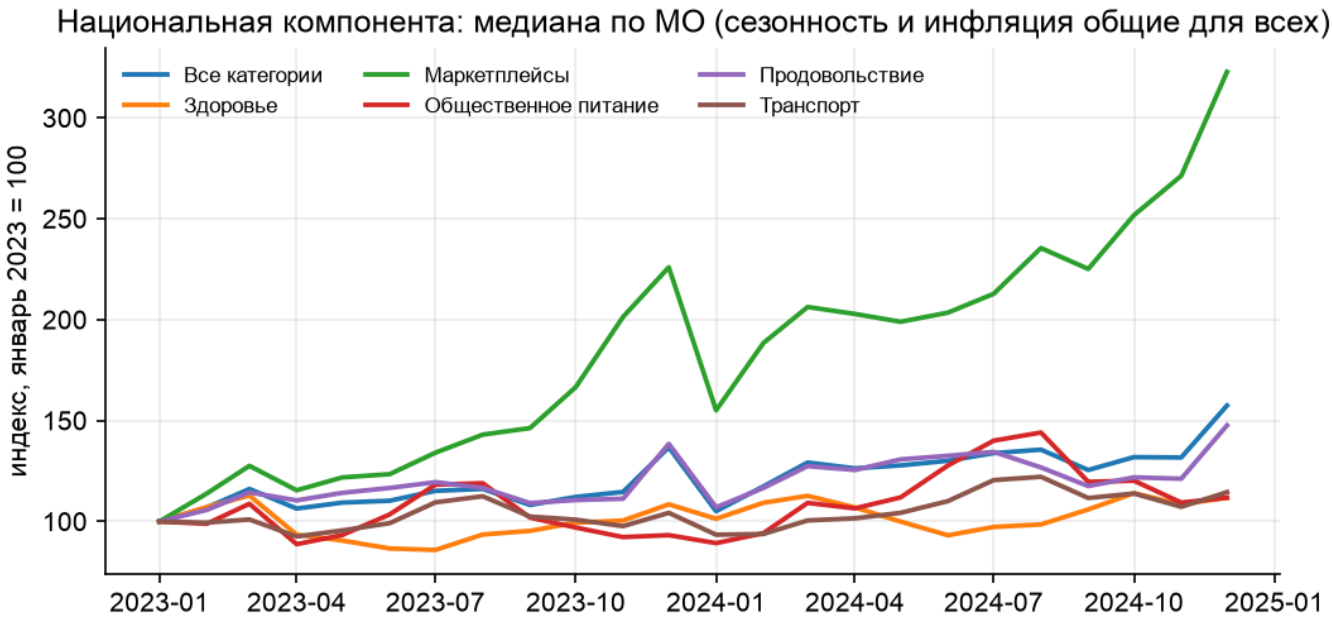


Рис. 3: Национальная компонента: сезонность общая для всех МО

Прогноз национальной компоненты (звёздочка * обозначает прогноз):

$$n*[c,T] = n[c,T-12] + G, \quad G = w \cdot YoY_own(k) + (1 - w) \cdot YoY_Росстат$$

YoY_own — средний годовой прирост n за последние k месяцев. YoY_Росстат — годовой прирост оборота розничной торговли со сдвигом 2 месяца. Пока у СберИндекса нет 12 месяцев истории (origin до 2023-12), G берётся только из Росстата. Так решается задача h = 12: годовой темп роста приходит из внешнего источника. Параметры на validation: k = 1; w = 0.75 для h = 1-2, 0.25 для h = 3, 0.5 для остальных. Сезонный профиль Росстата не подошёл (февраль −10% у Росстата, −1% у СберИндекса), поэтому из Росстата берём только темп роста. Итог: y* = exp(n* + d*).



Рис. 4: Архитектура решения

3.2. Модели

Группа	Модели	Роль
Наивные	naive, сезонная наивная × собственный YoY (k = 3), × национальный YoY, с учётом сдвигов	Опорные точки
Базовая организатора	**Prophet** (Фурье 3-го порядка, мультипликативная), отдельно на каждый ряд и origin	Цель «превзойти Prophet»
Классика	AutoETS, AutoTheta, AutoARIMA (statsforecast)	Сравнение
Первый бейзлайн	LightGBM v1 на log(y_T/y_o) без декомпозиции	Вклад архитектуры
Декомпозиция	n* + d; *d* = persistence / среднее 3 мес. / локальный сезон	Простая сильная модель

Группа	Модели	Роль
Фундаментальные	Chronos-Bolt S/B, Chronos-2, Chronos-2 мультивариантный, TimesFM 2.5, TiRex-2, Toto-2.0 22M/313M, Chronos-2 дообученный	§4
GBM	LightGBM и CatBoost на изменении d, прямой мульти-горизонтный	Признаки: лаги d, d год назад, региональный d, рост n*, календарь, FM, новости, CPD
Ансамбль	Отбор Caruana (жадный, с возвращением, 20 шагов), отдельно для каждого h, пул соседних h ± 1	Веса только по validation

3.3. Как выбрана итоговая модель

Правило выбора (зафиксировано до test): итоговый прогноз — ансамбль, потому что на validation он лучше каждой одиночной модели на всех h. Веса ансамбля подбираются на validation. Пул из 35 моделей зафиксирован в `configs/config.yaml`; `make ensemble` воспроизводит веса бит в бит.

h	Validation: лучшая одиночная	Validation: ансамбль*	Test: ансамбль	Ранг на test	Test: лучшая одиночная (после)	Test: Prophet
1	400 (TimesFM 2.5, декомп.)	301	306	10 из 36	296 (TimesFM 2.5, декомп.)	563
3	569 (Theta)	369	435	2 из 36	420 (LightGBM v1)	574
6	540 (TimesFM 2.5, декомп.)	484	446	**1** из 36	493 (TimesFM 2.5, декомп.)	652
12	993 (GBM база)	800	658	**1** из 36	691 (декомпозиция)	1361

* MAE ансамбля на validation посчитано на том же окне, где подобраны веса, и поэтому оптимистично.

Выбор на validation не гарантирует первое место на test. На h = 1 ансамбль 10-й из 36, но отставание от лучших одиночных моделей (296) не значимо: ΔMAE +9, 95% ДИ [−38; +67]. На h = 3 лучшая на test модель (LightGBM v1, 420) на validation была одной из худших (676); выбрать её заранее было нельзя. Разница с ней тоже не значима: +15 [−37; +76]. Мы не меняли выбор после test.

3.4. Сравнение на test

MAE на **test** (руб. на жителя в месяц). Жирным — лучшая модель в столбце. Полная таблица с validation, рангами, R^2 на изменении и ДИ для каждой модели — в приложении Б.

Модель	h = 1	h = 3	h = 6	h = 12
Наивная	624	864	1124	1289
Сезонная наивная × YoY	340	469	663	1289
Prophet	563	574	652	1361
AutoETS	634	807	1036	1383
AutoTheta	614	744	767	922
AutoARIMA	645	862	1094	1529
LightGBM v1 (без декомпозиции)	313	**420**	761	969
TimesFM 2.5, zero-shot на уровнях	559	797	1283	1691
Chronos-2, zero-shot на уровнях	613	877	1361	1817
Декомпозиция, d = persistence	318	566	526	691
TimesFM 2.5 на локальной компоненте	**296**	522	493	729
Chronos-2 мультивариантный на лок. комп.	302	531	532	772
Chronos-2 дообученный на лок. комп.	308	528	527	771
GBM LightGBM, все признаки	**296**	532	509	724
GBM CatBoost, все признаки	302	536	513	712
Ансамбль	306	435	**446**	**658**

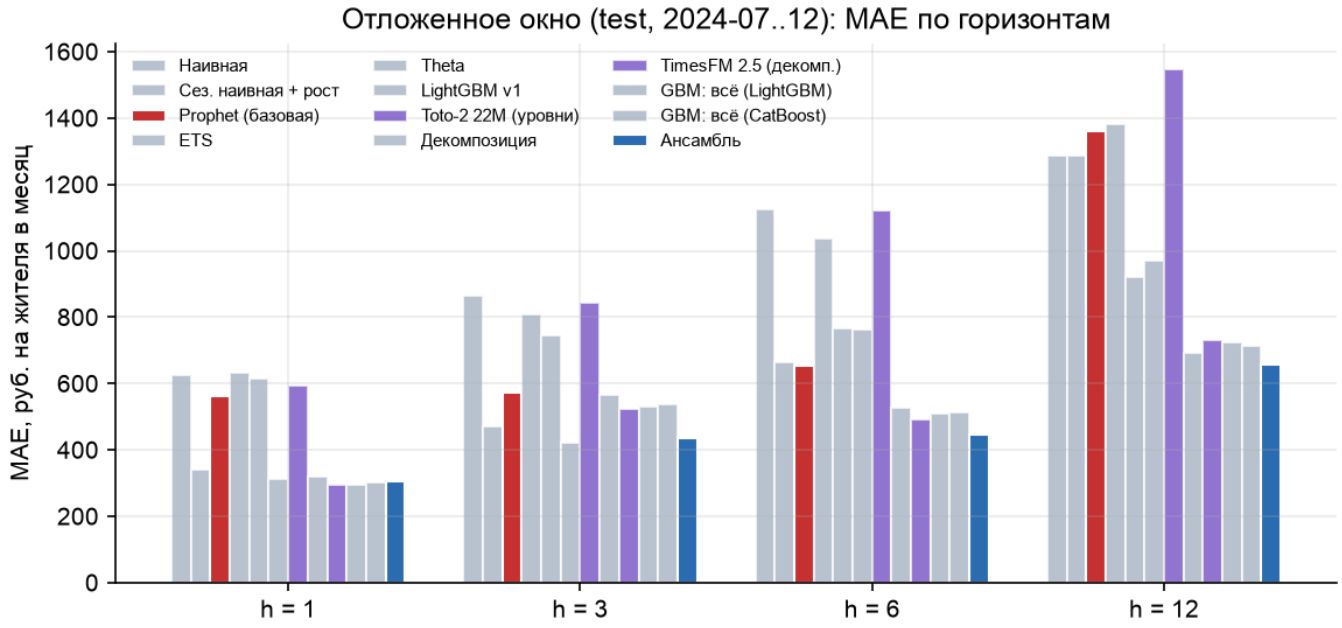


Рис. 5: MAE по горизонтам на test

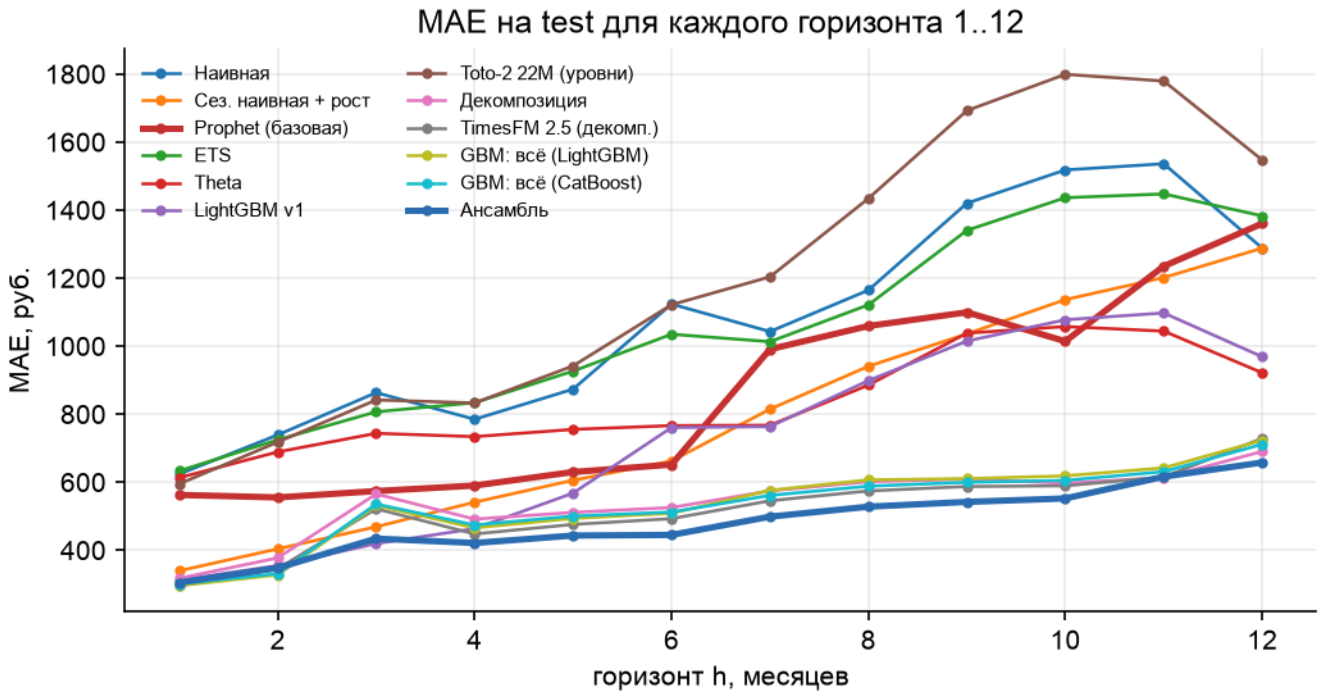


Рис. 6: MAE на test для каждого горизонта 1..12

Выводы.

- **Prophet проигрывает всем моделям на декомпозиции на всех горизонтах** по точечной оценке. На 24 точках он переоценивает тренд и плохо переносит декабрьский пик (смещение +6.8% на h = 12).
- **На h = 12 решает архитектура.** Модели без внешней информации о годовом росте (наивная, ETS, Prophet) дают 1289-1383. Национальная компонента с ростом Росстата снижает ошибку до 658-729.
- **На h = 1 сильные модели близки (296-318)**, различия между ними не значимы.

- **Состав ансамбля (веса validation):** h = 1 — сезонная наивная с учётом сдвигов 0.35, Theta 0.25, TimesFM 2.5 0.15; h = 6 — TimesFM 2.5 на локальной компоненте 0.55; h = 12 — GBM 0.45, Theta 0.25, Prophet 0.15. Prophet вошёл в ансамбль на h = 12: его ошибки слабо коррелируют с остальными.

3.5. Prophet — не соломенное чучело

Сильный результат против слабой настройки базовой модели ничего не стоит. Поэтому мы прогнали 10 конфигураций Prophet (по умолчанию; порядок Фурье 3 и 5; аддитивная и мультипликативная сезонность; обучение на log y; changepoint_prior_scale 0.01 / 0.05 / 0.5; плоский тренд; сжатая сезонность) на 400 МО (2400 рядов, по 80 МО из каждого квинтиля уровня), на тех же origin test. Лучшая конфигурация выбрана **по test** для каждого h — это заведомо в пользу Prophet.

TODO_PG

3.6. По категориям (test, MAE)

Категория	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12
Все категории	837 / 1147 / 1181 / 1695	1792 / 1772 / 2057 / 4060
Продовольствие	428 / 728 / 672 / 839	755 / 744 / 768 / 2070
Маркетплейсы	334 / 401 / 461 / **927**	526 / 547 / 593 / **825**
Транспорт	85 / 125 / 140 / 190	124 / 157 / 206 / 431
Здоровье	81 / 98 / 91 / 164	91 / 106 / 128 / 449
Общественное питание	69 / 110 / 127 / 136	90 / 120 / 161 / 332

Главная таблица (§1) — средний MAE по всем 12 096 рядам, то есть по 6 категориям вместе. Строка «Все категории» — отдельная категория с самыми крупными уровнями. Ансамбль лучше Prophet в 23 из 24 ячеек. Исключение — маркетплейсы на h = 12: рост категории ≈ +45% в год, а рост розничной торговли Росстата (≈ +15%) его занижает; трендовая экстраполяция Prophet здесь уместнее.

3.7. Абляция признаков GBM

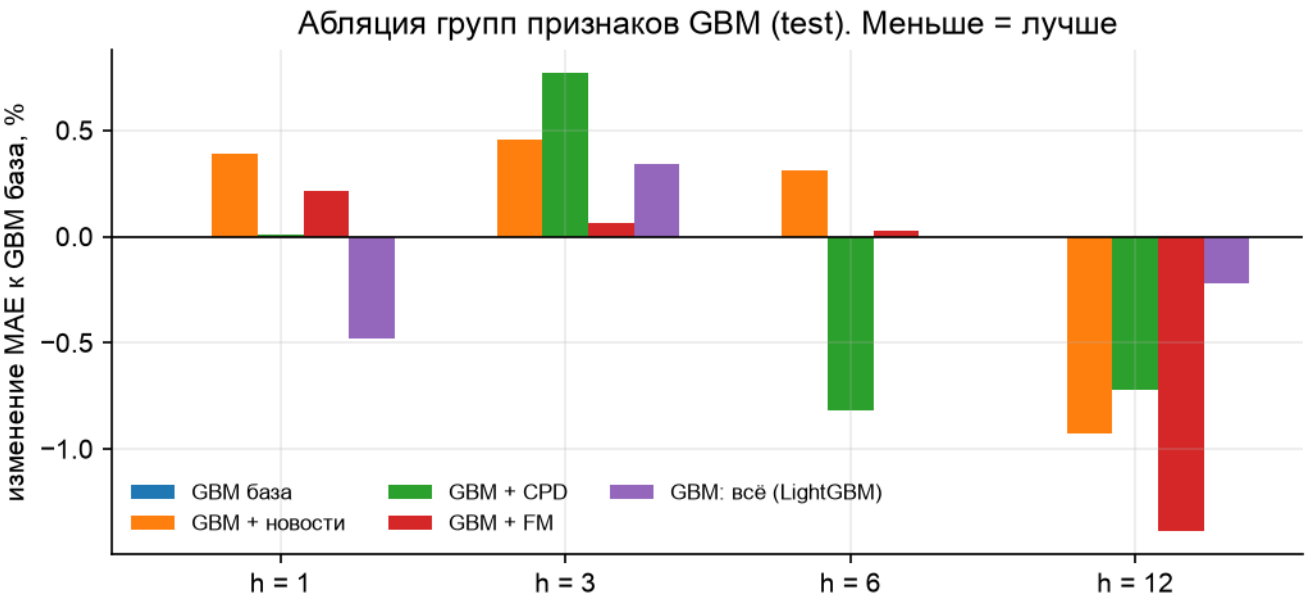


Рис. 7: Абляция групп признаков

Все варианты GBM отличаются от базового не более чем на 1.4%. Новости: +0.4% (h = 1), −0.9% (h = 12); на подвыборке МО с новостями в 3 месяцах до origin эффект тот же. Признаки сдвигов: −0.8% на h = 6. FM-

признаки: −1.4% на h = 12. Главные признаки (gain): регион, d год назад относительно origin, месяц цели, категория, изменение регионального d за 3 месяца.

4. Фундаментальные модели: где помогают и где нет

Только модели с открытыми весами Apache-2.0, запуск локально (Apple M3 Pro, MPS). Moirai (CC BY-NC) и TimesFM 3.0 (некоммерческая лицензия) исключены: Положение §10.3 запрещает технологии, на которые нужны платные права. Способы применения:

1. **Zero-shot на уровнях** — «из коробки».
2. **Zero-shot на локальной компоненте** exp(d); национальная компонента добавляется обратно. Chronos-2 мультивариантный: 6 категорий одного МО как одна группа.
3. **Признаки для GBM**: медианный прогноз FM для d и ширина 80% интервала.
4. **Дообучение Chronos-2** (полное, 300 шагов, lr = 1e-5) на локальной компоненте, строго каузально: модель, дообученная на месяцах 0..c, применяется к origin c..(следующая отсечка − 1). Отсечки 2023-12, 2024-06, 2024-12.

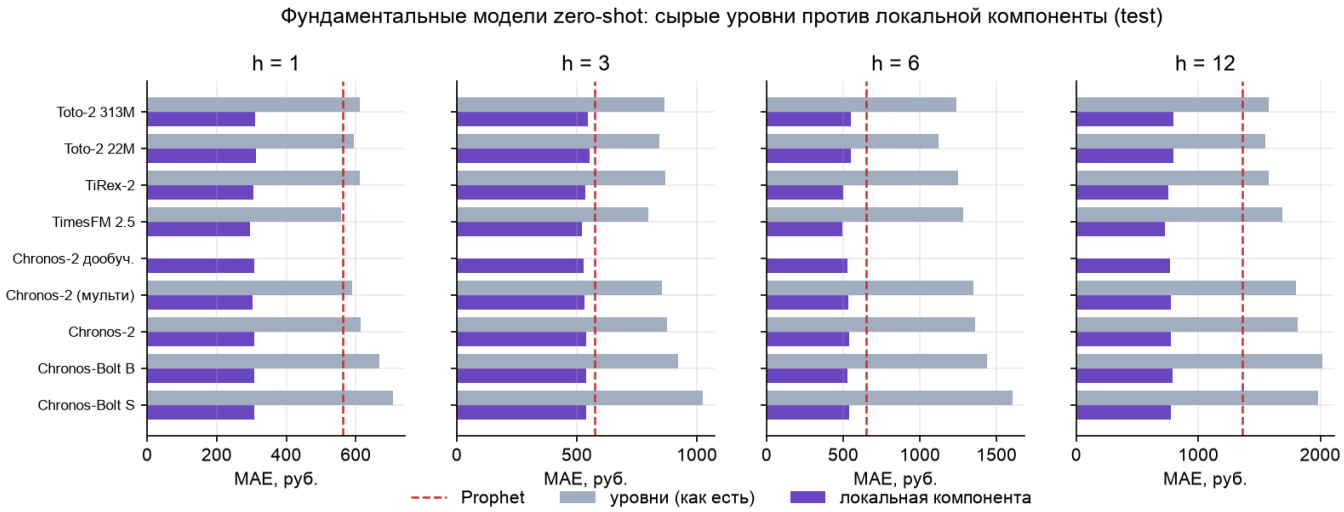


Рис. 8: FM: сырые уровни против локальной компоненты

FM (test, MAE)	уровни h = 1 / 3 / 6 / 12	лок. компонента h = 1 / 3 / 6 / 12	покрытие 80% инт., h = 1 / 12	время, с
Chronos-Bolt S	707 / 1024 / 1603 / 1986	307 / 538 / 539 / 774	0.82 / 0.88	37
Chronos-Bolt B	668 / 920 / 1439 / 2015	307 / 538 / 529 / 787	0.83 / 0.89	75
Chronos-2	613 / 877 / 1361 / 1817	307 / 539 / 540 / 776	0.83 / 0.90	102
Chronos-2 мультивар.	588 / 854 / 1351 / 1802	302 / 531 / 532 / 772	0.81 / 0.91	104
Chronos-2 дообуч.	—	308 / 528 / 527 / 771	0.88 / 0.89	982
TimesFM 2.5	559 / 797 / 1283 / 1691	**296 / 522 / 493 / 729**	0.82 / 0.73	1028
TiRex-2	612 / 870 / 1250 / 1575	305 / 535 / 502 / 757	0.80 / 0.76	3220
Toto-2.0 22M	595 / 842 / 1122 / 1548	313 / 552 / 550 / 799	0.74 / 0.88	28
Toto-2.0 313M	611 / 866 / 1240 / 1576	310 / 548 / 548 / 794	0.82 / 0.87	356

Время — полный прогон 24 origin × 12 096 рядов на Apple M3 Pro (MPS).

Где FM помогают	Где FM не помогают
На локальной компоненте: MAE в 1.5-3 раза ниже, чем на уровнях; лучше Prophet на всех h	На сырых коротких рядах: при h ⩾ 3 все 8 вариантов хуже Prophet и на уровне наивной

Где FM помогают	Где FM не помогают
Средний горизонт: в ансамбле FM дают −5.9% MAE на h = 6 (446 против 473 без FM)	h = 12: FM экстраполируют локальный тренд (TimesFM 729 против persistence 691)
h = 1-3: TimesFM лучше persistence (296 против 318 на h = 1)	В ансамбле на h = 3 веса FM не перенеслись с validation (+2.4% MAE)
Chronos-2 мультивариантный: совместная динамика категорий (302 против 307)	Как признаки GBM: ±1%, GBM уже видит те же лаги
Дообучение Chronos-2: −2% на h = 3-6, покрытие на h = 1 0.88 против 0.83	Дообучение дорого (16 мин) при 24 месяцах данных; эффект скромный
Семейство Chronos: откалиброванные 80% интервалы (0.81-0.91)	TimesFM 2.5: узкие интервалы на h = 12 (покрытие 0.73)

Причина провала на уровнях: ряды из 7-23 точек с сильным декабрьским пиком. Модель не знает календарь и не может выучить сезон из одного года. Декомпозиция убирает сезон до FM, и FM получает то, что умеет прогнозировать: гладкий ряд без календарного эффекта.

5. Структурные сдвиги

5.1. Методы

Сдвиг ищем в локальной компоненте d (сезон и инфляция уже убраны). Ряд стандартизуется робастным масштабом месячных изменений в 2023 г. (MAD).

Детектор	Идея
Скачок (spike)	$\|\Delta z_t\| > k$: скачок за один месяц
CUSUM	двусторонние кумулятивные суммы отклонений от уровня 2023 г., перезапуск после тревоги
PELT, BinSeg, Window (ruptures)	переподгонка сегментации на z[0..t]; тревога, если последний разрыв свежий
BOCPD (Adams, MacKay 2007)	апостериорное распределение длины текущего режима, модель Normal-Gamma, hazard 0.05
BOCPD-подтв.	то же, но новый режим должен продержаться 2 месяца (устойчив к выбросам)
CUSUM по остаткам	CUSUM на ошибках локальной сезонной наивной модели
CUSUM / BOCPD + новости	порог CUSUM × 0.6 или hazard BOCPD × 5 в месяц новостного всплеска и следующий

Офлайн-методы (весь ряд сразу): PELT, BinSeg, BottomUp, Window, KernelCPD (rbf), MAP-сегментация BOCPD.

Честное сравнение. У каждого онлайн-детектора один порог. Его калибруем на половине рядов так, чтобы частота ложных тревог на чистых рядах была $\leqslant 2\%$ на ряд-месяц. Метрики считаем на другой половине. Без такой калибровки любой детектор можно сделать сколь угодно чувствительным.

Синтетика. В реальные ряды d («Все категории», 400 МО) вставляем в случайный месяц 2024-02..10 ступеньку 5/10/20/30%, излом тренда 2/4% в месяц или одномесячный выброс 20% (выброс — не структурный сдвиг: хороший детектор его игнорирует). Метрики: recall и precision с допуском 2 месяца, F1, средняя задержка, частота ложных тревог.

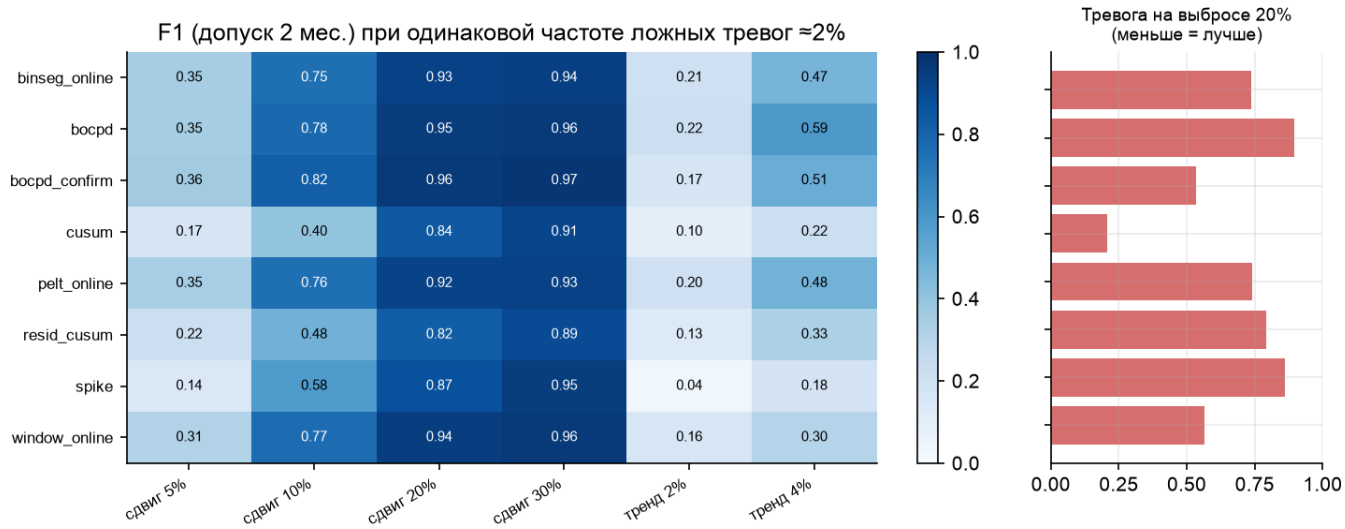


Рис. 9: F1 детекторов при равной частоте ложных тревог

5.2. Таблица решений

Все детекторы откалиброваны на одну частоту ложных тревог (≈ 1-2%), поэтому recall в таблице — это recall при фиксированной частоте ложных тревог.

Детектор	F1, сдвиг 5 / 10 / 20%	Recall при 10%	Задержка, мес.	Тревога на выбросе	Ложные тревоги	Орск: первая тревога	Lift: события GDELT	Паводки из реестра: доля МО с тревогой (lift)
BOCPD-подтв.	0.36 / 0.82 / 0.96	0.74	1.2	0.54	1.3%	нет	0.6	0% (0.0)
BOCPD	0.35 / 0.78 / 0.95	0.69	0.3	0.90	1.6%	нет	0.0	0% (0.0)
PELT	0.35 / 0.76 / 0.92	0.68	0.7	0.74	1.5%	нет	0.4	0% (0.0)
BinSeg	0.35 / 0.75 / 0.93	0.67	0.7	0.74	1.4%	нет	0.4	0% (0.0)
Window	0.31 / 0.77 / 0.94	0.70	1.6	0.56	1.2%	нет	0.9	8% (1.8)
Скачок (spike)	0.14 / 0.58 / 0.87	0.45	0.0	0.86	0.8%	нет	0.0	0% (0.0)
CUSUM по остаткам	0.22 / 0.48 / 0.82	0.36	0.3	0.79	1.3%	нет	1.2	0% (0.0)
CUSUM	0.17 / 0.40 / 0.84	0.36	1.4	0.21	1.4%	2024-06	1.5	12% (2.3)
CUSUM + новости	полусинтетика: 0.43	—	1.1	—	1.6%	2024-05	1.5	12% (2.3)
BOCPD + новости	полусинтетика: 0.73	—	0.4	—	1.6%	нет	1.2	0% (0.0)

Паводки из реестра: 26 МО с режимом ЧС в 2024 г.; доля МО с тревогой в 0..2 месяца после месяца паводка; базовая частота такого окна у CUSUM 5.1%, у BOCPD 3.1%. Приморье 2023 не входит: онлайн-детекторы запускаются с 2024-01.

Офлайн (весь ряд, допуск 1 месяц), F1 при сдвиге 10 / 20%: Window 0.71 / 0.82, PELT 0.66 / 0.76, BinSeg 0.66 / 0.77, BOCPD-MAP 0.59 / 0.69, BottomUp 0.58 / 0.68, KernelCPD 0.57 / 0.72.

Выбор для мониторинга: BOCPD с подтверждением. Правило: максимум F1 при сдвиге 10% при равной частоте ложных тревог, при условии, что детектор реагирует на одномесячный выброс реже, чем в 60% случаев. BOCPD-подтв. даёт лучший F1 (0.82 при 10%, 0.96 при 20%), лучший recall (0.74), ложные тревоги 1.3%, выбросы 54% (у BOCPD 90%). Цена — задержка ≈ 1.2 месяца. **Быстрый сигнал** без подтверждения — BOCPD (задержка 0.3 месяца). **Проверка гипотез по реестру ЧС и новостям** — CUSUM с prior: на реальных событиях он единственный стабильно выше базовой частоты. Сдвиг 5% (≈ месячный шум ряда) не обнаруживает надёжно ни один метод (F1 ⩽ 0.36): это предел данных.

Почему победитель синтетики слабее на реальных событиях. На событиях GDELT и на паводках из реестра BOCPD и BOCPD-подтв. почти не поднимают тревог (lift 0-0.6), CUSUM — 1.5 и 2.3 (на паводках 3 из 26 МО, поэтому оценка грубая). Причины: (1) большинство событий не сдвигает расходы на жителя заметно: event study (§6.5) не находит среднего эффекта; (2) реальные сдвиги около +7% (Орск) лежат у предела обнаружения, где BOCPD без накопления не срабатывает, а CUSUM накапливает отклонение; (3) синтетика содержит чистые ступеньки, а реальный шок в Орске — временный всплеск на 3 месяца. Поэтому синтетика выбирает детектор для мониторинга, а реальные события — детектор для проверки гипотез.

5.3. Реальные данные

Тревоги по месяцам 2024 г. (2016 МО, «Все категории»): BOCPD 13-53 в месяц, PELT 26-66; у CUSUM число тревог растёт к концу года (с 0 до 91): он накапливает медленный локальный дрейф. Всплеск CUSUM по остаткам в 2024-04 (100 тревог) — артефакт: его эталон «год назад» — апрель 2023, где у многих МО разрыв в исходных данных (в офлайн-PELT 341 разрыв из 986 приходится на 2023-04).

Паводок в Орске (прорыв дамбы 5 апреля 2024). Локальная компонента Орска выросла с +16% к национальному уровню (апрель) до +24% (май), затем вернулась к +16-17% к августу. В GDELT за апрель 2024 об Орске 1 367 документов, 1 336 с темой «наводнение» (обычно 0-10 в месяц). Сдвиг +7% обычные детекторы не видят; CUSUM поднимает тревогу в июне, **CUSUM с новостным prior — в мае**, на месяц раньше.



Рис. 10: Орск: данные, тревоги, новости

5.4. Как учёт сдвигов улучшает прогноз

Модели с «памятью» о прошлом годе (сезонная наивная, Prophet, признак «d год назад» в GBM) после сдвига опираются на старый уровень. Поправка: после тревоги точка сдвига уточняется (разбиение с минимальной суммой квадратов в окне [тревога − 3; тревога]), история до сдвига переносится на новый уровень, и только потом считается прогноз.

Синтетика, сдвиг 15%, MAE (руб.)	h = 1	h = 2	h = 3	h = 6
Локальная сезонная модель (YoY за 3 мес.)	947	1022	1164	1567
То же с поправкой на сдвиг	**819**	**920**	**1032**	**1397**
Изменение	−14%	−10%	−11%	−11%

На реальных данных (test) поправка затрагивает 15% рядов на h = 1 и даёт на них −0.3% MAE на h = 1 и −1.3% на h = 3. Эта модель получила наибольший вес в ансамбле на h = 1 (0.35).

6. Интеграция новостей и событий

6.1. GDELT

1. **Сбор.** Ежедневные файлы GDELT GKG 1.0 за 2022-12..2024-12 (761 день, ≈ 33 ГБ; 2023-03-23 на сервере отсутствует). Документы с городом или регионом РФ: **1,55 млн**.
2. **Привязка к МО.** GDELT геокодирует шумно (украинские топонимы попадают в российские регионы, фамилии распознаются как сёла). Точку GDELT привязываем к МО, только если (а) центр МО в 30 км и (б) транслитерация названия начинается с тех же 5 букв. Так 942 места привязаны к 811 МО; в панели новости есть у 575 МО. Остальные места — на уровне региона (ADM1, 81 регион). Таблица привязки для аудита: `data/external/news_location_match.csv`.
3. **Темы.** Группы тем GKG: бедствие, наводнение, пожар, экономика-негатив, цены, инфраструктура, безопасность. Тему MANMADE_DISASTER_IMPLIED исключаем: GDELT ставит её на большинство военных текстов.
4. **Признаки** на месяц t: log(1 + число документов), «сюрприз» (отклонение от среднего за 6 месяцев), число документов по темам, тональность; то же для региона.

6.2. Реестр событий из официальных источников

GDELT — англоязычные СМИ, малые МО почти не упоминаются. Поэтому мы вручную собрали реестр событий из русскоязычных официальных источников: режимы ЧС паводка весны 2024 (сайты МЧС, правительств регионов), решения Банка России по ключевой ставке, индексация тарифов ЖКХ, конец массовой льготной ипотеки. В каждой строке: дата объявления, дата вступления в силу, МО или регион, ожидаемый знак эффекта, ссылка на источник, признак «проверено» (страница открыта и подтверждает дату). Файл: `data/external/event_registry.csv`. Тексты страниц использовались только как данные: даты, названия МО, номера актов.

Реестр: **71 строк, все проверены** по странице источника: 48 строк о паводках (6 регионов, 42 МО панели, названных в постановлениях о ЧС), 17 решений Банка России по ключевой ставке, индексация тарифов ЖКХ с 2024-07-01, конец массовой льготной ипотеки 2024-07-01, 4 строки о лесных пожарах. Источники: publication.pravo.gov.ru (38 строк: указы и постановления губернаторов о ЧС), cbr.ru (17), mchs.gov.ru, РИА Новости и Интерфакс (даты фактических событий: прорыв дамбы, пик воды). Две даты мы перепроверили вручную повторно (прорыв дамбы в Орске 2024-04-05; уровень Тобола в Кургане 850 см 2024-04-17). Использование: (а) разметка МО для event study; (б) проверка детекторов на реальных событиях (§5.2).

6.3. Правило согласования новостей с данными

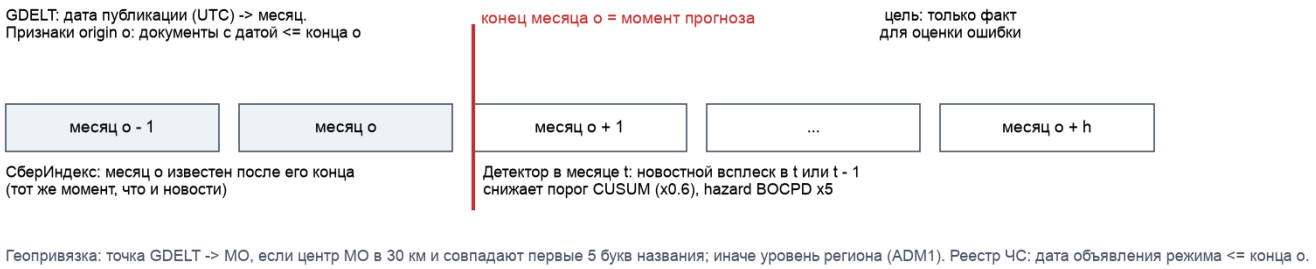


Рис. 11: Согласование по времени: что известно в момент прогноза

Что	Правило
Дата документа	GDELT `DATE` = дата публикации (UTC). Документ относится к календарному месяцу публикации
Признаки для origin o	документы с датой ⩽ конца месяца o. Месяц o СберИндекса тоже известен только после его конца, поэтому новости и расходы имеют одинаковый момент «as-of»
Prior детектора в месяце t	всплеск новостей в месяце t или t − 1 (оба известны в конце t)
Реестр ЧС	событие используется с месяца даты **объявления**; дата вступления — для event study
Место	точка GDELT -> МО (30 км + 5 букв названия), иначе регион; реестр — МО из официального акта
Будущее	ни один признак не использует документы после конца месяца o

Событие и публикация — не одно и то же. Новость о паводке выходит в день события или позже; акт о ЧС — в день объявления режима. Для прогноза важна дата, когда информация стала доступна, поэтому в признаках используется дата публикации, а не дата события.

6.4. Что дают новости: результаты, включая нулевые

Использование	Результат
Признаки GBM	эффект на MAE ±1% (§3.7): новости редки (575 из 2016 МО) и англоязычны
Prior для CUSUM, Орск	тревога в мае 2024 вместо июня, на месяц раньше
Prior, полусинтетика (сдвиг 10%)	CUSUM + новости F1 0.43 против 0.38, задержка 1.1 против 1.5 мес.; BOCPD + новости 0.73 против 0.78 (хуже: рост hazard добавляет ложные тревоги)
Разметка событий GDELT (53 МО-месяца)	lift CUSUM 1.5, CUSUM + новости 1.5, BOCPD 0
Event study по реестру ЧС	§6.5

Вывод: новостной prior полезен медленному детектору (CUSUM) и не нужен быстрому (BOCPD). В прогнозе уровня новости почти ничего не дают; их ценность — в поиске и объяснении шоков.

6.5. Event study: паводок 2024

Вопрос: меняются ли расходы на жителя в МО, которые официальный акт о ЧС назвал зоной паводка, по сравнению с другими МО того же региона? Дизайн:

- **Опыт:** 42 МО из постановлений о ЧС: Приморье (тайфун «Ханун», 2023-08, 16 МО), Оренбургская (2024-04, 4), Курганская (2024-04, 6), Тюменская (2024-04, 13), Омская (2024-05, 3) области.
- **Контроль:** остальные 111 МО тех же регионов. Тот же национальный шок, та же региональная политика.

- **Исход:** локальная компонента d (национальная сезонность и инфляция уже убраны), 6 категорий.
- **Эффект:** разность разностей к среднему за 3 месяца до события, с отдельным месяцем события для каждого региона (stacked DiD). Основная величина — средний эффект за месяцы 0..2.
- **Вывод о значимости:** перестановочный тест (метка «опыт» случайно переставляется внутри региона, 1000 раз), поправка Холма на 6 категорий. 95% ДИ — бутстреп МО внутри регионов.
- **Плацебо по датам:** тот же дизайн с месяцем события, сдвинутым на 4 и более месяцев (23 ложные даты).

Категория	Эффект 0..2 мес.	95% ДИ	p (перестановки)	p (Холм)	Доля ложных дат с эффектом не меньше
Все категории	+0.7%	[−0.5%; +1.7%]	0.25	1.00	0.52
Продовольствие	+0.1%	[−0.9%; +1.2%]	0.78	1.00	0.87
Маркетплейсы	+0.7%	[−2.6%; +4.2%]	0.69	1.00	0.83
Транспорт	−1.9%	[−4.3%; +0.5%]	0.13	0.63	0.39
Здоровье	+0.2%	[−2.7%; +2.9%]	0.90	1.00	0.87
Общественное питание	+7.1%	[−0.8%; +15.3%]	0.09	0.55	0.17

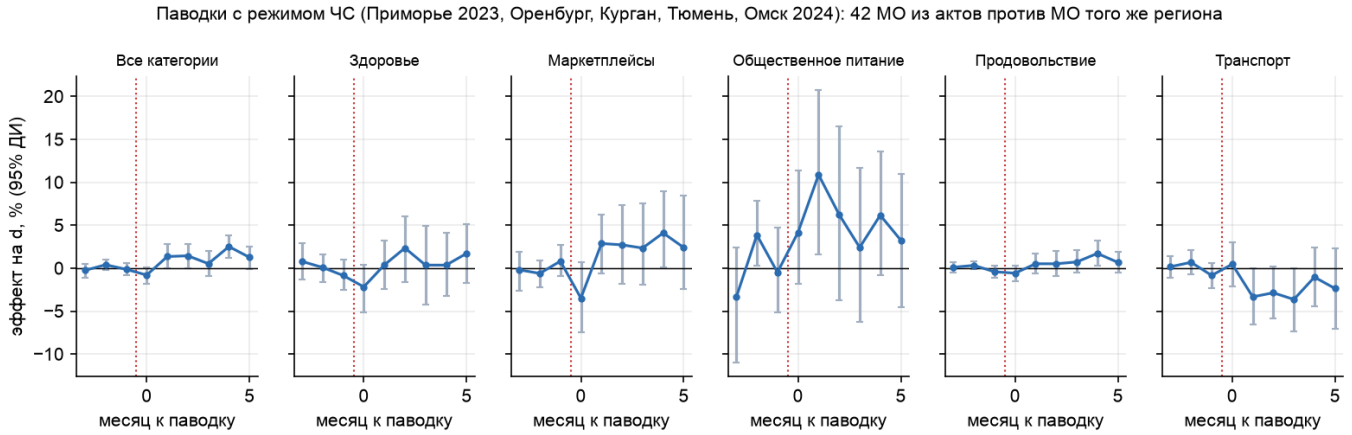


Рис. 12: Event study паводков: эффект по месяцам и категориям

Результат — нулевой, и мы его публикуем. Ни в одной категории средний эффект не значим после поправки Холма. Для «Всех категорий» эффект +0.7% [−0.5%; +1.7%], p = 0.25; ложные даты дают эффект такого же размера в половине случаев. Наибольшая точечная оценка — общепит (+7.1%, p = 0.09, после поправки 0.55). Расходы в Орске выросли на 7% (§5.3), но среднее по 42 МО из актов о ЧС эффекта не показывает: акт называет МО, где пострадала часть территории, а расходы на жителя считаются по всему МО. Практический вывод: факт режима ЧС сам по себе не предсказывает сдвиг расходов; нужен масштаб ущерба (число пострадавших домов на жителя). Это ограничение и направление развития реестра.

7. Метрики

Метрика	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12	Что показывает
MAE, руб.	306 / 435 / 446 / 658	563 / 574 / 652 / 1361	средняя ошибка в рублях (обязательная)
R^2 (уровни)	0.998 / 0.996 / 0.995 / 0.991	0.991 / 0.992 / 0.990 / 0.954	почти всегда ≈ 1: уровни МО сильно различаются
R^2 на изменении log(y_T/y_o)	0.42 / 0.59 / 0.53 / −0.17	−2.6 / −0.86 / −8.4 / −167	объясняет ли модель динамику
WAPE	3.3% / 4.7% / 4.9% / 7.2%	6.1% / 6.3% / 7.1% / 14.8%	ошибка в % от суммы факта

Метрика	Ансамбль h = 1 / 3 / 6 / 12	Prophet h = 1 / 3 / 6 / 12	Что показывает
MdAPE	3.7% / 5.3% / 5.4% / 8.1%	5.6% / 6.3% / 7.5% / 16.7%	типичная ошибка ряда в %
Смещение	+0.7% / +1.2% / −0.4% / +0.3%	−0.6% / −0.5% / −1.6% / +6.8%	систематический сдвиг прогноза
Покрытие 80% интервала	0.81 / 0.74 / 0.67 / 0.76	0.87 / 0.90 / 0.87 / 0.93	честность интервала (цель 0.80)
WIS (80% интервал + медиана), руб.	211 / 302 / 333 / 516	485 / 448 / 503 / 1205	точность интервала и медианы вместе

Интерпретация. R^2 на уровнях не различает модели. R^2 на изменении показывает, что ансамбль объясняет 42-59% вариации изменения расходов за 1-6 месяцев. На h = 12 он отрицательный: годовой рост в основном общий для всех МО, а ошибка оценки общего роста (≈ 1 п.п.) больше, чем различия между МО. Prophet на изменении хуже константы на всех горизонтах.

Интервалы. 80% интервал строится по квантилям 10% и 90% логарифмических ошибок на **validation** (по горизонту и категории) и проверяется на test. У ансамбля покрытие ниже номинала на h = 3-12 (0.67-0.76): ошибки на test больше, чем на validation. У Prophet покрытие выше номинала, потому что его ошибки на validation велики и интервалы широкие. WIS учитывает обе стороны; у ансамбля он в 1.5-2.3 раза ниже.

Значимость. ΔMAE = MAE(модель) − MAE(Prophet) на одних и тех же рядах и месяцах. 95% ДИ — **двусторонний бутстреп**: независимо пересэмплируются МО (6 категорий МО вместе) и целевые месяцы test, 1000 повторов. Бутстреп только по МО даёт слишком узкие ДИ: ошибки всех МО в одном месяце связаны через общую национальную компоненту. Дополнительно — тест Диболда-Мариано с поправкой HLN по 6 месячным разностям (при 6 месяцах мощность низкая; для h ⩾ 6 не определён).

Ансамбль против Prophet	h = 1	h = 3	h = 6	h = 12
ΔMAE, руб.	−258	−140	−207	−702
95% ДИ, двусторонний бутстреп	[−511; −37]	[−302; +16]	[−353; −66]	[−1110; −430]
95% ДИ, только по МО (для сравнения)	[−263; −253]	[−145; −134]	[−215; −199]	[−722; −682]
DM-HLN, p	0.11	0.44	—	0.003
Месяцев test, где ансамбль лучше	5 из 6	5 из 6	5 из 6	6 из 6

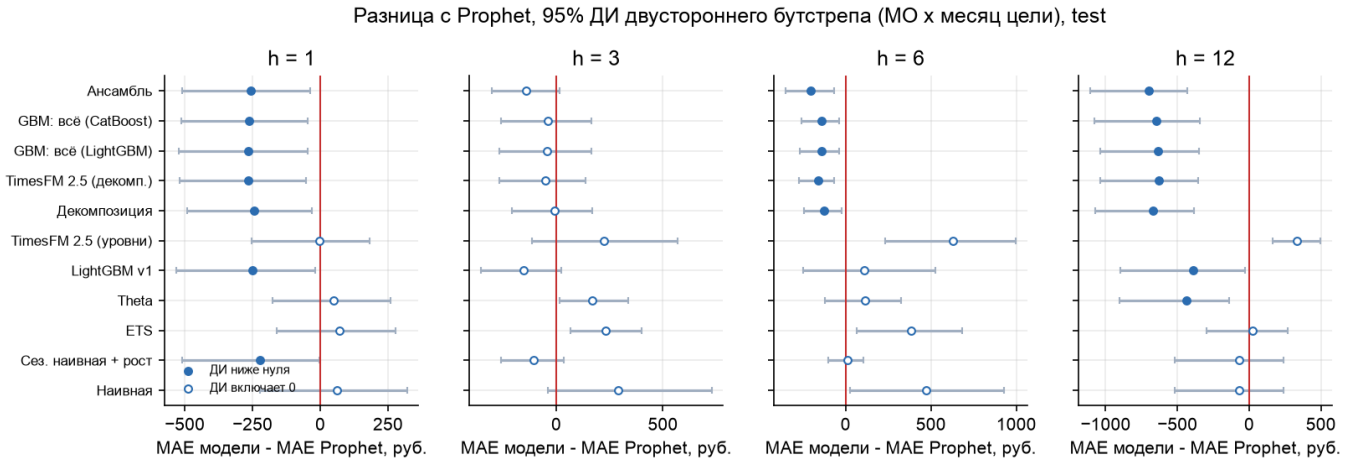


Рис. 13: Разница с Prophet, двусторонний 95% ДИ

8. Выводы, практическая ценность, проверка на 2025

8.1. Прогноз на 2025 год

Финальный прогноз (origin 2024-12, h = 1..12) делает тот же ансамбль; веса выбраны заново на validation + test. 80% интервал — квантили 10% и 90% логарифмических ошибок ансамбля на test по горизонту и категории. Файл `results/forecast_2025.csv` (145 152 строки).

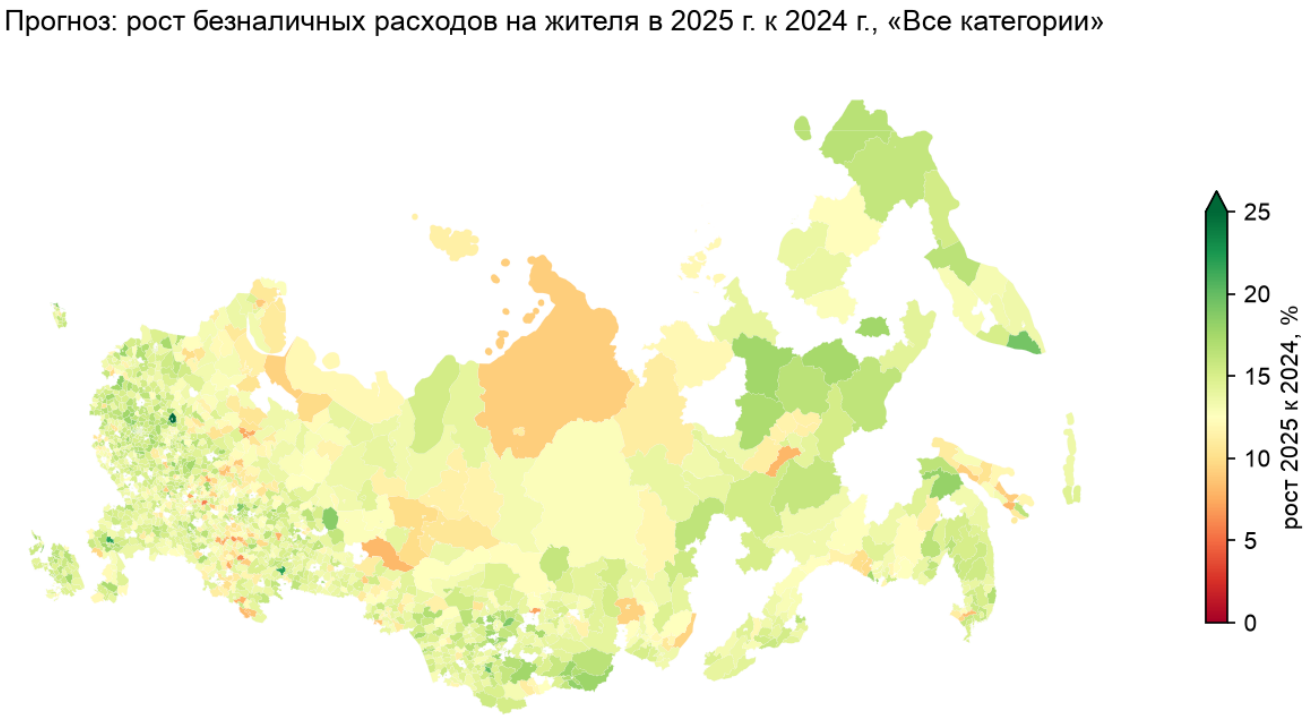


Рис. 14: Прогноз роста 2025 к 2024

Медианный прогноз декабря 2025 к декабрю 2024: все категории +10.5%, маркетплейсы +24.6%, общественное питание +13.6%, транспорт +9.9%, здоровье +7.1%, продовольствие +6.2%.

8.2. Проверка прогноза 2025 на факте

Прогноз 2025 сделан в конце 2024 г. Сейчас (октябрь 2026) на портале СберИндекса есть национальные расходы за 2025 год. Это единственная проверка на данных, которых не видел ни один этап разработки. Панель — медиана по МО на жителя, портал — сумма по РФ. Поэтому сравниваем годовой прирост log(2025-m / 2024-m), а не уровни.

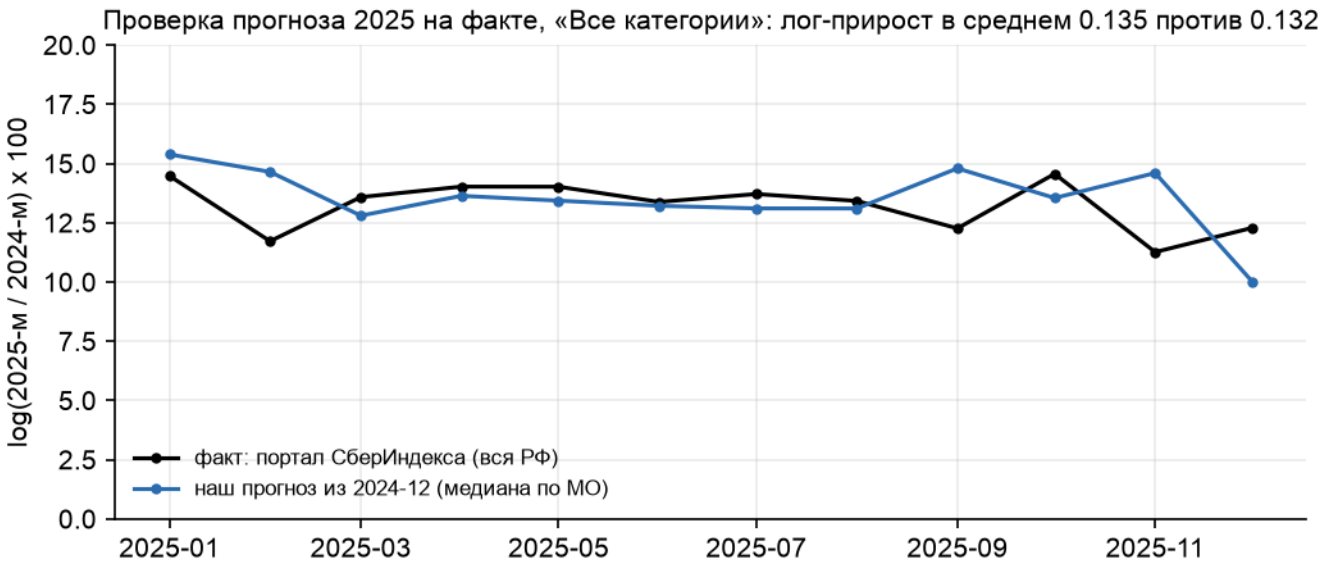


Рис. 15: Проверка прогноза 2025 на портале СберИндекса

«Все категории»	Прогноз / панель	Факт портала	Разница
Годовой log-прирост 2025, среднее за 12 месяцев	0.135 (+14.5%)	0.132 (+14.1%)	+0.3 п.п.
Тот же прирост за 2024: факт панели против портала	0.139	0.149	−1.0 п.п.

Для «Всех категорий» прогноз роста 2025 совпал с фактом с точностью 0.3 п.п.; источники в 2024 г. расходятся на 1.0 п.п., то есть сравнение корректно. По отдельным категориям сравнение грубое: типы портала не совпадают с категориями панели (у маркетплейсов разница источников за 2024 г. 28.7 п.п.; у общепита на портале в 2025 г. скачок +40%).

8.3. Практические выводы

- **Для прогноза по МО на короткой истории главное — отделить общую динамику.** Декомпозиция с persistence уже снижает MAE к Prophet на 44% / 1% / 19% / 49%.
- **Годовой горизонт требует внешнего источника роста.** Без него h = 12 не прогнозируется. Проверка 2025 показывает, что внешний рост (Росстат) переносится на следующий год.
- **Фундаментальные модели стоит применять к очищенному от сезонности сигналу**, а не к «сырым» коротким рядам; лучший выигрыш — на среднем горизонте (h = 6).
- **Мониторинг шоков.** BOCPD с подтверждением даёт устойчивые сигналы с задержкой ~1 месяц; CUSUM с prior из новостей ловит слабый сдвиг в Орске на месяц раньше.
- **Локальный шок не обязательно долгий.** В Орске всплеск расходов после паводка продлился ~3 месяца; прогноз после сдвига должен переоценивать уровень, а не продлевать скачок.

9. Ограничения

- 24 месяца: окно validation для h = 12 короче по истории, чем test (§2).
- Один взгляд на test в дизайне заголовка: правило «отдельные (k, w) для h ⩽ 3» (§2, `LOG.md`). Пост-hoc эксперименты (приложение A) смотрели на test ещё 5 раз и в заголовок не входят.
- На h = 3 выигрыш у Prophet не значим (§7). Все ДИ построены по 6 месяцам test: это мало.
- Нет настоящей разметки шоков; проверка — по реестру ЧС, новостям и примерам.
- GDELT GKG 1.0 — только англоязычные источники; реестр ЧС собран вручную и неполон.
- Фундаментальные модели обучались на открытых корпусах; мы не можем исключить, что в них есть ряды за 2024 г. (не данные СберИндекса).
- Проверка 2025 — одна национальная цифра для «Всех категорий»; факт 2025 по МО недоступен.

10. Воспроизводимость

```
make setup          # uv + Python 3.13, точные версии из requirements.lock.txt
make data           # данные СберИндекса, справочник МО, Росстат, портал (≈ 50 МБ)
make quick          # свежий клон: тесты на утечку + пересчёт всех главных чисел (≈ 2 мин)
make reproduce      # полный прогон, 4–5 ч
```

- `make quick` на свежем клоне запускает `make smoke` (тесты на утечку и проверка формы, секунды) и `make verify`: пересчёт MAE, R^2, R^2 на изменении, MAE по категориям, ДИ двустороннего бутстрепа, DM-HLN и прогноза 2025 из `results/verify/cubes.npz` (8 МБ: прогнозы 8 ключевых моделей на test) со сверкой с таблицами `results/metrics/`. Если есть полный кэш `results/cache/`, `make quick` пересобирает ансамбль, таблицы, рисунки и отчёт.
- Все параметры — в `configs/config.yaml` (окна, сетки, гиперпараметры, пул ансамбля, список FM, темы новостей). Каждый шаг — отдельный скрипт в `src/` с инструкцией в начале файла.
- Полный прогон на Apple M3 Pro: Prophet ≈ 50 мин, statsforecast ≈ 45 мин, FM ≈ 1.5 ч, GBM ≈ 1.5 ч, загрузка GDELT ≈ 1-2 ч. Журнал экспериментов со всеми итерациями — `LOG.md`.
- Данные организатора в репозиторий не входят (Положение §9.2.2).

При разработке кода использовались инструменты ИИ-ассистирования (Claude Code). Все решения, результаты и текст проверены автором; автор отвечает за проект.

Приложение А. Пост-hoc эксперименты (не используются для выбора)

Всё в этом разделе сделано **после** фиксации решения, с просмотром test (4 раза для ансамбля v2, 1 раз для варианта nat3). Числа на test здесь — не независимая оценка. Заголовок (§1) остаётся v1.

Диагностика. Если заменить прогноз национальной компоненты на факт (оракул), test MAE декомпозиции падает с 318 / 566 / 526 / 691 до 252 / 366 / 419 / 394. Главный источник ошибки — национальная компонента (6 рядов), а не локальная модель. Эта диагностика смотрела на test.

Национальная компонента v3 (выбрана на validation). Ряд портала СберИндекса (национальные расходы, в origin o только месяцы $\leqslant$ o) вместо Росстата; для o $\geqslant$ 12 — среднее с Росстатом по категориям. Validation MAE декомпозиции с persistence: 428 / 682 / 587 / 1058 -> 348 / 429 / 525 / 735. Ограничение: портал скачан в винтаже 2026-10, поздние пересмотры данных 2023-2024 могли попасть в прошлое.

Test MAE	h = 1	h = 3	h = 6	h = 12
v1, заголовок	306	435	446	658
nat3: тот же отбор Caruana, пул v1 + декомпозиция на национальной v3	291	451	487	542
nat3 − v1, двусторонний 95% ДИ	−15 [−40; +10]	+16 [−2; +32]	+41 [−10; +99]	**−117 [−176; −63]**
v2: стекинг (`src/stack.py`), выбор пула и схемы после test	268	393	568	586
v2 − v1, двусторонний 95% ДИ	−37 [−79; +1]	−42 [−80; 0]	**+122 [+25; +218]**	−72 [−189; +35]

- **nat3** (вариант предрегистрирован в `LOG.md` до просмотра test): значимо лучше v1 только на h = 12 (−18%, DM-HLN p = 0.02); на h = 1-6 разница не значима. Проверка 2025 для «Всех категорий»: 0.137 против факта 0.132 (v1: 0.135).
- **v2** не лучше v1 значимо ни на одном горизонте и значимо хуже на h = 6 (продовольствие и маркетплейсы в 2024-H2 замедлились, а ряд портала нет). Проверка 2025: 0.130 против 0.132.
- Вывод: портал как источник национального роста полезен на годовом горизонте. Это направление для следующей версии, а не замена заголовка, выбранного по честному протоколу.

Приложение Б. Все модели: validation, test, ранги, R^2, значимость

Ранг — место среди 35 кандидатов и ансамбля на test (1 = лучший). ΔMAE к Prophet — двусторонний 95% ДИ. MAE ансамбля на validation посчитано на окне подбора весов.

Модель	MAE validation h = 1 / 3 / 6 / 12	MAE test h = 1 / 3 / 6 / 12	Ранг на test	R^2 на изменении, test
Наивная	726 / 668 / 868 / 1244	624 / 864 / 1124 / 1289	32 / 31 / 29 / 22	−0.04 / −0.07 / −0.37 / −0.90
Сез. наивная + рост	438 / 827 / 1244 / 1244	340 / 469 / 663 / 1289	21 / 4 / 21 / 22	0.06 / 0.36 / −0.11 / −0.90
Сез. наивная + нац. рост	578 / 876 / 1244 / 1244	439 / 491 / 617 / 1289	23 / 5 / 19 / 22	−0.59 / 0.35 / 0.35 / −0.90
Сез. наивная + рост, учёт сдвигов	438 / 827 / 1244 / 1244	340 / 469 / 663 / 1289	20 / 3 / 22 / 22	0.06 / 0.36 / −0.11 / −0.90
Prophet (базовая)	893 / 961 / 1241 / 2219	563 / 574 / 652 / 1361	25 / 23 / 20 / 26	−2.62 / −0.86 / −8.41 / −167.21
ETS	675 / 673 / 876 / 1244	634 / 807 / 1036 / 1383	33 / 27 / 26 / 27	−0.11 / 0.01 / −1.49 / −2.19
Theta	583 / 569 / 1008 / 1125	614 / 744 / 767 / 922	31 / 25 / 25 / 20	−0.08 / −0.76 / −1.48 / −29.38
ARIMA	723 / 820 / 1088 / 1325	645 / 862 / 1094 / 1529	34 / 30 / 27 / 28	−0.11 / −0.18 / −0.55 / −10.03
LightGBM v1	705 / 676 / 855 / 1193	313 / 420 / 761 / 969	17 / 1 / 24 / 21	0.39 / 0.49 / 0.22 / −0.17
TimesFM 2.5 (уровни)	714 / 765 / 944 / 1363	559 / 797 / 1283 / 1691	24 / 26 / 32 / 32	0.08 / 0.11 / −0.52 / −2.38
Chronos-2 (уровни)	706 / 772 / 997 / 1389	613 / 877 / 1361 / 1817	30 / 34 / 34 / 34	−0.04 / −0.09 / −0.92 / −2.25
Декомпозиция	428 / 682 / 587 / 1058	318 / 566 / 526 / 691	18 / 22 / 11 / 2	0.35 / 0.36 / 0.45 / −0.12
Декомп. (ср. 3 мес.)	421 / 681 / 565 / 1084	335 / 553 / 501 / 707	19 / 21 / 3 / 4	0.29 / 0.39 / 0.49 / −0.12
Декомп. (лок. сезон)	470 / 776 / 587 / 1058	345 / 605 / 702 / 691	22 / 24 / 23 / 2	0.05 / 0.24 / 0.06 / −0.12
TimesFM 2.5 (декомп.)	400 / 638 / 540 / 1098	296 / 522 / 493 / 729	1 / 6 / 2 / 11	0.43 / 0.46 / 0.52 / −0.34
Chronos-2 (мульти) (декомп.)	409 / 658 / 559 / 1106	302 / 531 / 532 / 772	8 / 10 / 14 / 14	0.43 / 0.43 / 0.48 / −0.25
Chronos-2 дообуч. (декомп.)	409 / 659 / 557 / 1111	308 / 528 / 527 / 771	14 / 7 / 12 / 13	0.41 / 0.45 / 0.50 / −0.27
GBM база	439 / 697 / 624 / 993	298 / 530 / 509 / 725	3 / 8 / 7 / 10	0.42 / 0.45 / 0.52 / −0.12
GBM + новости	442 / 691 / 618 / 994	299 / 532 / 511 / 719	6 / 12 / 9 / 7	0.42 / 0.44 / 0.52 / −0.12
GBM: всё (LightGBM)	443 / 695 / 622 / 999	296 / 532 / 509 / 724	2 / 11 / 6 / 9	0.42 / 0.44 / 0.52 / −0.12
GBM: всё (CatBoost)	434 / 686 / 616 / 1011	302 / 536 / 513 / 712	7 / 15 / 10 / 5	0.42 / 0.46 / 0.53 / −0.09
Ансамбль	301 / 369 / 484 / 800	306 / 435 / 446 / 658	10 / 2 / 1 / 1	0.42 / 0.59 / 0.53 / −0.17

ΔMAE к Prophet, руб., и двусторонний 95% ДИ. Жирным — ДИ целиком ниже нуля (значимо лучше Prophet).

Модель	h = 1	h = 3	h = 6	h = 12
Наивная	+61 [−222; +320]	+289 [−40; +728]	+472 [+26; +927]	−72 [−517; +241]
Сез. наивная + рост	**−223 [−510; −2]**	−105 [−261; +33]	+11 [−100; +104]	−72 [−517; +241]
Сез. наивная + нац. рост	−124 [−405; +91]	−83 [−228; +50]	−35 [−162; +96]	−72 [−517; +241]
Сез. наивная + рост, учёт сдвигов	**−223 [−509; −3]**	−106 [−261; +33]	+11 [−99; +104]	−72 [−517; +241]
ETS	+71 [−161; +278]	+233 [+68; +402]	+383 [+65; +681]	+22 [−298; +271]
Theta	+51 [−176; +259]	+170 [+16; +336]	+115 [−123; +326]	**−439 [−906; −138]**
ARIMA	+81 [−167; +297]	+287 [+73; +538]	+442 [+67; +817]	+168 [−112; +459]
LightGBM v1	**−251 [−532; −18]**	−154 [−354; +22]	+109 [−247; +528]	**−392 [−897; −26]**
TimesFM 2.5 (уровни)	−5 [−252; +184]	+223 [−116; +567]	+630 [+231; +999]	+330 [+165; +498]
Chronos-2 (уровни)	+50 [−235; +307]	+303 [−65; +711]	+708 [+286; +1140]	+456 [+294; +636]

Модель	h = 1	h = 3	h = 6	h = 12
Декомпозиция	**−245 [−491; −32]**	−9 [−207; +168]	**−126 [−246; −25]**	**−670 [−1074; −385]**
Декомп. (ср. 3 мес.)	**−229 [−486; −11]**	−21 [−224; +160]	**−151 [−270; −54]**	**−654 [−1046; −381]**
Декомп. (лок. сезон)	**−218 [−476; −3]**	+30 [−197; +244]	+49 [−81; +171]	**−670 [−1074; −385]**
TimesFM 2.5 (декомп.)	**−267 [−521; −52]**	−52 [−266; +139]	**−159 [−271; −66]**	**−632 [−1040; −354]**
Chronos-2 (мульти) (декомп.)	**−261 [−510; −44]**	−44 [−251; +142]	**−121 [−245; −9]**	**−589 [−1013; −316]**
Chronos-2 дообуч. (декомп.)	**−255 [−519; −35]**	−46 [−259; +144]	**−126 [−255; −8]**	**−590 [−1025; −309]**
GBM база	**−265 [−520; −46]**	−44 [−264; +157]	**−143 [−266; −35]**	**−636 [−1050; −341]**
GBM + новости	**−264 [−519; −44]**	−42 [−266; +165]	**−141 [−262; −36]**	**−642 [−1054; −345]**
GBM: всё (LightGBM)	**−267 [−523; −48]**	−43 [−266; +165]	**−143 [−266; −37]**	**−637 [−1038; −347]**
GBM: всё (CatBoost)	**−262 [−514; −46]**	−38 [−257; +163]	**−140 [−259; −36]**	**−649 [−1076; −342]**
Ансамбль	**−258 [−511; −37]**	−140 [−302; +16]	**−207 [−353; −66]**	**−702 [−1110; −430]**

Все 35 кандидатов и все метрики: `results/metrics/model_table_test.csv`, `metrics_test.csv`, `bootstrap_test_vs_prophet.csv`.

Источники

- СберИндекс, данные конкурса: https://sber.ru/sberindex/konkurs_sberindex (CC BY-SA 4.0).
- Портал СберИндекса, consumer-spending: https://sberindex.ru.
- Росстат, оборот розничной торговли: https://rosstat.gov.ru/statistics/roznichnayatorgovlya.
- The GDELT Project, GKG 1.0: https://www.gdeltproject.org.
- МЧС России, правительства регионов, Банк России: ссылка на каждый акт — в `data/external/event_registry.csv`
- Ansari et al. Chronos (2024); Chronos-2 (2025), amazon/chronos-2, Apache-2.0.
- Das et al. TimesFM (2024); google/timesfm-2.5-200m-pytorch, Apache-2.0.
- NX-AI TiRex-2 (2026), Apache-2.0. Datadog Toto 2.0 (2026), Apache-2.0.
- Adams R., MacKay D. Bayesian Online Changepoint Detection (2007).
- Truong C., Oudre L., Vayatis N. Selective review of offline change point detection methods (ruptures), 2020.
- Caruana R. et al. Ensemble Selection from Libraries of Models, ICML 2004.
- Diebold F., Mariano R. (1995); Harvey D., Leybourne S., Newbold P. (1997): тесты точности прогнозов.
- Gneiting T., Raftery A. Strictly proper scoring rules (2007); Bracher J. et al. WIS (2021).
- Taylor S., Letham B. Forecasting at Scale (Prophet), 2018.